


# Modèle GLM Gaussien



# Introduction

Le modèle gaussien dans le cadre des modèles linéaires généralisés (GLM) est considéré comme le plus basique. En effet, il constitue une extension directe de la régression linéaire classique, souvent réalisée par la méthode des moindres carrés. Cette simplicité réside dans le fait qu'il reprend les principes fondamentaux de la régression linéaire, tout en les adaptant à la structure des modèles généralisés, où la variable de réponse suit une distribution normale. Ce modèle offre ainsi une approche intuitive pour les premières étapes de l'analyse statistique dans un cadre GLM.



# Carte d'identité du modèle gaussien

- Type de variable dépendante : Il s'agit d'une variable continue dans l'intervalle  $] -\infty; +\infty[$ .

## Formulation

$$Y \sim Normal(\mu, \sigma)$$

$$g(\lambda) = \beta_0 + \beta \cdot X$$

$$g(x) = x$$

- Fonction de lien : Il s'agit de la fonction identitaire ;
- Paramètre modélisé :  $\mu$
- Distribution utilisée : Normale et Paramètres à estimer :  $\beta_0, \beta, \sigma$  ;
- Conditions d'application : Homoscédasticité .



# Les paramètres du modèle

L'interprétation des paramètres est la même que pour une régression linéaire classique :

- $\beta_0$  : la constante, soit la moyenne attendue de la variable  $Y$  lorsque les valeurs de toutes les variables  $X$  sont égales à 0 ;
- $\beta$  : les coefficients de régression qui quantifient l'effet d'une augmentation d'une unité des variables  $X$  sur la moyenne de la variable  $Y$  ;
- $\sigma$  : l'écart-type de  $Y$  après avoir contrôlé les variables  $X$ . Il peut s'interpréter comme l'incertitude restante après modélisation de la moyenne de  $Y$ .



# Conditions d'application

Les conditions d'application restent identiques à celles d'une régression linéaire classique. La condition d'homoscédasticité (**homogénéité de la variance**) est requise en raison du fait que la variance du modèle est contrôlée par un paramètre unique, tel que  $\text{var}(y) = \sigma^2$  (**l'écart-type de la distribution normale**). À titre comparatif, dans un modèle de Poisson, la variance est égale à la moyenne ( $\text{var}(y) = E(y)$ ), tandis que dans un modèle binomial négatif, on a :  $\text{var}(y) = E(y) + E(y)^{\frac{2}{\theta}}$ .



# La base de données utilisée

Le jeu de données utilisé dans ce cours, **DATA**, contient **1832** observations, dont **1612** complètes. Il inclut des informations sur des caractéristiques démographiques, les soins prénataux, les comportements maternels, ainsi que les résultats à la naissance, comme le poids de naissance (**bwght**) et les indicateurs de faible poids. Les variables incluent l'âge, l'éducation des parents, les soins prénataux, et des comportements tels que la consommation de cigarettes et d'alcool. L'objectif est de modéliser le poids de naissance à l'aide d'un modèle **GLM** gaussien pour identifier les facteurs influençant ce résultat de santé clé.



# Mise en œuvre du modèle GLM Gaussien avec R

- Vérification des conditions d'application

La première étape pour vérifier les conditions d'application consiste à s'assurer qu'il n'y a pas de multicolinéarité excessive.

```
# Chargement du package  
library(car)  
  
# Calcul du VIF  
vif(glm(bwght ~ cigs+poly(mage,2)+npvis+  
      drink+meduc, data=DATA))
```



## Mise en œuvre du modèle GLM Gaussien avec R

|               | GVIF     | Df | $\widehat{GVIF}(1/(2*Df))$ |
|---------------|----------|----|----------------------------|
| cigs          | 1.064066 | 1  | 1.031536                   |
| poly(mage, 2) | 1.148636 | 2  | 1.035251                   |
| npvis         | 1.022936 | 1  | 1.011403                   |
| drink         | 1.042601 | 1  | 1.021079                   |
| meduc         | 1.167141 | 1  | 1.080343                   |

Étant donné que toutes les valeurs de VIF sont inférieures à deux, nos données ne présentent pas de multicolinéarité problématique.






# Mise en œuvre du modèle GLM Gaussien avec R

- Vérification des conditions d'application

La seconde étape consiste à calculer et à afficher les distances de Cook.



Le graphique nous indique trois cas étranges.

# Mise en œuvre du modèle GLM Gaussien avec R

- Vérification des conditions d'application

Quelques caractéristiques des trois observations qui sont très influentes dans le modèle :

|      | mage | meduc | monpre | npvis | fage | feduc |
|------|------|-------|--------|-------|------|-------|
| 202  | 34   | 12    | 3      | 15    | 40   | 12    |
| 685  | 17   | 12    | 2      | 9     | 20   | 15    |
| 1555 | 20   | 12    | 3      | 10    | 33   | 11    |


Ces trois valeurs influentes correspondent aux observations 202, 685 et 1555. Par conséquent, nous allons tout simplement les supprimer.



# Mise en œuvre du modèle GLM Gaussien avec R

- Vérification des conditions d'application

Après avoir supprimé les observations influentes, nous procéderons au recalcul et à l'affichage des distances de Cook.



# Mise en œuvre du modèle GLM Gaussien avec R

## Note importante

Une fois ces observations retirées, les nouvelles distances de Cook n'indiquent plus d'observations fortement influentes (**Voir graphique précédent**). Nous pouvons donc passer à l'analyse des résidus simulés.


**L'histogramme ci-dessous** montre que la distribution normale s'ajuste pas correctement les données, qui sont légèrement asymétriques (légèrement étalées vers la gauche) et non négatives.




# Mise en œuvre du modèle GLM Gaussien avec R

DHARMA residual

QQ plot residuals




DHARMA residual vs. predicted  
Quantile deviations detected (red curves)  
Combined adjusted quantile test n.s.




# Mise en œuvre du modèle GLM Gaussien avec R

- Comparaison de la distribution originale de la variable dépendante et des simulations issues du modèle



# Mise en œuvre du modèle GLM Gaussien avec R

- Vérifier la condition d'homogénéité des variances



# Mise en œuvre du modèle GLM Gaussien avec R

À nouveau, nous observons que la figure précédente indique que le modèle anticipe uniquement des valeurs positives pour le poids à la naissance des nouveau-nés en grammes, ce qui correspond bien à notre cas (en rouge) . Par ailleurs, la variance semble homogène, comme en témoigne la dispersion des observations, qui suit globalement celle attendue par le modèle (en noir). Malgré ces différentes observations qui montrent que le modèle gaussien peut être adapté à nos données, nous poursuivons l'analyse de celui-ci.





# Mise en œuvre du modèle GLM Gaussien avec R

- Vérification de la qualité d'ajustement

*# Détermination des pseudo-R*

```
rsqs(  
  loglike.full = logLik(modele),  
  loglike.null = logLik(modelnull),  
  full.deviance = deviance(modele),  
  null.deviance = deviance(modelnull),  
  nb.params = modele$rank, n = nrow(DATA)  
)
```



# Mise en œuvre du modèle GLM Gaussien avec R

| Mesure             | Valeur |
|--------------------|--------|
| Deviance expliquée | 0.0133 |
| McFadden ajusté    | 0.0003 |
| Cox and Snell      | 0.0133 |
| Nagelkerke         | 0.0133 |

Le modèle explique 1,33 % de la déviance totale, indiquant une faible capacité à capturer la variabilité des données. Le pseudo- $R^2$  de McFadden ajusté est de 0,0003, montrant une amélioration marginale par rapport au modèle nul. Les coefficients de Cox and Snell (0,013) et de Nagelkerke (0,013) confirment cette faible performance explicative.



# Mise en œuvre du modèle GLM Gaussien avec R

- Moyenne du poids de naissance et du RMSE

```
# Moyenne du ppoids de naissance
```

```
mean(DATA$bwght)
```

```
## [1] 3417.271
```

```
# Calcul du RMSE
```

```
sqrt(mean((predict(modele, type = "response")  
- DATA$bwght)**2))
```

```
## [1] 553.6739
```



# Mise en œuvre du modèle GLM Gaussien avec R

- Moyenne du poids de naissance et du RMSE

La moyenne du poids de naissance dans l'échantillon est de **3417,27** grammes. L'erreur quadratique moyenne (**RMSE**) du modèle est de **553,67** grammes, ce qui reflète l'écart moyen entre les valeurs prédites et les valeurs observées. Cette **RMSE** indique une précision relativement faible du modèle, suggérant qu'il y a une marge importante d'amélioration possible pour mieux capturer les variations du poids à la naissance et réduire l'erreur des prédictions.

# Les résultats du modèle GLM Gaussien avec R

## • Tableau des résultats

|                | Coeff    | Err.Stand | IC.Inf   | IC.Sup  | p.value | Signif |
|----------------|----------|-----------|----------|---------|---------|--------|
| (Intercept)    | 3291.97  | 106.08    | 3084.05  | 3499.89 | 0.00    | ***    |
| cigs           | -7.99    | 3.53      | -14.91   | -1.07   | 0.02    | *      |
| poly(mage, 2)1 | 499.61   | 590.35    | -657.48  | 1656.70 | 0.40    |        |
| poly(mage, 2)2 | -1044.25 | 559.60    | -2141.07 | 52.57   | 0.06    | .      |
| npvis          | 10.62    | 3.76      | 3.25     | 17.99   | 0.00    | ***    |
| drink          | -50.87   | 63.12     | -174.59  | 72.85   | 0.42    |        |
| meduc          | 0.80     | 7.14      | -13.19   | 14.79   | 0.91    |        |

# Interprétation des résultats du modèle

Les résultats du modèle **GLM Gaussien** montrent que le nombre de cigarettes fumées par jour par la mère **cigs** et le nombre de visites prénatales **npvis** influencent significativement le poids à la naissance **bwght**. Chaque cigarette supplémentaire réduit le poids de **7,99** grammes en moyenne, tandis que chaque visite prénatale l'augmente de **10,62** grammes. Les autres variables, dont l'âge de la mère **mage**, la consommation d'alcool **drink** et le niveau d'éducation **meduc** n'ont pas d'effet statistiquement significatif sur le poids à la naissance.



*MERCI POUR VOTRE ATTENTION !!!*

