



CLASSIFICATION ASCENDANTE HIÉRARCHIQUE (CAH) SOUS R

***Cours Théorique
La SG-SERVICE
January 13, 2026***



INTRODUCTION

La classification ascendante hiérarchique (**CAH**) est une méthode statistique de regroupement visant à partitionner une population en classes homogènes tout en maximisant les différences entre celles-ci. Elle repose sur une matrice de distances, qui mesure la ressemblance entre individus, avec une distance nulle pour des observations identiques. La **CAH** regroupe les individus de façon itérative, créant un dendrogramme qui illustre ces regroupements hiérarchiques. En choisissant une hauteur de coupe dans ce dendrogramme, on obtient la partition finale, avec des classes de plus en plus vastes incluant des sous-groupes.



NOTIONS DE DISTANCE

La ressemblance entre observations se mesure par une distance entre individus, avec différents types de distances selon les données. Pour les variables quantitatives, on utilise des distances mathématiques comme **euclidienne** ou **Manhattan**, calculables via la fonction **dist**. Pour des variables qualitatives, la distance du Φ^2 est utilisée, notamment en analyse des correspondances multiples (avec la fonction **dist.dudi** de l'extension **ade4**). La distance de **Gower**, calculée avec **daisy** (cluster), permet de gérer à la fois des variables qualitatives et quantitatives. Enfin, la fonction **seqdist** (TraMineR) sert à mesurer des distances entre séquences.



DISTANCE EUCLIDIENNE

Il s'agit vraisemblablement de la distance la plus couramment utilisée, soit la longueur de la ligne droite la plus courte entre les deux objets considérés. La formule de la distance euclidienne est simplement la racine carrée de la somme des écarts au carré pour chacune des variables décrivant les observations **a** et **b**.

$$d(a, b) = \sqrt{\sum_{i=1}^v (a_i - b_i)^2}$$

avec **v** le nombre de variables décrivant les observations **a** et **b**.



DISTANCE DE MANHATTAN

Cette seconde distance est aussi couramment utilisée. Elle doit son nom au réseau de rue de l'île de **Manhattan** qui suit un plan quadrillé. La distance de **Manhattan** correspond à la somme des écarts absolus entre les valeurs des différentes variables décrivant les observations. La distance de Manhattan doit être privilégiée à la distance euclidienne lorsque les données considérées ont un très grand nombre de dimensions (**variables**). En effet, lorsque le nombre de variables est important (**supérieur à 30**), la distance euclidienne tend à être grande pour toutes les paires d'observations et à moins bien discriminer les observations proches et lointaines les unes des autres.



DISTANCE DE MANHATTAN

Formule

$$d(a, b) = \sum_{i=1}^v |a_i - b_i|$$

- ❶ **$d(a,b)$** : la distance de Manhattan entre les deux points **a** et **b** ;
- ❷ **a_i et b_i** : les coordonnées respectives des points **a** et **b** dans l'espace de dimension **v** ;
- ❸ **$|a_i - b_i|$** : la valeur absolue de la différence entre les coordonnées correspondantes des deux points .



DISTANCE DE GOWER

La distance de Gower (1971) peut être utilisée pour mesurer la distance entre deux observations lorsque les données sont à la fois qualitatives et quantitatives. Cette distance est comprise dans un intervalle de 0 à 1, 0 signifiant que les deux observations sont identiques et 1, que les observations sont radicalement différentes. Elle se calcule de la façon suivante :

$$d(a, b) = 1 - \frac{1}{p} \sum_{j=1}^p s_{12j}$$



DISTANCE DE GOWER

où s_{xyj} est défini comme suit : .

Formule

- 1 **Pour une variable qualitative** : $s_{xyj} = \begin{cases} 1 & \text{si } x_j = y_j \\ 0 & \text{sinon} \end{cases}$
- 2 **Pour une variable quantitative** : $s_{xyj} = 1 - \frac{|x_j - y_j|}{\max(j) - \min(j)}$

avec **p** le nombre de variables, **x** et **y** deux observations et **j** une variable.



DISTANCE DE GOWER

Bien que cette mesure permet de combiner des variables quantitatives et qualitatives, elle souffre de deux limites importantes :

- 1 Elle ne prend pas en compte le fait que certaines modalités qualitatives sont moins fréquentes ni que certaines combinaisons sont également moins fréquentes ;
- 2 Les variables qualitatives tendent à affecter bien plus la distance que les variables quantitatives. En effet, pour obtenir un écart de 1 sur une variable quantitative, il faut que les deux valeurs soient respectivement le maximum et le minimum de cette variable.



DISTANCE DE Φ^2

La distance du Φ^2 est une variante de la distance du χ^2 , utilisée lorsque les données à analyser sont uniquement **qualitatives**. Elle calcule la distance entre deux observations en additionnant les différences entre les valeurs de chaque variable (**1** si différentes, **0** si identiques, pour chaque variable), divisées respectivement par la **fréquence totale** d'occurrences de chaque modalité dans le jeu de données. Cette distance tient compte du fait que certaines valeurs pour des **variables qualitatives** peuvent être observées plus fréquemment que d'autres et qu'une distance plus grande devrait être obtenue entre deux observations si l'une des deux présente des modalités rares comparativement au reste du jeu de données.



DISTANCE DE Phi2

Elle peut être calculée de la façon suivante :

Formule

$$d_{\Phi^2}(i, j) = \frac{1}{Q} \sum_k \frac{(\delta_{ik} - \delta_{jk})^2}{f_k}$$

avec **i** et **j** deux observations, **k** une modalité d'une variable qualitative, **Q** le nombre total de modalités des variables qualitatives, $\delta_{ik} = 1$ si l'observation **i** a la modalité **k**, **0** sinon, et f_k la fréquence de la modalité **k** dans le jeu de données.



APPLICATION CAH APRÈS UNE ACM SOUS R

Nous allons réaliser l'ACM avec dudi.acm (ade4).

```
# Chargement de la bibliothèque du package
```

```
library(ade4)
```

```
# Analyse des correspondances multiples
```

```
analyse.acm <- dudi.acm(Data, scannf = FALSE, nf = 5)
```

```
# La matrice des distances avec la fonction dist.dudi
```

```
dist.matrice <- dist.dudi(analyse.acm)
```



APPLICATION CAH APRÈS UNE ACM SOUS R

● Notion de dendrogramme

Il faut ensuite choisir une méthode d'agrégation pour construire le **dendrogramme**. De nombreuses solutions existent (**saut minimum**, **distance maximum**, **moyenne**, **Ward** ...). Chacune d'elle produira un dendrogramme différent. Nous ne détaillerons pas ici ces différentes techniques. Cependant, à l'usage, on privilégiera le plus souvent la méthode de Ward. De manière simplifiée, cette méthode cherche à minimiser l'inertie intra-classe et à maximiser l'inertie inter-classe afin d'obtenir des classes les plus homogènes possibles.

APPLICATION CAH APRÈS UNE ACM SOUS R

La méthode de **Ward** est souvent incorrectement présentée comme une "**méthode de minimisation de la variance**" alors qu'au sens strict **Ward** vise l'augmentation minimum de la somme des carrés. En raison de la variété des distances possibles et de la variété des techniques d'agrégation, on pourra être amené à réaliser plusieurs dendrogrammes différents sur un même jeu de données jusqu'à obtenir une classification qui fait « **sens** ». La fonction de base pour le calcul d'un dendrogramme est **hclust** en précisant le critère d'agrégation avec **method**. Nous allons opter pour la méthode de **Ward** appliquée au carré des distances (**method = "ward.D2"**).




APPLICATION CAH APRÈS UNE ACM SOUS R

```
# Arbre
```

```
arbre <- hclust(dist.matrice, method = "ward.D2")
```

```
# Construction d'un dendrogramme
```

```
plot(arbre, labels = FALSE, main = "Dendrogramme")
```



APPLICATION CAH APRÈS UNE ACM SOUS R


Analyse de la forme du dendrogramme

Pour obtenir une partition de la population, il suffit de couper le dendrogramme à une certaine hauteur. Dans un premier temps, l'analyse de la forme du dendrogramme peut fournir des indications sur le nombre de classes à retenir. Dans notre exemple, deux classes bien distinctes apparaissent sur le dendrogramme dans la diapositive précédente.




APPLICATION CAH APRÈS UNE ACM SOUS R

Poursuivons l'analyse du choix des classes à retenir. Pour cela, nous allons représenter les sauts d'inertie du dendrogramme en fonction du nombre de classes.



APPLICATION CAH APRÈS UNE ACM SOUS R

D'après la diapositive précédente, on observe trois sauts assez nets à **2**, **5** et **8** classes, que nous avons représentés ci-dessous respectivement en **vert**, en **rouge** et en **bleu**.



APPLICATION CAH APRÈS UNE ACM SOUS R


A présent, nous allons visualiser les différentes partitions identifiées précédemment (partition à 2, 5 et 8 classes) avec la fonction `rect.hclust` directement sur le dendrogramme.

```
plot(arbre, labels = FALSE, main = "Dendrogrammes et Partitions",  
     xlab = "", ylab = "", sub = "", axes = FALSE, hang = -1)  
rect.hclust(arbre, 2, border = "green")  
rect.hclust(arbre, 5, border = "red")  
rect.hclust(arbre, 8, border = "blue")
```



APPLICATION CAH APRÈS UNE ACM SOUS R

Dendrogrammes et Partitions



APPLICATION CAH APRÈS UNE ACM SOUS R

Parmi les trois différentes partitions identifiées dans les diapositives précédentes, nous allons procéder à la selection de la meilleure partition.

```
# Découpage de l'arbre en différents nombres de clusters
```

```
cl2 <- cutree(arbre, k = 2) ; cl5 <- cutree(arbre, k = 5)
```

```
cl8 <- cutree(arbre, k = 8)
```

```
# Calculer l'inertie pour chaque partition
```

```
in2 <- sum(arbre$height[cl2]); in5 <- sum(arbre$height[cl5])
```

```
in8 <- sum(arbre$height[cl8])
```

APPLICATION CAH APRÈS UNE ACM SOUS R

```
# Créer un tableau des inerties
```

```
inertie <- data.frame(k = c(2, 5, 8),  
                      inertie = c(in2, in5, in8))
```

```
# Trouver la meilleure partition
```

```
m_partition <- inertie[which.min(inertie$inertie), ]  
cat("La meilleure partition est pour k =", m_partition$k)
```

```
## La meilleure partition est pour k = 2
```



APPLICATION CAH APRÈS UNE ACM SOUS R

Nous aboutissons à la même conclusion que celle observée directement sur le dendrogramme. Par conséquent, la meilleure partition est la partition en deux classes.

La partition en deux classes

```
classes <- cutree(arbre, 2)
```

```
kable(freq(classes))
```

n	%	val%
1447	72.4	72.4
553	27.7	27.7



APPLICATION CAH APRÈS UNE ACM SOUS R

Chargement du package

```
library(RColorBrewer)
```

Représentation graphique

```
par(mfrow = c(1, 2))
```

```
s.class(analyse.acm$li, as.factor(classes),
```


```
col = brewer.pal(2, "Set1"), sub = "Axes 1&2")
```

```
s.class(analyse.acm$li, as.factor(classes), 3, 4,
```

```
col = brewer.pal(2, "Set1"), sub = "Axes 3&4")
```



APPLICATION CAH APRÈS UNE ACM SOUS R



CAH APRÈS UNE ACM AVEC FactoMineR

L'extension **FactoMineR** offre une fonction **HCPC** qui permet d'effectuer une **CAH** à partir des résultats d'une analyse factorielle réalisée avec la même extension. Elle effectue simultanément le calcul de la matrice des distances, la construction du dendrogramme et le partitionnement de la population en classes. Par défaut, **HCPC** construit le dendrogramme en utilisant le carré des distances du Φ^2 et la méthode de **Ward**. Par défaut, l'arbre est affiché et coupé selon la partition avec la plus grande perte relative d'inertie.



CAH APRÈS UNE ACM AVEC FactoMineR

```
# Chargement du package FactoMineR
```

```
library(FactoMineR)
```

```
# Analyse des correspondances multiples ACM
```

```
analyse.acm <- MCA(Data, ncp = 5, graph = FALSE)
```

```
cah.acm <- HCPC(analyse.acm, graph = FALSE)
```

NOTA BENE : Par défaut, **HCPC** procède différemment pour calculer la matrice des distances en ne prenant en compte que les axes retenus dans le cadre de l'**ACM**.





CAH APRÈS UNE ACM AVEC FactoMineR

Affichage du dendrogramme

```
plot(cah.acm, choice = "tree")
```

Hierarchical clustering



CAH APRÈS UNE ACM AVEC FactoMineR

Analyse de la forme du dendrogramme

Le dendrogramme obtenu avec HCPC semble différent de celui calculé précédemment à partir de la matrice des distances fournie par dist.dudi. D'où l'importance du **nota bene** mentionné dans la diapositive précédente. Nous observons clairement qu'avec ce nouveau dendrogramme obtenu, la partition avec la plus grande perte relative d'inertie est celle en trois classes. Par conséquent, la meilleure partition est la partition en trois classes.



CAH APRÈS UNE ACM AVEC FactoMineR

La fonction `dist.dudi` prends en compte l'ensemble des axes pour calculer la matrice des distances. Toutefois, on peut aussi reproduire cela avec la fonction `HCPC` de `FactoMineR` en indiquant `ncp=Inf` au lieu de `ncp=5` lors du calcul de l'ACM.


```
# Analyse ACM et Création du dendrogramme
```

```
analyse.acm1 <- MCA(Data, ncp = Inf, graph = FALSE)
```

```
cah.acm1 <- HCPC(analyse.acm1, nb.clust = -1, graph = FALSE)
```




CAH APRÈS UNE ACM AVEC FactoMineR




Conclusion : On obtient bien cette fois-ci le même résultat.

CAH : AUTRES REPRÉSENTATIONS POSSIBLES


Hierarchical clustering on the factor map



CAH APRÈS UNE ACM AVEC FactoMineR



CAH APRÈS UNE ACM AVEC FactoMineR



MERCI POUR VOTRE ATTENTION !!!

