

CLASSIFICATION NON SUPERVISÉE

K-means

Cours Pratique

La SG-SERVICE

February 1, 2026

INTRODUCTION

Dans de nombreux domaines d'analyse de données, il est souvent utile de regrouper des observations similaires en ensembles homogènes, appelés clusters. Il existe deux méthodes classiques pour effectuer ce type de regroupement :

- La méthode des **k-means**,
- Le **clustering hiérarchique**.

Dans ce cours, nous allons nous concentrer sur la méthode des **k-means**, une approche que nous apprécions particulièrement pour son principe ingénieux et efficace.



MÉTHODE DES K-MEANS

La méthode des k-means permet de regrouper des objets (sujets, sites, points, etc.) en K clusters distincts. Ce nombre K doit être défini à l'avance, mais plusieurs approches permettent d'en déterminer la valeur optimale.

Cette méthode repose sur la minimisation de la somme des distances euclidiennes au carré entre chaque objet et le centroïde (point central) de son cluster.

Les k-means sont une approche de clustering non hiérarchique, ce qui signifie que les objets d'un même cluster ne sont pas organisés selon un degré de similarité interne.



MÉTHODE DES K-MEANS

Cette technique appartient aux algorithmes de classification non supervisée en machine learning. L'expression "non supervisée" signifie que les groupes ne sont pas définis à l'avance : l'objectif n'est pas d'apprendre à classer des données selon des catégories préexistantes, mais de découvrir naturellement des regroupements dans les données. Enfin, la méthode des k-means produit des clusters exclusifs, où chaque objet appartient à un seul groupe, sans chevauchement entre les clusters.



PRINCIPE : Notion de distance

→ La distance euclidienne

La distance euclidienne est au cœur de la méthode des k-means, car elle permet d'attribuer chaque point au cluster dont le centroïde est le plus proche. L'objectif est de minimiser la somme des distances euclidiennes au carré entre chaque point et son centroïde, ce qui réduit la variation intra-cluster (within-cluster variation en anglais).


Mathématiquement, la distance euclidienne est une extension du théorème de Pythagore, qui énonce que : *"Le carré de la longueur de l'hypoténuse (le côté opposé à l'angle droit) est égal à la somme des carrés des longueurs des deux autres côtés."*



PRINCIPE : Notion de distance

→ La distance euclidienne

Théorème de Pythagore



$$c^2 = a^2 + b^2$$

La distance euclidienne entre deux points $A(x_1, y_1)$ et $B(x_2, y_2)$ est donnée par :

$$d(A, B) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Pour un espace à n dimensions :

$$d(A, B) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

Cette mesure est utilisée dans l'algorithme des k-means pour minimiser la variation intra-cluster.

PRINCIPE : Notion de distance

→ La distance euclidienne

Note importante...

Il est essentiel de centrer et réduire les données en **k-means**, car des variables sur des échelles différentes influenceraient inégalement la distance euclidienne. Cette transformation rend les données comparables en supprimant l'effet des unités. Sans cette étape préalable, avant d'appliquer la méthode des K-means sur des variables ayant des échelles différentes, vous risquez d'obtenir des estimations biaisées.



L'ALGORITHME DES K-MEANS

—> Le principe de l'algorithme est le suivant :

- ➊ Attribuer aléatoirement un cluster à chaque objet ;
- ➋ Calculer le centroïde de chaque cluster ;
- ➌ Calculer la distance euclidienne entre chaque objet et les centroïdes de tous les clusters ;
- ➍ Affecter à chaque objet le cluster dont le centroïde est le plus proche ;
- ➎ Calculer la somme de la variabilité intra-cluster ;
- ➏ Répéter les étapes 2 à 5 jusqu'à atteindre un *équilibre*, ou *convergence*, c'est-à-dire lorsque plus aucun changement de cluster n'a lieu ou lorsque la somme de la variabilité intra-cluster se stabilise.



L'ATTRIBUTION INITIALE

Remarque...

Le résultat final, c'est-à-dire l'appartenance de chaque objet (ou sujet, ou point) à un cluster donné, peut dépendre de l'attribution initiale aléatoire des clusters effectuée lors de la première étape de l'algorithme. Pour éviter ce problème, il est nécessaire d'exécuter plusieurs fois l'algorithme et d'observer si la composition des clusters varie ou non. La fonction `kmeans()` effectue automatiquement ces multiples initialisations aléatoires et conserve uniquement les meilleurs résultats.



K-means AVEC R

→ Présentation des données

```
# Importation des données
```

```
data("iris")
```

```
df <- iris
```

```
kable(df[1:3, 1:4])
```

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width
5.1	3.5	1.4	0.2
4.9	3.0	1.4	0.2
4.7	3.2	1.3	0.2



K-means AVEC R

→ La nature des variables du jeu de données

```
# Nature des variables
```

```
str(df, vec.len = 3)
```

```
## 'data.frame':    150 obs. of  5 variables:
```

```
## $ Sepal.Length: num  5.1 4.9 4.7 4.6 5 5.4 4.6 5 ...
```

```
## $ Sepal.Width : num  3.5 3 3.2 3.1 3.6 3.9 3.4 3.4 ...
```

```
## $ Petal.Length: num  1.4 1.4 1.3 1.5 1.4 1.7 1.4 1.5 ...
```

```
## $ Petal.Width : num  0.2 0.2 0.2 0.2 0.2 0.4 0.3 0.2 ...
```

```
## $ Species      : Factor w/ 3 levels "setosa","versicolor"
```



K-means AVEC R

→ Sélection des variable numériques

```
# Sélection des variable numériques  
data.f <- df[, -5]
```

→ Standardisation des données

Avant d'appliquer les k-means, il est important de standardiser (centrer et réduire) les données. Cela peut être réalisé en utilisant la fonction `scale()`.

```
# Standardisation des données des données  
data.f_sc <- scale(data.f)
```



K-means AVEC R

→ Réalisation de la méthode des K-means ou K-moyennes

Les deux principaux arguments de la fonction `kmeans()` sont les suivants :

- **centers** : Détermine le nombre de clusters souhaités ;
- **nstart** : Spécifie le nombre de fois que l'algorithme est exécuté. Seul le meilleur résultat est retenu.

```
# Réalisation de la méthode des K-means
```

```
result.kmeans = kmeans(data.f_sc,centers=3,nstart =25)
```



K-means AVEC R

→ Affichage des clusters et de la variabilité intra-cluster

```
# Affichage des clusters
```

```
result.kmeans$cluster [1:60]
```

```
##      [1] 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3 3
```

```
## [39] 3 3 3 3 3 3 3 3 3 3 3 3 3 2 2 2 1 1 1 2 1 1 1
```

```
# Affichage de la valeur de la variabilité intra-cluster
```

```
result.kmeans$tot.withins
```

```
## [1] 138.8884
```



K-means AVEC R

→ Choix du nombre de clusters

Trois méthodes sont généralement utilisées pour déterminer le nombre optimal de clusters :

- **Méthode du coude (Elbow method)** : basée sur la minimisation de la somme des carrés des écarts à l'intérieur des clusters (SS_{within}) ;
- **Méthode de la silhouette moyenne (Average silhouette method)** : basée sur la maximisation du paramètre « silhouette moyenne » ;
- **Méthode de la statistique du gap (Gap statistic method)** : basée sur la comparaison de la variation totale intra-cluster pour différentes valeurs de k , par rapport à leurs valeurs attendues sous une distribution de référence nulle des données.



K-means AVEC R

→ Choix du nombre de clusters

Nous utiliserons dans ce cours uniquement la méthode Elbow pour le choix des clusters.

```
# Chargement des packages nécessaires

library(factoextra)

library(NbClust)


# Elbow method

fviz_nbclust(data.f_sc, kmeans, method = "wss") +
  geom_vline(xintercept = 3, linetype = 2) +
  labs(subtitle = "Elbow method")
```



K-means AVEC R

→ Choix du nombre de clusters



K-means AVEC R

—> Visualisations

À partir du graphique obtenu avec la méthode du coude (**méthode Elbow**), nous retenons deux clusters pour la suite de nos analyses. Nous procéderons ensuite à une nouvelle analyse des k-means sur ces deux clusters et poursuivrons par une représentation de la relation entre eux.

```
# Réalisation des K-means
```

```
result.kmeans2 <- kmeans(data.f_sc,centers=2,nstart =25)
```


```
# Visualisation de la relation entre les clusters
```

```
pairs(data.f_sc, col=c(1:2)[result.kmeans2$cluster])
```



K-means AVEC R

→ Visualisations



K-means AVEC R

—> Visualisations

Il est également possible de représenter les clusters sur un plan, c'est-à-dire en deux dimensions, en utilisant la fonction `fviz_cluster()`. Ce plan correspond à une analyse en composantes principales (ACP) réalisée au préalable.

```
library(factoextra)


# Visualisation sur le plan

fviz_cluster(result.kmeans2, data = data.f_sc,
  palette = c("red", "blue"), geom = "point",
  ellipse.type = "convex", ggtheme = theme_bw())
```

K-means AVEC R

→ Visualisations

Cluster plot



MERCI POUR VOTRE ATTENTION !!!

