

Le modèle de Cox

Cours Pratique

La SG-SERVICE

2025-12-14



Définition des notions

Fonction de survie

- Soit X_i le temps entre le début de l'observation et la défaillance ;
- Les X_i sont i.i.d. de fonction de densité $f(x)$ et de fonction de survie :

$$x > 0, S(x) = P(X > x), \text{ (v.a discrète)}$$

$$x > 0, S(x) = 1 - \int_0^x f(u) du, \text{ (v.a continue)}$$

Dans notre cours, X_i représente la durée entre le diagnostic de la maladie et le décès.



Définition des notions

Fonction de survie résiduelle

$$x > 0, S(x) = P(X - t > x | X > t) = \frac{S(t+x)}{S(t)}$$

Explication :

$$P(X - t > x | X > t) = \frac{P(X - t > x \cap X > t)}{P(X > t)}$$

$$P(X - t > x | X > t) = \frac{P(X > x + t)}{P(X > t)}$$

$$P(X - t > x | X > t) = \frac{S(t+x)}{S(t)}$$

Dans ce cours, la survie résiduelle correspond à la probabilité que le patient ne décède pas, sachant qu'à l'instant **t**, il est encore en vie.



Définition des notions

Taux de défaillance

$$x > 0, \alpha(x) = \lim_{h \rightarrow 0} \frac{1}{h} P(x \leq X < x + h | X \geq x)$$

$$\alpha(x) = \frac{-S'(x)}{S(x)} = \frac{f(x)}{S(x)}$$

Effet, on a :

$$f(x) = \lim_{h \rightarrow 0} \frac{1}{h} P(x \leq X < x + h) = F'(x) = -S'(x)$$

Appliqué à notre jeu de données, il s'agit de la probabilité que l'individu décède entre les instants x et $x + h$ étant donné qu'à l'instant x il est toujours en vie.



Définition des notions

Censure

On parle de censure C_i d'une donnée i si :

- Avant la fin de l'étude, on n'observe plus l'individu sans qu'il y ait eu de défaillance ;
- À la fin de l'étude, la défaillance n'a toujours pas été observée.

Sinon, si une défaillance est observée, on qualifie la donnée de complète.

La réponse à la fin de l'étude pour un individu i est notée :

$$X_i^{obs} = \min(X_i, C_i)$$



Définition des notions

Processus de comptage des défaillances

- T_i : la date de de défaillance pour l'individu i ;
- $N(t)$: la variable aléatoire indiquant le nombre de défaillances observées à l'instant t .
- Au début de l'étude, on a : $N(0)=0$.

$$Y_i(t) = \begin{cases} 1 & \text{si l'individu } i \text{ est encore à risque à } t \\ 0 & \text{sinon} \end{cases}$$



Introduction

Le modèle de Cox, également connu sous le nom de "modèle de régression semi-paramétrique à risques proportionnels", est une méthode de régression applicable aux données de survie en temps continu. C'est un modèle linéaire généralisé pour la probabilité de survie.

Formule du modèle

$$\alpha(t \mid Z_i(t)) = \alpha_0(t) \exp(Z_i(t)^\top \beta) \quad \text{Avec}$$

$\alpha_0(t)$: représentant le risque de base, une fonction non spécifiée (intensité en l'absence d'effet des covariables) ;



Introduction

β : indiquant les coefficients mesurant l'influence des covariables sur l'intensité ;

Z_i : désignant le vecteur des covariables pour un individu i .

- Hypothèse des risques proportionnels

Pour deux individus i et j , $\forall i \neq j$ on remarque :

Hypothèse des risques proportionnels

$$\frac{\alpha(t \mid Z_i)}{\alpha(t \mid Z_j)} = \frac{\exp(Z_i^\top \beta)}{\exp(Z_j^\top \beta)} = \exp((Z_i - Z_j)^\top \beta)$$

- ne dépend que des individus i et j ;
- constant au cours du temps.



Introduction

Le modèle de Cox peut efficacement approximer divers modèles paramétriques, tels que Weibull ou exponentiel. Lorsqu'on ne connaît pas le modèle paramétrique exact, le modèle de Cox constitue une alternative solide. Cependant, si le modèle paramétrique précis est identifié, il est préférable d'utiliser ce dernier.

Pour estimer un modèle de Cox, il est essentiel de disposer de deux variables spécifiques : Une variable représentant la durée jusqu'à l'événement d'intérêt ou jusqu'à la fin de la période d'observation pour les données censurées et Une variable binaire indiquant si l'événement s'est produit **1** ou non **0**.



Note importante

Lorsque toutes les variables explicatives sont invariantes dans le temps, le modèle peut être calculé directement sur le jeu de données, alors que lorsque certains facteurs évoluent au cours du temps, une procédure particulière est appliquée au préalable sur les données. S'il n'y a pas de facteurs explicatifs évoluant dans le temps, le modèle s'apparente à une "simple" régression linéaire.



Estimation du modèle

Nous cherchons à déterminer la probabilité qu'un individu **i**, caractérisé par des covariables Z_i , subisse un événement au moment T_j , en sachant qu'un événement se produit à ce moment-là.

Probabilité

$$P(\text{indiv. } i \text{ ait un eve. } T_j \mid \text{un eve. } T_j) = \frac{P(\text{indiv. } i \text{ ait un eve. } T_j)}{P(\text{un eve. } T_j)}$$

c'est la probabilité que l'individu **i** décède au moment T_j , sachant qu'un décès a eu lieu à la date T_j .



Estimation du modèle

- Le numérateur représente le taux de défaillance pour l'individu i au temps T_j ;
- Le dénominateur correspond à la somme des taux de défaillance pour l'ensemble des individus toujours à risque à T_j .

Définition

La vraisemblance d'un modèle correspond à la probabilité que ce modèle ait pu produire les données observées.



Estimation du modèle

Identifier la combinaison optimale des valeurs des paramètres qui maximise la vraisemblance revient à sélectionner le modèle le plus adéquat par rapport aux données observées. Étant donné que la vraisemblance est généralement très faible, il est courant de travailler avec son logarithme, appelé *log.vraisemblance*. Pour le modèle de Cox, on utilise le terme de *vraisemblance partielle*, car seuls les sujets ayant subi l'événement étudié sont inclus dans le calcul, tandis que les sujets censurés sont pris en compte de manière indirecte.



Estimation du modèle

La contribution de l'individu i à la vraisemblance est donc :

Formule

$$L_i(\beta) = \frac{\alpha_i(T_i|Z_i)}{\sum_{j=1}^n Y_j(T_i) \alpha_j(T_j|Z_j)}$$

$$L_i(\beta) = \frac{\alpha_0(T_i) \exp(Z_i^\top (T_i) \beta)}{\sum_{j=1}^n Y_j(T_i) \alpha_0(T_i) \exp(Z_i^\top (T_i) \beta)}$$

$$L_i(\beta) = \frac{\exp(Z_i^\top (T_i) \beta)}{\sum_{j=1}^n Y_j(T_i) \exp(Z_i^\top (T_i) \beta)}$$



Estimation du modèle

La fonction de **vraisemblance partielle** s'écrit :

$$L_p(\beta) = \prod_{i=1}^n \left\{ \frac{\exp(Z_i^\top \beta)}{\sum_{j=1}^n Y_j(T_i) \exp(Z_j^\top \beta)} \right\}^{\delta_i}$$

Avec T_i la date de défaillance de l'individu i .

On en dérive l'expression du **score partiel** :

$$U_p(\beta) = \sum_{i=1}^n \delta_i \left\{ Z_i - \frac{\sum_{j=1}^n Y_j(T_i) Z_j \exp(Z_j^\top \beta)}{\sum_{j=1}^n Y_j(T_i) \exp(Z_j^\top \beta)} \right\}$$



Estimation du modèle

Pour maximiser la vraisemblance partielle (c'est-à-dire maximiser le score partiel) et ainsi déterminer les paramètres β , il est courant d'utiliser l'algorithme de Newton-Raphson.

$$\beta_{k+1} = \beta_k + I_n^{-1}(\beta_k) U_p(\beta_k),$$
$$\text{avec } I_n = -E \left[\frac{\partial^2 \log L_p(\beta)}{\partial \beta \partial \beta^\top} \right]$$

Il est nécessaire de fournir une valeur initiale β_0 ainsi qu'un critère d'arrêt.



Mise en oeuvre du modèle sous R

Les coefficients sont estimés à l'aide de l'algorithme de **Newton-Raphson**.

```
Modele <- coxph ( surv ~ sex + age + ph.ecog + pat.karno  
+ ph.karno + meal.cal + wt.loss, data = DATA_SURV )
```

	Coeff	EXP.Coeff.	SE.Coeff.	Z	P.value	Signif
sex	-0.55	0.57	0.20	-2.75	0.006	***
age	0.01	1.01	0.01	0.93	0.352	
ph.ecog	0.74	2.09	0.22	3.29	0.001	***
pat.karno	-0.01	0.99	0.01	-1.49	0.137	.
ph.karno	0.02	1.02	0.01	2.00	0.046	**
meal.cal	0.00	1.00	0.00	0.11	0.913	
wt.loss	-0.01	0.99	0.01	-1.83	0.067	*



Notion de risque instantané et de résidu

Dans un modèle de régression linéaire classique, les résidus représentent l'écart entre les valeurs observées de la variable dépendante et les valeurs prévues par le modèle. En revanche, dans un modèle de Cox, c'est le risque instantané qui est modélisé, rendant la notion de résidu traditionnelle inapplicable, puisqu'il n'est pas possible de calculer une différence entre des valeurs observées et prédites de la même manière. Par conséquent, plusieurs autres types de résidus ont été définis, tels que ceux de Schoenfeld, de déviance, de martingale ou encore de score. Dans ce contexte, les résidus de Schoenfeld sont particulièrement pertinents.



Notion de résidu partiel de Schoenfeld

Les résidus de Schoenfeld sont associés aux covariables, non à la fonction de risque instantané, avec un résidu par covariable. Ils s'appliquent uniquement aux cas non-censurés. Un résidu représente l'écart entre la valeur d'une covariable pour un individu au moment de l'événement et la moyenne de cette covariable parmi tous les individus exposés au risque à ce moment. Contrairement à d'autres résidus, ils ne mesurent pas l'ajustement du modèle, mais la différence de profil entre un individu subissant l'événement et l'ensemble des individus exposés.



Analyse graphique des résidus de Schoenfeld

Les résidus de Schoenfeld peuvent être analysés à l'aide de graphiques pour identifier d'éventuelles violations de l'hypothèse de proportionnalité. L'approche consiste à représenter les résidus en fonction d'une transformation du temps. Une courbe représentant l'évolution moyenne des résidus peut être ajoutée au graphique pour indiquer la tendance générale. Toute déviation de cette courbe par rapport à une ligne horizontale suggère une possible violation de l'hypothèse de proportionnalité.



Test d'hypothèses

Note importante

Une méthode pour tester les résidus consiste à évaluer la corrélation entre les résidus et les durées de survie. Si l'hypothèse nulle d'absence de corrélation est confirmée, l'hypothèse de proportionnalité est validée ; dans le cas contraire, elle est rejetée. Alternativement, une régression linéaire des résidus en fonction du logarithme du temps peut être réalisée, suivie d'un test pour vérifier si la pente de la droite de régression est nulle.



Test d'hypothèses

$$\frac{1}{\sqrt{n}}U_p(\beta) \xrightarrow[n \rightarrow \infty]{L} N(0, \Sigma);$$

$$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow[n \rightarrow \infty]{L} N(0, \Sigma^{-1});$$

$\frac{1}{n}I_n(\hat{\beta})$ est un estimateur consistant de Σ .

Test de significativité d'un coefficient :

$$\begin{cases} H_0 : \beta = 0 \\ H_1 : \beta \neq 0 \end{cases}$$



Test d'hypothèses

Sous H_0 , la statistique de test est de la forme :

$$\sqrt{n} \cdot \frac{\hat{\beta}}{\hat{\sigma}} \xrightarrow[n \rightarrow \infty]{L} N(0, 1).$$

Un intervalle de confiance de niveau $1 - \alpha$ est alors donné par :

$$\text{IC}_{1-\alpha}(\beta) = \left[\hat{\beta} \pm u_{1-\alpha/2} \cdot \frac{\hat{\sigma}}{\sqrt{n}} \right]$$



Test d'hypothèses

- Détermination des intervalles de confiance à 95 % des coefficients :

```
IC_INF <- coef - 1.96 * se_coef
```

```
IC_SUP <- coef + 1.96 * se_coef
```

	Coeff	EXP.Coeff.	IC_INF.Coeff.	IC_SUP.Coeff.	P.value	Signif
sex	-0.55	0.57	-0.95	-0.16	0.006	***
age	0.01	1.01	-0.01	0.03	0.352	
ph.ecog	0.74	2.09	0.30	1.18	0.001	***
pat.karno	-0.01	0.99	-0.03	0.00	0.137	.
ph.karno	0.02	1.02	0.00	0.04	0.046	**
meal.cal	0.00	1.00	0.00	0.00	0.913	
wt.loss	-0.01	0.99	-0.03	0.00	0.067	*



Test d'hypothèses

- Interprétation des coefficients

Il est présumé que l'hypothèse des risques proportionnels est vérifiée.

$$\frac{\alpha(t \mid Z_i)}{\alpha(t \mid Z_j)} = \frac{\exp(Z_i^\top \beta)}{\exp(Z_j^\top \beta)} = \exp((Z_i - Z_j)^\top \beta)$$

Exemple de l'effet marginal d'un an supplémentaire :

$$= \frac{\exp(\text{sex}_i \times \beta_{\text{sex}} + \text{age}_i \times \beta_{\text{age}} + \dots + \text{wt.loss}_i \times \beta_{\text{wt.loss}})}{\exp(\text{sex}_i \times \beta_{\text{sex}} + (\text{age}_i + 1) \times \beta_{\text{age}} + \dots + \text{wt.loss}_i \times \beta_{\text{wt.loss}})}$$



Test d'hypothèses

- Interprétation des coefficients

$$HR_{age} = \frac{\exp(\text{age}_i \times \beta_{age})}{\exp((\text{age}_i + 1) \times \beta_{age})} == \exp(\beta_{age}) = 1.01$$

Quel que soit t, Chaque année supplémentaire d'âge multiplie le risque de décès par **1,01**, une augmentation de **1%**. Ce résultat est non significatif ;

Un risque relatif(HR) de **0,57** pour les femmes par rapport aux hommes signifie que le risque de décès est de **43%** plus faible que les hommes ;



Test d'hypothèses

Interprétation des coefficients

Un risque relatif (**HR**) est de **2,09** pour le score ECOG. Cela signifie que, toutes choses égales par ailleurs, chaque augmentation d'une unité du score multiplie le risque de décès par **2,09** ;

Un risque relatif (**HR**) est de **1,02** pour le score de Karnofsky évalué par le médecin (**ph.karno**). Cela signifie que, toutes choses égales par ailleurs, chaque augmentation d'une unité du score multiplie le risque de décès par **1,02**, soit une augmentation de **2%** ;



Test d'hypothèses

Interprétation des coefficients

Un risque relatif ou Hazard Ratio(**HR**) est de **0,99** pour le score de Karnofsky évalué par le patient (**pat.karno**). Cela signifie que, toutes choses égales par ailleurs, chaque augmentation d'une unité du score multiplie le risque de décès par **0,99**, soit une diminution de **1%** ;

Un risque relatif(**HR**) est de **0,99** pour la variable perte de poids au cours des six mois précédents (**en kg**). Cela signifie que, toutes choses égales par ailleurs, chaque perte de poids d'un kilogramme multiplie le risque de décès de **0,99**, soit une diminution de **1%**.



Différents tests de nullité simultanée des coefficients

- Rapport de vraisemblance :

$$2(L(\hat{\beta}) - L(\beta^{(0)})) \sim \chi^2, \text{ à } p \text{ degrés de liberté (ddl)}$$

p : correspond au nombre de paramètre du modèle non naïf.

- Test de Wald (maximum de vraisemblance) :

$$(\hat{\beta} - \beta^{(0)})^\top I(\hat{\beta})^{-1} (\hat{\beta} - \beta^{(0)}) \sim \chi^2, \text{ à } p \text{ degrés de liberté (ddl)}$$

- Score (ou logrank) :

$$U^\top(\beta^{(0)}) I(\hat{\beta})^{-1} U(\beta^{(0)}) \sim \chi^2, \text{ à } p \text{ degrés de liberté (ddl)}$$


où I est la matrice d'information de Fisher



Fonction de survie

Représentation graphique

```
plot(survfit(Modele), xlim = c(0, 300), ylim = c(0.7, 1))
```



Vérification de l'hypothèse des risques proportionnels

Note Importante

Vérification de l'hypothèse des risques proportionnels à partir de tests, qui sont entre autres les suivants :

- Numériques ;
- Graphiques (ex : tracé des résidus de Schoenfeld normalisés).

À tester sur un modèle avec des variables dont le coefficient est significativement non nul.



Vérification de l'hypothèse des risques proportionnels

- Test numérique

Pour chaque variable, on cherche à s'assurer que le coefficient associé est stable au cours du temps.

$$\begin{cases} H_0 : \beta_j(t) = \beta_j \\ H_1 : \beta_j(t) \neq \beta_j \end{cases}$$

```
model <- coxph (surv ~ sex + ph.ecog + ph.karno  
+ wt.loss, data = DATA_SURV )  
cox.zph(model)
```



Vérification de l'hypothèse des risques proportionnels

- Résultat du test numérique

##		chisq	df	p
##	sex	1.190	1	0.275
##	ph.ecog	3.987	1	0.046
##	ph.karno	6.630	1	0.010
##	wt.loss	0.031	1	0.860
##	GLOBAL	8.145	4	0.086

Au regard des résultats ci-dessus, les variables **ph.karno** et **ph.ecog** ne respectent pas l'hypothèse des risques proportionnels (Rejet de H_0).




Vérification de l'hypothèse des risques proportionnels

● Test graphique - Résidus de Schoenfeld

Représentation graphique

```
plot(cox.zph(model)[1]) ; abline(h=0, col = " red " )
```



Vérification de l'hypothèse des risques proportionnels

- Test graphique - Résidus de martingale

```
# Estimer les résidus de Martingale
```

```
residus.martingale <- residuals(model, type = "martingale")
```

```
# Représentation graphique
```

```
plot ( residus.martingale ~ DATA_SURV[ ,"sex" ] ,
```


```
  xlab = "sex" , ylab = "Residus de Martingale " )
```

```
lines ( lowess(DATA_SURV[ ,"sex" ] , residus.martingale ,  
  iter =0) , lwd=2 , col = " dodger blue " )
```



Vérification de l'hypothèse des risques proportionnels

● Test graphique - Résidus de martingale



Vérification de l'hypothèse des risques proportionnels


- Test graphique - Résidus de martingale (Modèle de Cox-Aalen)

```
# Chargement du package  
library(timereg)  
  
# Représentation graphique  
Div <- par(mfrow=c(1,4))  
  
plot(cox.aalen(surv ~ prop(sex) + prop(ph.ecog)  
+ prop(ph.karno) + prop(wt.loss), data = DATA_SURV,  
n.sim =100) , score =1)  
  
par(Div)
```



Vérification de l'hypothèse des risques proportionnels

● Test graphique - Résidus de martingale (Modèle de Cox-Aalen)



Rappel des hypothèses du modèle de Cox

Nous allons vous lister les hypothèses du modèle de Cox :

- ❶ **Hypothèse des risques proportionnels** : Pour évaluer cette hypothèse, il convient de vérifier si le paramètre θ_j varie avec le temps ($\beta_j(t) = \beta_j + \theta_j g_j(t)$) ;
- ❷ **Hypothèse de log-linéarité** : Bien que difficile à vérifier en pratique, cette hypothèse doit également être considérée ;
- ❸ **Forme des covariables** : Il est nécessaire d'examiner si les covariables doivent être transformées, par exemple en les élevant au carré, en prenant leur logarithme ou leur racine carrée.

La première constitue la principale hypothèse du modèle.



Références

-  Cox, D. R. (1972). Regression models and life-tables. *Journal of the Royal Statistical Society. Series B (Methodological)*, 34(2), 187–220.
-  Dupuy, J.-F., & Ledoux, J. (2012). *Analyse de durées de vie. Fiabilité.*
-  Fox, J. (2002). Cox proportional-hazards regression for survival data: The Cox proportional-hazards model. *Most*, 2008(June), 1–18.
-  Reboul, L. (2011). *Cours de durées de vie.*
-  Rossi, P. H., Berk, R. A., & Lenihan, K. J. (1980). *Money, work, and crime: Experimental evidence.* Quantitative studies in social relations. Academic Press.
-  Taupin, M.-L. (2011). *Durées de survie.*



MERCI POUR VOTRE ATTENTION !!!

