


DiD

DiD with Interaction

Doubles différences (Dif-in-dif) et Données de Panel



Cours Théorique
La SG-SERVICE
2026-01-18



La méthode des **doubles différences** est une méthode **quantitative quasi-expérimentale** permettant d'évaluer l'impact d'une *intervention* grâce à la constitution de **groupes de comparaison** et à la mesure de l'évolution d'un résultat entre un moment **initial pré-intervention** et un **moment ultérieur** où seulement un des deux groupes a reçu l'**intervention**. Cette méthode est très utile pour l'évaluation **ex post** de l'impact d'une intervention.

Quand utilise-t-on diff-in-diff ?

- On ne peut pas toujours sélectionner aléatoirement les bénéficiaires **d'une politique ou d'un programme**.
 - **Exemple** : estimer l'impact d'un programme mis en place dans le passé.
- Avant toute chose, il est nécessaire d'identifier :
 - ① Le groupe affecté par le changement de politique (**groupe traité**) ;
 - ② Le groupe non affecté par le changement (**groupe témoin**).
- La **méthode Diff-in-Diff** repose souvent sur l'identification d'une **expérience naturelle** permettant d'isoler **l'impact causal** d'une politique.
- **Exemples d'expériences naturelles** :
 - ① Un changement de **politique inattendu** ;
 - ② Une politique affectant uniquement les jeunes âgés de **16 ans**, mais pas ceux âgés de **15 ans**.
- La qualité du **groupe témoin** détermine directement la qualité de l'évaluation de l'impact.



Trois approches d'analyse de la méthode Diff-in-Diff

① À l'aide de la « boîte » (tableau de différences)

*Interprétation du **Diff-in-Diff** comme une comparaison de différences moyennes* entre les groupes **traité** et **témoin**, **avant** et **après** l'intervention.

② Représentation graphique

Analyse visuelle de l'évolution temporelle des *groupes* **traité** et **témoin**, permettant de vérifier l'hypothèse de tendances parallèles et d'illustrer l'effet du traitement.

③ Formulation en régression

Estimation de l'effet causal du traitement à l'aide d'un **modèle de régression** incluant une variable de **traitement**, une variable **temporelle** et leur **interaction**.




Doubles Différences(DD) à l'aide de la «Boîte»

	Groupe affecté par le changement de politique (Traitement)	Groupe non affecté par le changement de politique (Témoin/Contrôle)
Après le lancement du programme	$Y_1(u_i) \mid D_i = 1$	$Y_1(u_i) \mid D_i = 0$
Avant le lancement du programme	$Y_0(u_i) \mid D_i = 1$	$Y_0(u_i) \mid D_i = 0$
Différence	$(\bar{Y}_1 \mid D = 1) -$ $(\bar{Y}_0 \mid D = 1)$	$(\bar{Y}_1 \mid D = 0) -$ $(\bar{Y}_0 \mid D = 0)$

$$DD = ((\bar{Y}_1 \mid D = 1) - (\bar{Y}_0 \mid D = 1)) - ((\bar{Y}_1 \mid D = 0) - (\bar{Y}_0 \mid D = 0))$$



Doubles Différences(DD) à l'aide d'un «Graphique»



Doubles Différences(DD) à l'aide d'une «Régression»

→ Pour 2 périodes temporelles

$$Y_{it} = \alpha + \beta \mathbb{1}(t = 1) + \gamma \mathbb{1}(D_i = 1) + \delta \mathbb{1}(t = 1)\mathbb{1}(D_i = 1) + \varepsilon_{it}$$



$$\mathbb{E}(Y_{i1} \mid D_i = 1) = ???$$

$$\mathbb{E}(Y_{i0} \mid D_i = 1) = ???$$

$$\mathbb{E}(Y_{i1} \mid D_i = 0) = ???$$

$$\mathbb{E}(Y_{i0} \mid D_i = 0) = ???$$



$$\begin{aligned} DD &= (\mathbb{E}(Y_{i1} \mid D_i = 1) - \mathbb{E}(Y_{i0} \mid D_i = 1)) - (\mathbb{E}(Y_{i1} \mid D_i = 0) - \mathbb{E}(Y_{i0} \mid D_i = 0)) \\ &= ??? \end{aligned}$$

Doubles Différences(DD) à l'aide d'une «Régression»

→ Pour 2 périodes temporelles

$$Y_{it} = \alpha + \beta \mathbb{1}(t = 1) + \gamma \mathbb{1}(D_i = 1) + \delta \mathbb{1}(t = 1)\mathbb{1}(D_i = 1) + \varepsilon_{it}$$

↓

$$\mathbb{E}(Y_{i1} \mid D_i = 1) = \alpha + \beta.1 + \gamma.1 + \delta.1.1 + E(\varepsilon_{i1} \mid D_i = 1) = \alpha + \beta + \gamma + \delta$$

$$\mathbb{E}(Y_{i0} \mid D_i = 1) = \alpha + \beta.0 + \gamma.1 + \delta.0.1 + E(\varepsilon_{i0} \mid D_i = 1) = \alpha + \gamma$$

$$\mathbb{E}(Y_{i1} \mid D_i = 0) = \alpha + \beta.1 + \gamma.0 + \delta.1.0 + E(\varepsilon_{i1} \mid D_i = 0) = \alpha + \beta$$

$$\mathbb{E}(Y_{i0} \mid D_i = 0) = \alpha + \beta.0 + \gamma.0 + \delta.0.0 + E(\varepsilon_{i0} \mid D_i = 0) = \alpha$$

↓

$$\begin{aligned} DD &= (E(Y_{i1} \mid D_i = 1) - E(Y_{i0} \mid D_i = 1)) - (E(Y_{i1} \mid D_i = 0) - E(Y_{i0} \mid D_i = 0)) \\ &= (\beta + \delta) - \beta = \delta \end{aligned}$$

NOTA BENE : $\mathbb{E}(\varepsilon_{it} \mid D_i) = 0, \quad \forall t \in \{0, 1\}, D_i \in \{0, 1\}.$



Doubles Différences(DD) à l'aide d'une «Régression»

→ Pour plus de deux périodes de temps et/ou plusieurs groupes

Dans le cas où l'on dispose de **plus de deux** périodes et/ou **de plusieurs** groupes, on recourt à une **régression** à effets **fixes temporels** et **individuels**.

Modèle économétrique

$$Y_{it} = \alpha + \sum_{\tau=1}^T \beta_{\tau} \mathbf{1}(t = \tau) + \sum_{i=1}^I \gamma_i \mathbf{1}(i = i) + \delta D_{it} + \varepsilon_{it}$$

où D_{it} représente l'intensité du traitement D pour le groupe i à la période t .



Identification en Doubles Différences (Diff-in-Diff)

L'identification de l'effet du traitement repose sur la *variation intertemporelle* entre les groupes. Plus précisément, elle se fonde sur :

- *Les changements* dans la variable de résultat **Y** au fil du temps, qui sont spécifiques aux groupes de *traitement* ;
- *Les changements* de tendance de la variable de résultat affectant uniquement les groupes de *traitement* et non les groupes de *comparaison* ou de *contrôle*, survenant exactement au moment où le *traitement* prend effet.



La méthode **Diff-in-Diff** combinée au contrôle des effets fixes repose sur certaines hypothèses importantes :

- ❶ **Effets de groupes fixes** : Elle permet de contrôler les caractéristiques constantes propres à chaque groupe.
 - **Exemple** : agriculteurs propriétaires de leurs terres versus agriculteurs non-propriétaires.
- ❷ **Effets temporels communs** : Elle prend en compte les événements affectant tous les groupes à un moment donné, appelés **tendances communes**.
 - **Exemple** : la sécheresse de 2006 affectant tous les agriculteurs, quel que soit leur statut de propriété.
- ❸ **Impact immédiat du traitement** : L'approche **Diff-in-Diff** est valide uniquement si le changement de politique a un effet immédiat sur la variable de résultat.
 - Si l'effet du traitement est retardé, il est nécessaire d'introduire variables de traitement décalées dans le modèle.



Suites des avertissements

- ❶ La méthode des Doubles Différences (***Diff-in-Diff***) repose sur l'hypothèse que toute différence de tendance entre les groupes de ***traitement*** et les groupes ***témoins***, survenant au moment de ***l'intervention*** est imputable à cette ***intervention***.
- ❷ **Attention** : si ***d'autres facteurs*** influencent la différence de tendance entre les ***groupes***, l'estimation obtenue sera ***biaisée***.

- **Réaliser un test placebo (DD placebo)**

- ① Estimer un **modèle DD** sur des périodes *antérieures au traitement*.
- ② Ou utiliser comme groupe **traité** une population que l'on sait **non affectée** par l'intervention.
- ③ Si **l'estimateur DD** est significativement différent de **0**, alors l'hypothèse de **tendances parallèles** est violée et **l'estimateur DD** initial est probablement **biaisé**.

- **Utiliser un groupe témoin alternatif**

- ① Estimer le **modèle DD** avec un autre groupe de contrôle pertinent.
- ② Les **estimations DD** obtenues avec différents groupes **témoins** devraient être **similaires**.
- ③ De fortes divergences suggèrent un problème de **spécification** ou de **comparabilité**.

- **Utiliser une variable de résultat placebo**

- ① Choisir une variable de résultat que l'on sait **non affectée** par l'intervention.
- ② Utiliser la même année de traitement et le même groupe témoin.
- ③ Si **l'estimation DD** est différente de **0**, cela indique un **problème de validité du modèle**.



Problèmes fréquents

La méthode des doubles différences compare l'évolution d'un résultat entre un groupe traité et un groupe de contrôle, mais comporte certaines limites.

- **Sélection basée sur les résultats passés** : La participation au traitement peut dépendre de l'évolution du résultat avant l'intervention.
 - **Effet d'Ashenfelter ("Ashenfelter dip")** : les unités traitées connaissent souvent une baisse temporaire du résultat juste avant l'intervention.
 - Ce phénomène peut conduire à une surestimation de l'effet causal du traitement.
- **Mauvaise spécification de la forme fonctionnelle** : L'estimation en DD suppose implicitement une certaine forme fonctionnelle reliant la variable de résultat aux facteurs explicatifs.
 - Si la relation réelle est non linéaire alors qu'un modèle linéaire est imposé,
 - Les estimations obtenues peuvent être biaisées ou inefficaces.
- **Effets de traitement non linéaires** : L'ampleur de la réponse au traitement peut dépendre de l'intensité de l'intervention.
 - Lorsque l'effet du traitement est non linéaire,
 - Comparer un groupe fortement exposé au traitement à un groupe faiblement exposé peut conduire à une mauvaise interprétation de l'effet moyen du traitement.



- **Corrélation intra-groupe ou temporelle des observations**

: Les observations peuvent être corrélées au sein d'un même groupe ou d'une même période.

- Cette corrélation viole l'hypothèse d'indépendance des erreurs,
- Et entraîne généralement une sous-estimation des écarts-types,
- Ce qui conduit à des tests statistiques trop optimistes.

Remarque

Afin d'obtenir des inférences valides, il est recommandé d'utiliser des erreurs standards robustes, par exemple en les *clusterisant* au niveau du groupe ou de l'unité d'observation pertinente.

Impact d'une *intervention promotionnelle* sur les *écoutes musicales*

Une analyse en *différences-en-différences* à partir de *données longitudinales*.

CAS PRATIQUE : Diff-in-Diff

→ Préparation de données en utilisant le *data.table* et *dplyr*

```
# Chargement du package
library(data.table)
# Chargement des données
did_data <- fread("./did_data_exp.csv")
# Conversion de l'identifiant chanson en caractère
did_data$song_id <- as.character(did_data$song_id)
# Création de variables factorielles pour le traitement
did_data$treated_fct <- factor(
  did_data$treated, levels = c(0, 1),
  labels = c("non-traité", "traité"))
# Création de variables factorielles pour la période
did_data$post_fct <- factor(did_data$post,
  levels = c(0, 1), labels = c("avant", "après"))
# Conversion de la variable temporelle en format Date
did_data$week <- as.Date(did_data$week)
# Suppression de certaines chansons spécifiques
did_data <- did_data %>%
  dplyr::filter(!song_id %in%
    c("101", "143", "154", "63", "161", "274")) %>%
  as.data.frame()
```



CAS PRATIQUE : Diff-in-Diff À l'aide de la « boîte »

```
# Regardons la moyenne des variables de résultats
did_table <- did_data %>%
  group_by(treated_fct, post_fct) %>%
  summarise(
    mean_streams = mean(log(streams), na.rm = TRUE),
    .groups = "drop"
  )
did_wide <- did_table %>%
  tidyr::pivot_wider(
    names_from = post_fct,
    values_from = mean_streams
  ) %>%
  mutate(
    diff = après - avant
  )
did_wide
```



CAS PRATIQUE : Diff-in-Diff À l'aide de la « boîte »

→ Moyenne des variables de résultats

treated_fct	avant	après	diff
non-traité	9.767047	9.717792	-0.0492556
traité	9.853375	10.087762	0.2343871

$$\begin{aligned} DD &= (\mathbb{E}(Y_{i1} | D_i = 1) - \mathbb{E}(Y_{i0} | D_i = 1)) - (\mathbb{E}(Y_{i1} | D_i = 0) - \mathbb{E}(Y_{i0} | D_i = 0)) \\ &= (10.087762 - 9.853375) - (9.717792 - 9.767047) \\ &= 0.2343871 - (-0.0492556) \\ &= 0.2343871 + 0.0492556 \\ &= 0.2836427 \end{aligned}$$


Le programme a augmenté la variable de résultat d'environ **0,28** unité (en **log**) chez les individus **traités**, toutes choses égales par ailleurs.



CAS PRATIQUE : Diff-in-Diff À l'aide d'un graphique

→ Visualisation de la variable de résultat

```
# Chargement de package
library(panelView)
# Visualisation
panelview(streams ~ treated_post,
           data = did_data, index = c("song_id", "week"),
           type = "outcome", axis.lab.angle = 90)
```



CAS PRATIQUE : Diff-in-Diff À l'aide d'une régression

→ Modèle DID « simple » (OLS)

```
# Chargement du package
library(stargazer)
# Modèle DID « simple » (OLS)
did_m1 <- lm(
  log(streams + 1) ~ treated * post,
  data = did_data %>% filter(week != as.Date("2018-03-19")))
summary(did_m1)

##
## Call:
## lm(formula = log(streams + 1) ~ treated * post, data = did_data %>%
##   filter(week != as.Date("2018-03-19")))
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -6.2118 -0.4589 -0.0230  0.5686  2.6057
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   9.76719    0.01782  548.033 < 2e-16 ***
## treated        0.08629    0.04126   2.092  0.0365 *
## post         -0.05319    0.02520  -2.110  0.0349 *
## treated:post   0.28722    0.05834   4.923 8.77e-07 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.8566 on 5676 degrees of freedom
## Multiple R-squared:  0.01498,    Adjusted R-squared:  0.01446
## F-statistic: 28.78 on 3 and 5676 DF,  p-value: < 2.2e-16
```



CAS PRATIQUE : Diff-in-Diff À l'aide d'une régression

→ Modèle DID avec effets fixes

```
# Chargement du package
library(fixest)
# Modèle DID avec effets fixes
did_m2 <- feols(
  log(streams + 1) ~ treated * post |
    song_id + week,
  cluster = "song_id",
  data = did_data %>% filter(week != as.Date("2018-03-19")))
summary(did_m2)
```

```
## OLS estimation, Dep. Var.: log(streams + 1)
## Observations: 5,680
## Fixed-effects: song_id: 284, week: 20
## Standard-errors: Clustered (song_id)
##               Estimate Std. Error t value Pr(>|t|)
## treated:post 0.287222    0.0403 7.12703 8.5477e-12 ***
## ... 2 variables were removed because of collinearity (treated:post)
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
## RMSE: 0.177164      Adj. R2: 0.955458
##               Within R2: 0.090696
```



Le modèle estimé par OLS (*did_m1*) fournit une première approximation de l'effet du traitement, mais ne contrôle pas ***l'hétérogénéité*** inobservable entre les ***unités*** ni les chocs *communs* dans le temps.

Le modèle à effets fixes (*did_m2*) permet de corriger ces biais en contrôlant les effets spécifiques aux individus et aux périodes, tout en utilisant des ***erreurs standards clusterisées***. L'estimation obtenue est donc plus ***robuste*** et ***interprétable*** causalement.

MERCI POUR VOTRE ATTENTION !!!

