

La régression logistique multinomiale

Cours Pratique

La SG-SERVICE

2025-12-07



Introduction

La régression logistique multinomiale est une extension directe de la régression logistique binaire appliqué à une variable dépendante **Y** comportant plusieurs catégories (**M**>**2**) non ordonnées.

Formule de la régression logistique multinomiale

$$\pi_{m/x} = Pr(Y = m/x)$$

Une régression logistique multinomiale s'ajuste simultanément à **M-1** catégories de la variable dépendante **Y**.

Lorsqu'il est appliqué à une variable dichotomique, la régression logistique multinomiale devient équivalent à la régression logistique binaire.



Introduction

Pour une compréhension concise et précise d'une régression multinomiale :
Considérons une variable dépendante Y . Si cette variable comporte $M(M > 2)$ catégories possibles, nous effectuerons $M-1$ comparaisons par rapport à la catégorie de référence. Chaque comparaison est modélisée par sa propre équation, ce qui entraîne la génération de nombreux paramètres. Par exemple, supposons que notre variable Y possède quatre catégories et que nous disposions de sept variables prédictives X . Nous aurons alors $3(4-1)$ équations de régression, chacune avec 8 paramètres (7 coefficients et une constante), soit un total de 24 coefficients à analyser.



Carte d'identité de la régression logistique multinomiale

- Type de variable dépendante : Il s'agit d'une variable qualitative multinomiale avec **M** catégories ;

Formulation

$$Y \sim \text{Binomial}(p)$$

$$g(p = m \text{ avec } ref = a) = \beta_{0m} + \beta \cdot X_m$$

$$g(x) = \frac{\log(x)}{1-x}$$

- Fonction de lien : Il s'agit d'une fonction logistique ;



Carte d'identité de la régression logistique multinomiale

- Conditions d'application : Non-séparation complète, absence de sur-dispersion ou de sous-dispersion, Indépendance des alternatives non pertinentes.

Remarque Importante

Veuillez noter que le grand nombre de paramètres dans ce type de modèle nécessite un nombre d'observations plus élevé afin de disposer de suffisamment d'informations dans chaque catégorie pour ajuster tous les paramètres.



Carte d'identité de la régression logistique multinomiale

- Détection de la sur-dispersion ou de la sous-dispersion

Note Importante

Le khi-deux de Pearson

$$\chi^2 = \sum_{i=1}^N \sum_{c=1}^M \frac{(y_{ic} - p_{ic})^2}{p_{ic}}$$

Ratio

$$\frac{\chi^2}{(N - p)(M - 1)}$$

Pour chaque observation i , y_{ic} vaut **1** si elle appartient à la catégorie c et **0** sinon. p_{ic} représente la probabilité prédite que l'observation i appartienne à la catégorie c . **N** désigne le nombre total d'observations et **M** le nombre de catégories.



Carte d'identité de la régression logistique multinomiale

- Détection de la sur-dispersion ou de la sous-dispersion

critère de diagnostic de dispersion

Si le ratio $\frac{\chi^2}{(N-p)(M-1)}$ est égal ou supérieur à 1, le modèle présente une sur-dispersion. En revanche, s'il est inférieur à 1, le modèle montre une sous-dispersion. Un écart léger ($> 0,15$) n'est pas jugé préoccupant.

NOTA BENE : Les conditions d'application d'une régression multinomiale sont les mêmes que pour une régression binomiale, avec l'ajout de l'hypothèse sur l'indépendance des alternatives non pertinentes.



Propriété d'invariance sous permutation

Pour la régression logistique multinomiale, le choix de la catégorie de référence n'affecte pas l'ajustement du modèle. De manière plus générale, elle est invariante sous toutes les permutations des M ($M > 2$) catégories de la variable dépendante Y .

Note Importante

La régression logistique imbriquée est une extension de la régression logistique multinomiale, reposant sur le principe que certaines catégories peuvent être regroupées en '**nids**' (*nest* en anglais).



Mise en œuvre de la régression multinomiale avec R

Dans ce cours, nous allons procéder à l'analyse des différents profils professionnels des individus en fonction de leurs caractéristiques socio-économiques et professionnelles en utilisant une régression logistique multinomiale. L'objectif est de déterminer comment ces caractéristiques influencent la probabilité d'appartenir à différents types de profils professionnels.

Pour ce faire, nous allons créer une variable dépendante appelée *jobprofile* avec plusieurs catégories professionnelles à partir des variables binaires disponibles suivantes : **construc** et **trade**.



Mise en œuvre de la régression multinomiale avec R

- Création d'une variable dépendante :

```
# Créer la variable de catégorie professionnelle  
DATA$job_profile <- with(DATA,  
ifelse(construc=="oui" & trade=="non", "Construction",  
ifelse(trade=="oui" & construc=="non", "Commerce",  
"Autres")))
```

Les modalités de la variable dépendante : Construction, Commerce et Autres.



Mise en œuvre de la régression multinomiale avec R

- Statistique descriptive :

Répartition de la population selon la variable dépendante

```
Tab <- as.data.table(freq(DATA$job_profile, plot = F))
```

Professions	Effectif	Pourcentage
Autres	351	66.73%
Commerce	151	28.71%
Construction	24	4.56%
Total	526	100.00%



Mise en œuvre de la régression multinomiale avec R

- Vérification des conditions d'application

Avant de procéder à l'ajustement du modèle, nous débutons par une vérification rigoureuse afin de nous assurer de l'absence de multicolinéarité excessive entre les variables indépendantes.

```
# vérification de la multicolinéarité  
vif(glm(job_profile ~ educ + nonwhite + female  
      + married + numdep + smsa + lwage  
      + tenure + exper, data = DATA))
```



Mise en œuvre de la régression multinomiale avec R

- Résultat de la multicolinéarité :

	x
educ	1.518967
nonwhite	1.018026
female	1.204641
married	1.283663
numdep	1.141064
smsa	1.107415
lwage	1.558826
tenure	1.450357
exper	1.691463

Mise en œuvre de la régression multinomiale avec R

Interprétation du résultat : Toutes les valeurs du VIF (Variance Inflation Factor) sont inférieures à 2, ce qui confirme l'absence de multicolinéarité significative entre les variables indépendantes.

- Vérification de l'absence de sur ou sous-dispersion

Nous utilisons la fonction *vglm* du package *VGAM*, avec le paramètre **family = multinomial()**. Le rapport entre le χ^2 de Pearson et le nombre de degrés de liberté du modèle indique une absence ou pas de sur ou sous-dispersion.



Mise en œuvre de la régression multinomiale avec R

```
# Ajustement du modèle
```

```
modele <- vglm(job_profile ~ educ + nonwhite + female +  
married + numdep + smsa + lwage + tenure + exper, data = DATA,  
family = multinomial(refLevel="Construction"), model = T)
```

```
# Calcul du Khi2 de Pearson
```

```
pred <- predict(modele, type= "response")  
cat_predict <- colnames(pred)[max.col(pred)]  
freq_real <- table(DATA$job_profile)  
freq_pred <- table(cat_predict)
```



Mise en œuvre de la régression multinomiale avec R

```
# Suite calcul du Khi2 de Pearson
```

```
khi2 <- sum(residuals(modele, type = "pearson")^2)
```

```
## [1] 1263.151
```

```
# Calcul du degré de liberté
```

```
N <- nrow(DATA)
```

```
p <- modele@rank
```

```
r <- length(freq_real)
```

```
ratio <- khi2 / ((N-p)*(r-1))
```

```
## [1] 1.248173
```



Mise en œuvre de la régression multinomiale avec R

Interprétation du résultat : Le rapport calculé entre la statistique de Pearson (χ^2) et le nombre de degrés de liberté du modèle est de **1,05** indiquant une absence de sur ou sous-dispersion.

- Analyse des distances de Cook.

Étant donné que le modèle évalue la probabilité d'appartenir à **M-1** catégories, nous pouvons calculer **M-1** résidus par observation, et par conséquent, **M-1** distances de Cook.



Mise en œuvre de la régression multinomiale avec R

- Analyse des distances de Cook.

```
# Extraction des résidus et de la hat matrix
resid <- residuals(modele, type = "pearson")
hatmat <- hatvaluesvlm(modele)

# Calcul des distances de Cook

Distcooks <- lapply(1:ncol(resid),function(i){
  r <- resid[,i]
  h <- hatmat[,i]
  distcook <- (r/(1 - h))^2 * h/(1 * modele@rank)})
```



Mise en œuvre de la régression multinomiale avec R

- Analyse des distances de Cook.

Combinez les distances de Cook en une matrice

```
distcook_matrix <- do.call(cbind, Distcooks)
```

Convertissez la matrice en dataframe

```
matcook <- data.frame(  
  oid = 1:nrow(distcook_matrix),  
  distcook_matrix  
)
```





Mise en œuvre de la régression multinomiale avec R

- Analyse des distances de Cook.

Représentation graphique

```
ggarrange(plotlist = cooks, ncol = 2, nrow = 2)
```



Mise en œuvre de la régression multinomiale avec R

Aucune observation ne se distingue de manière significative comme cas étranges dans les figures ci-dessus. Par conséquent, nous avons décidé de conserver l'intégralité des observations dans notre base de données.

- Analyse des résidus simulés


Le modèle est limité par le package **DHARMa**, conçu pour les variables quantitatives, binaires ou ordinales. La solution sera de traiter le modèle multinomial comme une série de binomiaux pour analyser les résidus. Nous rappelons que pour un modèle multinomial, la variable dépendante est qualitative avec plus de deux catégories non ordinales.




Mise en œuvre de la régression multinomiale avec R

DHARMA residual

QQ plot residuals



DHARMA residual vs. predicted
No significant problems detected



Mise en œuvre de la régression multinomiale avec R










La figure précédente montre que les résidus se conforment à une distribution uniforme et qu'aucune anomalie notable n'est détectée (absence de valeur aberrante).

- Analyse de relation entre les variables indépendantes et les résidus

Nous allons générer des graphiques pour affiner le diagnostic et vérifier l'absence de relation entre les variables indépendantes et les résidus. Les graphiques ci-dessous nous indiquent qu'il n'y a pas de d'irrégularité observée pour les variables de perception.



Mise en œuvre de la régression multinomiale avec R



Mise en œuvre de la régression multinomiale avec R

- Vérification de la séparation parfaite

Dans notre contexte, en utilisant le package **VGM**, nous procéderons à l'analyse de l'effet Hauck-Donner pour déterminer si les variables indépendantes entraînent des séparations parfaites.

```
test <- hdeff(modele)

test[test==TRUE]
```

```
## named logical(0)
```

Le test Hauck-Donner n'a détecté aucune variable indépendante provoquant des séparations parfaites dans le modèle.



Mise en œuvre de la régression multinomiale avec R

- Vérification l'ajustement du modèle

Étant donné que les conditions d'application du modèle sont respectées, nous pouvons maintenant évaluer sa qualité d'ajustement.

```
# Calculer les R2
```

```
Rsquart(loglike.full = logLik(modele),  
loglike.null = logLik(modele.null),  
full.deviance = deviance(modele),  
null.deviance = deviance(modele.null),  
nb.params = slot(modele, "rank"), n = nrow(DATA))
```



Mise en œuvre de la régression multinomiale avec R

- Vérification l'ajustement du modèle

	Valeur
Deviance.expliquée	0.0784246
McFadden.ajusté	0.0289845
Cox.and.Snell	0.1136362
Nagelkerke	0.1447191

Le modèle parvient à expliquer 7,84 % de la déviance totale, avec un R^2 ajusté de McFadden de 0,029, et des R^2 de Cox et Snell et de Nagelkerke de respectivement 0,113 et 0,145.



Mise en œuvre de la régression multinomiale avec R

- Les résultats du modèle

Pour visualiser les résultats de la régression logistique multinomiale, la fonction **summary** est utilisée de la manière suivante :

```
# Affichage des résultats de la régression  
summary(modele)
```

Dans une régression multinomiale, la distribution utilisée est la distribution binomiale, avec une fonction de lien logistique. Les coefficients obtenus s'interprètent comme des rapports de cotes après transformation par la fonction exponentielle.



MERCI POUR VOTRE ATTENTION !!!

