

Modèle binomial négatif

Cours Pratique

La SG-SERVICE

2026-01-04



Introduction

La régression binomiale négative ressemble à la régression multiple, à la différence que la variable dépendante (Y) est une variable discrète suivant une distribution binomiale négative. Cette méthode est utilisée en alternative pour traiter le problème de ***l'équi-dispersion*** observé dans le modèle de Poisson. Elle étend le modèle de Poisson en relâchant ***l'hypothèse restrictive qui impose que la variance soit égale à la moyenne***. La régression binomiale négative classique repose sur une distribution ***Poisson-gamma mixte***, une approche largement utilisée car elle permet de capturer l'hétérogénéité en modélisant la distribution de Poisson avec une distribution gamma.



Concept de sur-dispersion

La dispersion se caractérise comme une mesure quantifiable de la variabilité des données par rapport à une valeur centrale. On distingue trois formes de dispersion : l'équi-dispersion, la sur-dispersion et la sous-dispersion. Théoriquement, dans le modèle de Poisson, le rapport entre la variance et la moyenne est égal à **1**, indiquant une équi-dispersion. Une sur-dispersion survient lorsque ce rapport dépasse **1**, tandis qu'une sous-dispersion se manifeste par un rapport inférieur à **1**. Pour les variables de type dénombrement, la sur-dispersion est un phénomène fréquent, souvent causé par des corrélations entre les observations ou par la violation des hypothèses de distribution des données, comme l'indépendance des observations.



Distinction entre sur-dispersion réelle et apparente

En pratique, un rapport supérieur à **1** n'indique pas nécessairement une sur-dispersion réelle, celle-ci pouvant être seulement apparente. Un test plus précis permet de confirmer la présence effective de sur-dispersion, ce qui détermine si des ajustements sont nécessaires. Concrètement, la sur-dispersion est vérifiable en divisant le chi-carré (χ^2) de Pearson par le nombre de degrés de liberté du modèle. Si ce rapport dépasse **1,25**, le recours à un modèle binomial négatif est recommandé. Cependant, avec un grand échantillon, un rapport de **1,05** peut aussi révéler une sur-dispersion réelle.



Distinction entre sur-dispersion réelle et apparente

Si le rapport se situe entre **1,01** et **1,25** pour un échantillon modéré, il existe des ajustements permettant de maintenir le modèle de Poisson sans traiter explicitement la sur-dispersion :

- Tout d'abord, il est possible qu'une variable explicative soit absente du modèle, ce qui rend essentiel l'identification précise des facteurs influençant le phénomène étudié ;
- Par ailleurs, la présence de données aberrantes pourrait nécessiter leur exclusion, ce qui peut être efficacement réalisé en analysant les résidus et la dispersion des données via l'écart-type ;



Distinction entre sur-dispersion réelle et apparente

- De plus, un nombre d'itérations insuffisant pourrait empêcher la convergence du modèle, justifiant l'augmentation de cette limite dans le logiciel utilisé ;
- En outre, certains prédicteurs pourraient être mal calibrés sur l'échelle appropriée, nécessitant une révision pour éviter la sur-dispersion ;
- Enfin, la relation linéaire entre la fonction de lien, les données observées et les prédicteurs pourrait être incorrectement spécifiée .

Si, malgré toutes les tentatives précédentes, la sur-dispersion persiste, elle est considérée comme étant réelle. Celle-ci peut avoir trois origines principales :



Distinction entre sur-dispersion réelle et apparente

- ❶ Il pourrait y avoir une variation très importante entre les données observées et celles prévues par le modèle ;
- ❷ Il pourrait exister une forte corrélation positive entre les observations ;
- ❸ Les hypothèses des modèles de type Poisson pourraient être violées, par exemple si $\mathbf{Y}$ inclut des valeurs décimales ou négatives .

La sur-dispersion, qui reflète une grande hétérogénéité de la variance, est souvent causée par une fréquence excessive de zéros. Pour traiter ce problème, les modèles **ZIP** (modèle de Poisson à inflation de zéros) et **ZINB** (modèle binomial négatif à inflation de zéros) sont les plus couramment utilisés.



Loi binomiale négative

La loi binomiale négative est une loi discrète, souvent interprétée comme une généralisation de la loi de Poisson. En particulier, on la considère fréquemment comme une mixture Poisson-Gamma. Cela signifie qu'elle peut être perçue comme une loi de Poisson dont le paramètre est une variable aléatoire suivant une distribution Gamma. Plus précisément, $Y|\Theta = \theta \sim P(\theta)$ avec $\Theta \sim G(\alpha, \beta)$, où $\alpha > 0$ et $\beta > 0$. Ici, α et β représentent respectivement le paramètre de forme et le paramètre d'échelle.



Loi binomiale négative

La densité de la loi Gamma est alors définie par :

$$f(\theta, \alpha, \beta) = \frac{1}{\beta^\alpha \Gamma(\alpha)} \theta^{\alpha-1} \exp\left(-\frac{\theta}{\beta}\right) \mathbb{1}_{\{\theta > 0\}}$$

où Γ désigne la fonction gamma :

$$\Gamma(x) = \int_0^\infty t^{x-1} \exp(-t) dt$$

Contrairement aux lois discrètes, les distributions gamma et normale incluent un paramètre de dispersion, ce qui leur confère deux paramètres permettant de modéliser la variabilité extra-poissonienne.



Loi binomiale négative

La densité jointe est donnée par :

$$P(Y = y | \Theta = \theta) f(\theta) = \frac{\theta^y}{y!} \exp(-\theta) \cdot \frac{1}{\beta^\alpha \Gamma(\alpha)} \theta^{\alpha-1} \exp\left(-\frac{\theta}{\beta}\right) \mathbb{1}_{\{\theta > 0\}}$$

En intégrant cette densité par rapport à θ , on obtient la probabilité de $\mathbf{Y}$, soit :

$$P(Y = y; \alpha, \beta) = \int_0^\infty P(Y = y | \Theta = \theta) f(\theta) d\theta$$
$$P(Y = y; \alpha, \beta) = \frac{\Gamma(y+\alpha)}{\Gamma(y+1)\Gamma(\alpha)} \left(\frac{1}{1+\beta}\right)^\alpha \left(\frac{\beta}{1+\beta}\right)^y$$



Loi binomiale négative

En régression binomiale négative, l'espérance de la variable aléatoire y dépend du temps d'exposition t et d'un ensemble de k variables explicatives notées x . Cette relation est exprimée par la formule suivante :

$$\mu_i = \exp(\ln(t_i) + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki})$$

Dans de nombreux cas, x_1 est égal à 1, ce qui fait de β_1 l'ordonnée à l'origine du modèle. Les coefficients de régression $\beta_1, \beta_2, \dots, \beta_k$ représentent des paramètres inconnus qui sont estimés à partir des données disponibles. Leurs estimations respectives sont notées $b_1, b_2, \dots, b_k$.



Déviance

La déviance est une mesure qui quantifie la différence entre la log-vraisemblance maximale possible et celle obtenue avec le modèle ajusté. Dans le cas de la régression multiple sous l'hypothèse de normalité, la déviance correspond à la somme des carrés des résidus. Pour la régression binomiale négative, elle se généralise en une version élargie de cette somme des carrés. La log-vraisemblance maximale est calculée en remplaçant μ_i par y_i dans l'expression de la vraisemblance. La formule de déviance :

$$D = 2 [L(y_i) - L(\mu_i)] = 2 \sum_{i=1}^n \left\{ y_i \ln \left(\frac{y_i}{\mu_i} \right) - (y_i + \alpha^{-1}) \ln \left(\frac{1 + \alpha y_i}{1 + \alpha \mu_i} \right) \right\}$$



Critère d'information d'Akaike (AIC)

Hilbe (2014) souligne que le critère d'information d'Akaike (**AIC**) est l'une des statistiques d'ajustement les plus fréquemment utilisées. Il existe deux variantes de l'**AIC** :

$$AIC(1) = -2(L - k)$$

$$AIC(n) = -\frac{2}{n}(L - k)$$

où **k** désigne le nombre de prédicteurs, y compris l'ordonnée à l'origine. L'expression **AIC(1)** est généralement celle rapportée par les logiciels statistiques.

Critère d'information bayésien (BIC)

Hilbe (2014) souligne également l'importance du critère d'information bayésien (**BIC**) en tant que statistique d'ajustement fréquemment utilisée. Ce critère peut être exprimé sous trois formes différentes :

$$BIC(R) = D - (df) \ln(n)$$

$$BIC(L) = -2L + k \ln(n)$$

$$BIC(Q) = -\frac{2}{n} (L - k \ln(k))$$

où df représente les degrés de liberté résiduels.



Résidus

Comme pour toute analyse de régression, il est essentiel de mener une analyse résiduelle exhaustive. Cela comprend la représentation graphique des résidus en fonction de différentes quantités, telles que les variables explicatives (afin de détecter d'éventuelles valeurs aberrantes ou des non-linéarités) ainsi que la variable de réponse.

- Résidus bruts

Le résidu brut est défini comme la différence entre la valeur observée de la réponse et celle estimée par le modèle. La formule du résidu brut s'exprime comme suit : $r_i = y_i - \mu_i$



- Résidus de Pearson

Les résidus de Pearson ajustent l'inégalité des variances des résidus en les divisant par l'écart type de la variable y . La formule du résidu de Pearson est donnée par : $p_i = \frac{y_i - \mu_i}{\sqrt{\mu_i + \alpha \mu_i^2}}$.

- Résidus d'Anscombe

Le résidu d'Anscombe est une méthode couramment utilisée qui s'approche d'un résidu d'écart normalisé. Il permet de normaliser le résidu brut, facilitant ainsi la détection des hétérogénéités et des valeurs aberrantes. La formule du résidu d'Anscombe est la suivante :

$$a_i = \frac{\frac{3}{\alpha} \left[(1 + \alpha y_i)^{\frac{2}{3}} - (1 + \alpha \mu_i)^{\frac{2}{3}} \right] + 3 \left(y_i^{\frac{2}{3}} - \mu_i^{\frac{2}{3}} \right)}{2 (\mu_i + \alpha \mu_i^2)^{\frac{1}{6}}}$$

Carte d'identité du modèle binomial négatif

- Type de variable dépendante : Il s'agit d'une variable de comptage.
Exemple : le nombre d'incidents de fraude bancaire par jour , le nombre de défaillances de composants électroniques par semaine, le nombre de messages d'erreur reçus par un serveur informatique par heure. ;

Formulation

$$Y \sim NB(\mu, \theta)$$

$$g(\mu) = \beta_0 + \beta X$$

$$g(x) = \log(x)$$

Carte d'identité du modèle binomial négatif

Note importante

- Fonction de lien : Il s'agit de la fonction logarithme naturel ($\log$) ;
- Conditions d'application : Absence d'excès de zéros, respect du lien variance-moyenne ;
- Distribution utilisée : Négative binomiale ;
- Paramètre modélisé : μ ;
- Paramètres à estimer : β_0 , β et θ ;



Mise en œuvre du modèle binomial négatif avec R

Dans la base de données **DATA**, l'objectif est de modéliser le nombre d'articles publiés par des biochimistes, en fonction de plusieurs variables explicatives, telles que le nombre d'années d'expérience, le type d'institution dans laquelle ils travaillent, etc.

- Statistique descriptive

Avant d'entamer la modélisation multivariable, il est conseillé de débiter par des analyses descriptives. Comme la variable dépendante est numérique, il est pertinent d'étudier les variations de moyennes selon les différentes variables catégorielles.



Mise en œuvre du modèle binomial négatif avec R

- Statistique descriptive

Vars	Men (494)	Women (421)	Totaux: (915)
Articles	2 [0 - 19]	1 [0 - 10]	2 [0 - 19]

Vars	Single (309)¹	Married (606)¹	Totaux: (915)¹
Articles	2 [0 - 7]	2 [0 - 19]	2 [0 - 19]

¹Moyenne [Min - Max]



Mise en œuvre du modèle binomial négatif avec R

- Vérification de l'absence de multicolinéarité

Avant d'ajuster le modèle, nous commençons par une vérification minutieuse pour nous assurer qu'il n'y a pas de multicolinéarité excessive entre les variables indépendantes.

```
model <- glm(art ~ fem + mar + kid5 + phd  
+ ment, data=DATA)  
vif(model)
```



Mise en œuvre du modèle binomial négatif avec R

- Résultat de la multicollinéarité :

	x
fem	1.108477
mar	1.264643
kid5	1.286110
phd	1.067307
ment	1.081109

Mise en œuvre du modèle binomial négatif avec R

Interprétation du résultat : Toutes les valeurs du VIF (Variance Inflation Factor) sont inférieures à 2, ce qui confirme l'absence de multicolinéarité significative entre les variables indépendantes.


- Calcul et visualisation des distances de Cook

```
# Calcul des distances de Cook  
cooksd <- cooks.distance(modele)  
df <- data.frame(cook = cooksd,  
  oid = 1:length(cooksd))
```



Mise en œuvre du modèle binomial négatif avec R

● Calcul et visualisation des distances de Cook




Le graphique nous indique une absence de cas étranges.


Mise en œuvre du modèle binomial négatif avec R

● Analyse des résidus simulés ^{DHARMA residual}

QQ plot residuals



DHARMA residual vs. predicted
No significant problems detected



Mise en œuvre du modèle binomial négatif avec R


La figure dans la diapositive précédente, illustrant le diagnostic des résidus simulés, indique que ceux-ci suivent une distribution uniforme. Aucune dispersion excessive ni valeurs aberrantes n'ont été détectées.

- Comparaison de la distribution originale et des simulations issues du modèle binomial négatif (intervalles de confiance représentés en rouge)


La figure ci-dessous démontre que le modèle parvient à reproduire fidèlement les données de la distribution initiale.



Mise en œuvre du modèle binomial négatif avec R



Mise en œuvre du modèle binomial négatif avec R



Mise en œuvre du modèle binomial négatif avec R

- Vérification de la qualité d'ajustement

Détermination des pseudo-R

```
rsqs( loglike.full = logLik(modele),  
      loglike.null = logLik(modelnull),  
      full.deviance = deviance(modele),  
      null.deviance = deviance(modelnull),  
      nb.params = modele$rank, n = nrow(DATA)  
)
```



Mise en œuvre du modèle binomial négatif avec R

Mesure	Valeur
Deviance expliquée	0.0027
McFadden ajusté	0.0267
Cox and Snell	0.1015
Nagelkerke	0.1046

Le modèle explique 0,27 % de la déviance totale, ce qui indique une capacité limitée à capturer la variabilité des données. Le pseudo- R^2 de McFadden ajusté est de 0,027, suggérant une amélioration très faible par rapport au modèle nul, ce qui reflète une adéquation marginale du modèle aux données. Les coefficients de Cox and Snell (0,101) et de Nagelkerke (0,105) confirment également une faible performance explicative du modèle.



Mise en œuvre du modèle binomial négatif avec R

```
# Calcul du RMSE
```

```
sqrt(mean((predict(modele,type ="response")-DATA$art)**2))
```

```
## [1] 1.858989
```

```
# Nombre moyen d'articles
```

```
mean(DATA$art)
```

```
## [1] 1.692896
```



Mise en œuvre du modèle binomial négatif avec R

L'erreur quadratique moyenne (RMSE) du modèle est de 1,859, ce qui indique qu'en moyenne, le modèle se trompe d'environ 1,86 articles publiés par chercheur. Si nous comparons cette valeur avec le nombre moyen d'articles publiés, qui est de 1,693, cela montre que l'erreur du modèle est relativement élevée par rapport à la moyenne. Cette performance peut s'expliquer par la dispersion des données et la variabilité des publications, où certains chercheurs publient beaucoup moins ou plus que la moyenne, rendant les prédictions difficiles.



Les résultats du modèle binomial négatif

```
# Script du modèle binomial négatif
```

```
modele <- gam(art ~ fem + mar + kid5 + phd + ment,  
family=nb(link="log"), data=DATA)
```

```
null_deviance <- round(modele$null.deviance,2)
```

```
df_null <- round(modele$df.null,2)
```

```
log_likelihood <- round(logLik(modele)[1],2)
```

```
AIC_value <- round(AIC(modele),2)
```

```
BIC_value <- round(BIC(modele),2)
```



Les résultats du modèle binomial négatif

● Statistiques globales sur un modèle

Statistique	Valeur
Déviance nulle	1101.53
Degrés de liberté du modèle nul	915.00
Log-likelihood	-1560.97
AIC	3135.94
BIC	3169.68
Déviance	997.75
Degrés de liberté des résidus	909.00
Nombre d'observations	915.00



Les résultats du modèle binomial négatif

Caractéristique	$\exp(\text{Beta})^1$	95% IC	p-valeur
fem			
Men	1,00	—	
Women	0,81**	0,70 – 0,93	0,003
mar			
Single	1,00	—	
Married	1,16	0,99 – 1,37	0,068
kid5	0,84***	0,76 – 0,93	<0,001
phd	1,02	0,95 – 1,09	0,7
ment	1,03***	1,02 – 1,04	<0,001



Interprétation des résultats du modèle

Les résultats du modèle indiquent que les femmes publient **19** % d'articles en moins que les hommes, et ce de manière significative ($p = 1$ %). Le mariage est associé à une augmentation de **16** % des publications, cet effet est statistiquement significatif au seuil de **5** %. Chaque enfant de moins de **5** ans réduit la productivité de 16 %, un impact significatif ($p = 1$ %). Le doctorat n'influence pas de manière notable le nombre de publications, tandis que le mentorat augmente significativement ($p = 1$ %) la productivité de **3** % par unité supplémentaire.



MERCI POUR VOTRE ATTENTION !!!

