

PRÉPARATION DS DATA MINING PARTIE THÉORIQUE

1 Partie 1

Soient (x_i, y_i) , $i = 1, \dots, n$ un échantillon i.i.d d'un couple de variables $(X, Y) \in R^3 \times \{0, 1\}$. Un modèle de régression logistique et un modèle de régression probit ont été entraînés sur un sous échantillon d'apprentissage (l'échantillon ayant été partagé en deux échantillons d'apprentissage et de test) pour estimer le lien entre Y et X .

1. Un modèle linéaire classique serait-il adapté pour modéliser Y en fonction de X ?
2. Le modèle de régression probit est-il un modèle de classification ?

	y	X1	X2	X3
	0:485	Min. : -3.23639	Min. : -3.04536	Min. : -3.03684
	1:515	1st Qu.: -0.70846	1st Qu.: -0.73332	1st Qu.: -0.57447
		Median : -0.05887	Median : -0.03182	Median : 0.07692
		Mean : -0.01583	Mean : -0.02479	Mean : 0.06814
		3rd Qu.: 0.68764	3rd Qu.: 0.71756	3rd Qu.: 0.70388
		Max. : 3.26641	Max. : 3.03903	Max. : 3.02360

3. Quelle est la taille de l'échantillon? Quel est le pourcentage d'individus de l'échantillon ayant pris la valeur de $Y = 1$.
4. Quelle est la dimension des instances?
5. Le résultat de l'estimation du modèle logistique est

term	estimate	std.error	statistic	p.value
<chr>	<dbl>	<dbl>	<dbl>	<dbl>
1 (Intercept)	-0.0869	0.137	-0.633	5.27e- 1
2 X1	2.71	0.256	10.6	3.55e-26
3 X2	-3.78	0.332	-11.4	5.83e-30
4 X3	1.93	0.220	8.76	2.03e-18

- Ecrire le modèle estimé
- Dans ce modèle logistique comment interprétez-vous les coefficients des variables explicatives ?
- Donner les odds-ratios. Interpréter

6. Le résultat de l'estimation du modèle probit est

	term	estimate	std.error	statistic	p.value
	<chr>	<dbl>	<dbl>	<dbl>	<dbl>
1	(Intercept)	-0.0489	0.0776	-0.630	5.29e- 1
2	X1	1.52	0.133	11.4	3.83e-30
3	X2	-2.13	0.172	-12.4	3.29e-35
4	X3	1.08	0.117	9.27	1.92e-20

(a) Ecrire le modèle estimé

(b) Dans ce modèle logit comment interprétez-vous les coefficients des variables explicatives ?

(c) Donner les odds-ratios. Interpréter

7. Quelle est la différence entre la régression logistique et la régression probit en termes de fonction de lien

8. Prédiction des modèles sur l'échantillon test

[1] "Logistic Regression Classification Report:"

Confusion Matrix and Statistics

	Reference	
Prediction	0	1
0	137	34
1	8	120

Accuracy : 0.8595
95% CI : (0.8149, 0.8969)

Sensitivity : 0.9448
Specificity : 0.7792
Pos Pred Value : 0.8012
Neg Pred Value : 0.9375
Balanced Accuracy : 0.8620

[1] "Probit Regression Classification Report:"

Confusion Matrix and Statistics

	Reference	
Prediction	0	1
0	137	35
1	8	119

Accuracy : 0.8562
95% CI : (0.8112, 0.8939)

Sensitivity : 0.9448
Specificity : 0.7727
Pos Pred Value : 0.7965
Neg Pred Value : 0.9370
Balanced Accuracy : 0.8588

- (a) Quelle est la taille de l'échantillon d'apprentissage, de test?
- (b) Selon les résumés des modèles, lequel des deux modèles offre le meilleur taux de biens prédits ?
- (c) Donner d'autres mesures de performance à considérer pour évaluer ces modèles, et pourquoi sont-elles importantes ?
- (d) Dans les deux modèles, un seuil de 0.7 a été utilisé pour la prédiction. Comment le choix du seuil affecte-t-il les résultats de la classification ?
- (e) Quel serait l'impact de l'utilisation d'un seuil différent dans le cas du modèle probit ?

2 Partie 2

- 1. Quelle est la principale différence entre la classification et la régression?
- 2. Quelle est la principale différence entre le clustering (partitionnement) et la classification?
- 3. On se place dans le cas d'une population sur laquelle est définie une partition en $K = 2$ groupes, notés G_1 et G_2 . Les proportions théoriques de ces deux groupes sont respectivement p_1 et p_2 . On suppose que la distribution de probabilité d'une observation $X = (X_1, X_2)$ est donnée pour chaque groupe par une distribution de probabilité normale $N(\mu_k, \Sigma)$. On considère la règle qui consiste à affecter une nouvelle observation x au groupe G_k si

$$\delta_k(x) = x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log p_k$$

est maximale.

- (a) Quel est le nom de cette règle ?
- (b) On a appliqué cette règle sur un jeu de données de taille $n = 125$ avec $n_1 = 30$ observations dans G_1 et $n_2 = 95$ observations dans G_2 . On suppose que les probabilités p_1 et p_2 ont été estimées par les proportions des groupes. On obtient les résultats suivants: 23 des individus de G_1 ont été correctement prédits et 91 des individus de G_2 ont été bien classés. Donnez le pourcentage d'individus de G_1 et le pourcentage d'individus du groupe G_2 qui ont été mal classés.

- Le pourcentage d'individus de G_1 mal classés est

$$1 - \hat{p}_1 = 1 - \frac{23}{30} = \frac{7}{30}$$

- Le pourcentage d'individus de G_2 mal classés est

$$1 - \hat{p}_2 = 1 - \frac{91}{95} = \frac{4}{95}$$

- (c) Supposons que la propension Y_i^* à rembourser un crédit d'un individu i ne dépende que de son statut familial décrit par 3 modalités : célibataire : $X = 1$; marié : $X = 2$; autre : $X = 3$

Est-ce qu'un modèle latent sous la forme :

$$Y^* = \beta_0 + \beta_1 X + u$$

a un sens?

3 Partie 3

On se place dans le modèle :

$$Y_i = s(X_i) + \varepsilon_i, \quad i = 1, \dots, n$$

où $\{(X_i, Y_i), i = 1, \dots, n\}$ sont des variables aléatoires identiquement et indépendamment distribuées de densité jointe $f(\cdot, \cdot)$ par rapport à la mesure de Lebesgue, les X_i sont de loi uniforme sur $[0, 1]$, les ε_i sont i.i.d. de loi $\mathcal{N}(0, \sigma^2)$, les X_i et les ε_i sont indépendantes, s est une fonction à valeurs réelles bornée.

On s'intéresse à l'estimation par méthode du noyau de s . On définit l'estimateur $\hat{s}_h(x)$ à noyau de $s(x)$ par :

$$\hat{s}_h(x) = \frac{1}{nh} \sum_{i=1}^n Y_i K\left(\frac{x - X_i}{h}\right),$$

où $h = h_n \rightarrow 0$. L'objectif de cette partie est d'étudier la convergence en moyenne quadratique de $\hat{s}_h(x)$ sous les hypothèses suivantes :

- K est un noyau d'ordre 1 tel que

$$\int K^2(t)dt < \infty, \quad \int t^2 |K(t)| dt < \infty, \quad \int t^2 K(t) dt \neq 0$$

- s est de classe $\mathcal{C}^2$ et sa dérivée seconde s'' est bornée.

Montrer que :

1.

$$\hat{s}_h(x) = \int y \hat{f}_h(x, y) dy,$$

où

$$\hat{f}_h(x, y) = \frac{1}{nh^2} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right) K\left(\frac{y - Y_i}{h}\right)$$

est l'estimateur à noyau de $f(x, y)$.

Montrer que pour x tel que $s''(x) \neq 0$:

2.

$$Var(\hat{s}_h(x)) \leq \frac{\sigma^2}{nh} \int K^2(t) dt + \frac{s^2(x)}{nh} \int K^2(t) dt,$$

3.

$$E((\hat{s}_h(x) - s(x))) = \frac{h^2}{2} s''(x) \int t^2 K(t) dt (1 + o(1)).$$

En déduire que:

$$\lim_{n \rightarrow \infty} n^{4/5} E((\hat{s}_h(x) - s(x))^2) = O(1),$$

si h_n est choisie de manière optimale : c'est-à-dire: h_n minimise

$$I = \frac{1}{nh} \int K^2(t) dt (\sigma^2 + s^2(x)) + \frac{h^4}{4} \left(s''(x) \int t^2 K(t) dt \right)^2.$$