

## DS DATA MINING DU 23 MARS 2026

## Partie Pratique

La base de données 'DataDS-26.csv' utile à cette partie est sous Moodle.

## 1 Exercice

Passez-vous beaucoup de temps sur Internet et sur Facebook ? Pour tenter de répondre à cette question, vous étudierez les résultats d'une enquête réalisée auprès d'étudiant(e)s d'une formation E, à partir du fichier « DataDS-26.csv » qui contient :

- **Facebook** : le nombre d'ami(e)s sur Facebook
- **Facebooktemps** : la durée quotidienne passée sur Facebook (en heures)
- **Douche** : la durée des douches (en minutes)
- **Habillement** : le temps nécessaire pour choisir sa tenue le matin (en minutes)
- **Internet** : le temps passé chaque jour sur internet (en heures)
- **Ordi** : le temps quotidien d'utilisation de l'ordinateur (en heures)

Répondez aux questions ci-dessous. Pour les questions 3 à 11, fournissez des détails et proposez une interprétation des résultats.

1. Importez l'ensemble de données dans R ou Python et créez un dataframe intitulé 'dataDS'.
2. Créez les variables suivantes et ajoutez-les au dataframe 'dataDS' :
  - (a) **PeuFacebook** : une variable (indicatrice catégorielle) valant 1 si 'Facebooktemps' est strictement inférieur à 1, et 0 dans le cas contraire;
  - (b) **TropFacebook** : une variable (indicatrice catégorielle) valant 1 si 'Facebooktemps' est strictement supérieur à 4, et 0 sinon;
  - (c) **TropInternet** : une variable (indicatrice catégorielle) valant 1 si 'Internet' est strictement supérieur à 7, et 0 sinon;
3. Réalisez une analyse statistique exploratoire du jeu de données et produisez quelques tableaux récapitulatifs. Cette analyse doit permettre de dégager les facteurs associés au temps consacré à Internet.
4. Menez une analyse factorielle sur les variables de 'dataDS'. Expliquez le choix de la méthode retenue et commentez les résultats obtenus.
5. Effectuez une régression logistique en prenant 'TropInternet' comme variable dépendante  $Y$  et comme variables explicatives (prédicteurs) : 'Facebook', 'Douche', 'TropFacebook', 'Habillement' et 'Ordi'.

6. Évaluez si le modèle de la question 5) est pertinent pour prédire le temps passé sur Internet.

**Indication** : Si la p-value du test (de nullité simultanée de tous les coefficients sauf la constante) est supérieure au seuil critique (souvent fixé à 5%), alors le modèle logistique n'apporte pas d'information utile.

7. Dans la régression de la question 5), le nombre d'amis sur Facebook contribue-t-il à accroître la probabilité de passer beaucoup de temps sur Internet ?

**Indication** : Une variable prédictive a un effet sur la variable réponse  $Y$  si l'hypothèse de nullité de son coefficient est rejetée.

8. Effectuez une sélection de variables pour le modèle logistique de la question 5) et retenez le meilleur modèle en vous basant sur des métriques de classification (par exemple, le taux d'erreur de classification sur un ou plusieurs échantillons de test, l'AUC).

9. En vous appuyant sur la sortie de la régression en 8), considérez deux étudiants de  $E$ ,  $A$  et  $B$ , qui donnent exactement les mêmes valeurs (10 ; 120 ; 2 ; 7) pour les variables 'Douche', 'Facebook', 'Facebooktemps' et 'Habillement', dans cet ordre. L'étudiant  $A$  passe 2,1 heures par jour sur son ordinateur, tandis que l'étudiant  $B$  y consacre 0,8 heure par jour. Calculez les probabilités prédites pour  $A$  et  $B$  (respectivement notées  $\hat{y}_A$  et  $\hat{y}_B$ ) de passer au plus 7 heures par jour sur internet.

10. En utilisant les mêmes échantillons que pour la question 8), entraînez plusieurs modèles (au moins 4 parmi ceux vus en cours) pour prédire  $Y$  et sélectionnez le meilleur à l'aide de métriques de classification (par exemple, le taux d'erreur de classification sur un ou plusieurs échantillons de test, l'AUC).

11. En vous appuyant sur le meilleur modèle parmi ceux retenus aux questions 8) et 10), indiquez la probabilité prédite qu'un étudiant de  $E$  regarde son téléphone au plus 7h par jour. Cet étudiant passe 15 minutes par jour sous la douche, a 50 ami(e)s sur Facebook, met 30 minutes à s'habiller le matin et consacre 3h par jour à son ordinateur et 1h à Facebook.