

1 Arbres de décision (CART)

On observe un échantillon

$$\{(x_i, y_i)\}_{i=1}^n, \quad x_i = (x_i^1, \dots, x_i^p)^T \in \mathbb{R}^p$$

Un arbre de décision est une structure hiérarchique binaire composée :

- d'une racine,
- de nœuds internes (règles de décision),
- de feuilles (prédictions).

Chaque nœud correspond à une règle de la forme :

$$x^j < c$$

avec $j \in \{1, \dots, p\}$ et $c \in \mathbb{R}$.

2 Régression par arbre

Dans le cas de la régression, la prédiction dans une feuille est la moyenne :

$$\hat{y} = \frac{1}{N_R} \sum_{x_i \in R} y_i$$

où R est une région définie par les coupures successives.

2.1 Critère de coupure

Pour une coupure (j, c) :

$$R_1(j, c) = \{x : x^j < c\}, \quad R_2(j, c) = \{x : x^j \geq c\}$$

On minimise la somme des carrés :

$$E(j, c) = \sum_{x_i \in R_1} (y_i - \bar{y}_{R_1})^2 + \sum_{x_i \in R_2} (y_i - \bar{y}_{R_2})^2$$

On choisit (j^*, c^*) tel que :

$$(j^*, c^*) = \arg \min_{j, c} E(j, c)$$

3 Classification par arbre

Dans le cas de la classification, on utilise par exemple l'indice de Gini.

Pour une région R :

$$G(R) = 1 - \sum_{k=1}^K p_k^2$$

où p_k est la proportion de la classe k dans R .

Le critère de coupure devient :

$$G(j, c) = \frac{n_1}{n} G(R_1) + \frac{n_2}{n} G(R_2)$$

On choisit (j, c) minimisant $G(j, c)$.

4 Élagage (Pruning)

Un arbre trop profond sur-apprend.

On introduit une pénalisation de complexité :

$$C_\alpha(T) = \sum_{m=1}^{|T|} N_m Q_m + \alpha |T|$$

où :

- $|T|$ = nombre de feuilles,
- Q_m = erreur dans la feuille m ,
- α = paramètre de pénalisation.


On sélectionne l'arbre optimal par validation croisée.

Exemple simple

Considérons un exemple où nous cherchons à prédire si un individu achète un produit ($Y = 0$ ou $Y = 1$) en fonction de son âge (X_1) et de son revenu (X_2). Les données sont les suivantes :

X_1 (Âge)	X_2 (Revenu)	Y (Achat)
25	50K	0
45	80K	1
35	60K	1
20	30K	0

Pour construire l'arbre, nous devons déterminer les divisions qui minimisent une mesure de pureté des nœuds comme l'entropie ou l'indice de Gini. Supposons que la meilleure division se fasse sur $X_1 = 40$ (l'âge) créant ainsi deux sous-ensembles : ceux dont l'âge est inférieur ou égal à 40 et ceux ayant un âge supérieur. L'arbre de décision obtenu pourrait ressembler à ceci :



5 Random Forest

Une forêt aléatoire est un ensemble de M arbres construits ainsi :

- Tirage bootstrap de m observations
- À chaque nœud : sélection aléatoire de q variables parmi p
- Choix de la meilleure coupure parmi ces q variables

Valeurs usuelles :

$$M = 300, \quad m = \frac{2}{3}n, \quad q = \sqrt{p}$$

Prédiction en régression :

$$\hat{y}(x) = \frac{1}{M} \sum_{m=1}^M \hat{y}_m(x)$$

En classification : vote majoritaire.

Algorithm 1 Random Forest

```
for  $m = 1$  to  $M$  do
  Tirer bootstrap
  for chaque nœud do
    Sélectionner  $q$  variables aléatoires
    Choisir meilleure coupure parmi ces  $q$ 
  end for
end for
Agréger les prédictions
```

6 Bagging

Le Bagging (Bootstrap Aggregating) consiste à :

- construire plusieurs arbres sur des échantillons bootstrap,
- agréger leurs prédictions.

Erreur OOB (Out-Of-Bag) : estimation interne de l'erreur en utilisant les observations non tirées.

Algorithm 2 Bagging

```
for  $m = 1$  to  $M$  do
  Tirer un échantillon bootstrap
  Construire un arbre  $\hat{f}_m$ 
end for
return  $\hat{f}(x) = \frac{1}{M} \sum_{m=1}^M \hat{f}_m(x)$ 
```

7 Boosting

Le Boosting construit les arbres séquentiellement :

- chaque arbre corrige les erreurs du précédent,

- pondération adaptative des observations.

Méthodes populaires :

- AdaBoost
- Gradient Boosting