

1 Perceptron

Le perceptron est un algorithme d'apprentissage supervisé destiné à la classification binaire. On considère un ensemble d'apprentissage $S = \{(x_i, y_i)\}_{i=1}^n$ avec $x_i \in \mathbb{R}^d$ et $y_i \in \{-1, 1\}$.

Modèle

Le perceptron cherche à apprendre une fonction de seuil donnée par

$$\hat{y} = \begin{cases} 1 & \text{si } \sum_{j=1}^d \beta_j x_j > -\beta_0 \\ -1 & \text{sinon} \end{cases}$$

En introduisant le vecteur augmenté $\tilde{x} = (1, x_1, \dots, x_d)$ et $\beta = (\beta_0, \beta_1, \dots, \beta_d)$, la règle de décision s'écrit

$$\hat{y} = \text{sign}(\tilde{x}^T \beta).$$

Principe d'apprentissage

L'idée est de modifier les poids β uniquement lorsque la prédiction est erronée.

- Si la prédiction est correcte, les poids restent inchangés.
- Si la prédiction est incorrecte, les poids sont ajustés de manière à déplacer l'hyperplan de séparation dans la direction appropriée.

Algorithme

1. Initialiser $\beta^{(0)} = 0$.
2. Pour chaque exemple $(x^{(t)}, y^{(t)})$:
 - calculer $\hat{y}^{(t)} = \text{sign}(\tilde{x}^{(t)T} \beta^{(t)})$
 - si $\hat{y}^{(t)} \neq y^{(t)}$, alors

$$\beta^{(t+1)} = \beta^{(t)} + y^{(t)} \tilde{x}^{(t)}$$

- sinon, poser $\beta^{(t+1)} = \beta^{(t)}$.
3. Reprendre le processus jusqu'à convergence ou jusqu'à atteindre un nombre maximal d'itérations.

Garantie théorique

Lorsque les données sont **linéairement séparables** et que les vecteurs d'entrée sont bornés, l'algorithme du perceptron converge en un nombre fini d'itérations vers un hyperplan qui sépare parfaitement les données.

Plus précisément, si $\|x_i\| \leq r$ et s'il existe un vecteur v tel que $y_i(v^T x_i) \geq \gamma$ pour une marge $\gamma > 0$, alors le nombre de mises à jour est majoré par

$$M \leq \frac{r^2}{\gamma^2}.$$

2 Support Vector Machines (SVM)

Les SVM sont des méthodes d'apprentissage supervisé utilisées pour la classification et la régression. Elles visent à trouver, dans un espace de grande dimension, l'hyperplan qui sépare au mieux deux classes en maximisant la distance entre l'hyperplan et les points les plus proches de chaque classe.

Modèle linéaire

Considérons un ensemble d'apprentissage

$$S = \{(x_i, y_i)\}_{i=1}^n$$

où $x_i \in \mathbb{R}^d$ désigne un vecteur de caractéristiques de dimension d , et $y_i \in \{-1, 1\}$ la variable cible binaire associée.

Un hyperplan séparateur dans l'espace des caractéristiques est défini par

$$f(x) = w^T x + b,$$

où $w \in \mathbb{R}^d$ est le vecteur de poids (ou paramètres) et $b \in \mathbb{R}$ est le terme de biais.

La règle de décision associée au classifieur linéaire s'écrit alors

$$\hat{y} = \text{sign}(w^T x + b),$$

où $\hat{y}$ représente la classe prédite pour l'exemple x .

Principe de la marge maximale

Parmi l'ensemble des hyperplans séparateurs qui réalisent une séparation correcte des données d'apprentissage, les machines à vecteurs de support (Support Vector Machines, SVM) sélectionnent celui qui **maximise la marge w** , définie comme la distance minimale entre l'hyperplan de décision et les exemples d'apprentissage qui lui sont les plus proches. Ces exemples particuliers sont appelés **vecteurs de support**.

Ce principe conduit au problème d'optimisation suivant :

$$\min_{w, b} \frac{1}{2} \|w\|^2$$

sous les contraintes de séparation linéaire

$$y_i(w^T x_i + b) \geq w, \quad i = 1, \dots, n.$$

Maximiser la marge euclidienne revient à minimiser la norme euclidienne de w tout en respectant les contraintes de classification correcte des exemples d'apprentissage.

Données non séparables

En pratique, les ensembles de données ne sont que rarement linéairement séparables. On introduit alors des variables d'assouplissement (ou *slack*) $\xi_i \geq 0$ qui autorisent une certaine proportion d'erreurs de classification ou de violations de la marge.

Le problème d'optimisation devient

$$\min_{w,b,\xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i$$

sous les contraintes

$$y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad i = 1, \dots, n.$$

Le paramètre de régularisation $C > 0$ contrôle le compromis entre la maximisation de la marge (complexité du classifieur) et la pénalisation des erreurs de classification ou des marges violées.

Formulation duale

Ce problème peut être réécrit sous forme duale en introduisant des multiplicateurs de Lagrange α_i associés aux contraintes de marge. La solution du problème d'optimisation conduit alors à une fonction de décision de la forme

$$f(x) = \sum_{i=1}^n \alpha_i y_i x_i^T x + b.$$

Seuls certains multiplicateurs de Lagrange α_i sont strictement positifs. Les observations correspondantes sont appelées **vecteurs de support** et sont précisément celles qui déterminent l'hyperplan séparateur optimal.

SVM et Noyau: Kernel Trick

Pour traiter des données non linéairement séparables dans l'espace d'entrée, les SVM recourent à des **fonctions noyau**. Ces dernières définissent implicitement un plongement des données dans un espace de caractéristiques de dimension potentiellement très élevée, au sein duquel une séparation linéaire peut devenir possible.

La fonction de décision s'écrit alors

$$f(x) = \sum_{i=1}^n \alpha_i y_i K(x_i, x) + b$$

où $K(x_i, x)$ désigne une fonction noyau symétrique, généralement définie positive, qui joue le rôle de produit scalaire dans l'espace de caractéristiques induit.

Exemples usuels de noyaux :

- **noyau linéaire** : $K(x, z) = x^T z$
- **noyau polynomial** : $K(x, z) = (x^T z + c)^p$, avec $c \in \mathbb{R}$ et $p \in \mathbb{N}$
- **noyau gaussien (RBF)** :

$$K(x, z) = \exp\left(-\frac{\|x - z\|^2}{2\sigma^2}\right), \quad \sigma > 0$$

Avantages des SVM

- Excellentes performances dans des espaces de grande dimension, notamment grâce à leur capacité à gérer efficacement un nombre élevé de variables explicatives.
- Solution parcimonieuse reposant sur un sous-ensemble restreint d'exemples d'apprentissage, appelés vecteurs de support, ce qui favorise la généralisation et réduit la complexité du modèle.
- Aptitude à modéliser des frontières de décision non linéaires au moyen de fonctions noyau, permettant la projection implicite des données dans des espaces de caractéristiques de dimension potentiellement très élevée.