

Master Miashs
 Datamining
 Année 2025-2026

T.P. — Régression non-paramétrique

Estimateurs à noyau

1 Simulation de données

On suppose que l'on dispose de l'observation de n variables aléatoires réelles $Y_i, i = 1, \dots, n$ indépendantes, et l'on se place dans le cadre du modèle de régression standard :

$$Y_i = f(x_i) + \epsilon_i, \quad i = 1, \dots, n, \quad (1)$$

$$\epsilon_1, \dots, \epsilon_n \text{ i.i.d. avec } \mathbb{E}(\epsilon_i) = 0, \quad \text{Var}(\epsilon_i) = \sigma^2,$$

où les prédicteurs x_i sont **déterministes** et à valeurs dans $\mathbb{R}$ et f est une fonction inconnue que l'on cherche à estimer. Dans ce TP, on va utiliser le code suivant pour générer 4 fonctions de régression différentes :

```
# Ensemble de 4 fonctions tests
T = 1000
t = (1:T)/T

truef1 = 0.5 + (0.2*cos(4*pi*t)) + (0.1*cos(24*pi*t))
truef2 = 0.2 + 0.6*(t > 1/3 & t <= 0.75)
truef3 = 4*sin(4*pi*t) - sign(t - .3) - sign(.72 - t) + 5
truef4 = sqrt(t*(1-t))*sin((2*pi*1.05)/(t+.05)) + 0.5

# Visualisation des fonctions de regression
x11()
plot(t,truef1,type = "l", col="red", lwd=2)

# Choix des points du design : n valeurs regulierement espacees sur [0,1]
n <- 100
x <- (1:n)/n

# Choix du rapport signal sur bruit
rsnr = 5

# Data 1
f1 = 0.5 + (0.2*cos(4*pi*x)) + (0.1*cos(24*pi*x))
sigma1 <- sd(f1)/rsnr # Niveau de bruit
Y1 <- f1 + rnorm(n,mean=0,sd=sigma1)

# Visualisation des donnees
x11()
```

```
plot(x,Y1,type="p",pch=19)

# Visualisation des donnees avec la fonction de regression
x11()
plot(x,Y1,type="p",pch=19)
lines(t,truef1, type = "l", col="red", lty="dotdash", lwd=2)
```

Q. 1 Utiliser le code ci-dessus pour visualiser les données pour chacune des 4 fonctions de régression $f_1, \dots, f_4$.

En régression nonparamétrique, on ne suppose pas un modèle particulier pour f . Sous R, un estimateur de Nadaraya-Watson ou un estimateur par polynôme locaux peut s'implémenter à partir de la fonction `locpoly` de la librairie `KernSmooth`. On rappelle que l'estimateur de Nadaraya-Watson correspond à un estimateur par polynôme locaux de degré zéro.

Q. 2 Ajuster un estimateur à noyau pour chacun des 4 jeux de données $Y_1, \dots, Y_4$ qui correspondent aux fonctions $f_1, \dots, f_4$. Pour cela vous pouvez utiliser la fonction `help` de R pour connaître la syntaxe de `locpoly`.

Q. 3 Pour chaque fonction de régression, faites varier le paramètre de fenêtre h pour l'estimateur à noyau. Pour différentes valeurs de h , représenter également graphiquement l'erreur quadratique ponctuelle $x \mapsto (\hat{f}_h(x) - f(x))^2$. Que constatez-vous sur le biais et la variance des estimateurs quand h varie ?

Q. 4 Que pouvez-vous dire sur la qualité du choix de h par validation croisée pour l'estimation des fonctions de régression $f_1, \dots, f_4$?

2 Exemple de données réelles

2.1 Accélération de la tête d'un motard après un choc

On considère un ensemble de données qui correspondent à l'accélération (mesurée par des capteurs) de la tête d'un motard après un choc (ces données ont été analysées par Silverman(1985)). On voudrait connaître le lien qu'il existe entre l'accélération de la tête d'un motard et le temps écoulé après l'impact. Les données se trouvent dans le fichier `Motorcycledata.txt`. Le code ci-dessous permet d'accéder à ces données.

```
acceleration <- read.table("Motorcycledata.txt",header=TRUE)# pour lire les données

Y<-acceleration$acc # pour sélectionner l'accélération

x<-acceleration$temp # pour sélectionner le temps après le choc

# Visualisation des données
x11()
plot(x,Y,type="p",pch=19)
```

Q. 5 *Utiliser un estimateur à noyau ou par polynômes locaux pour estimer la fonction de régression entre le temps et l'accélération. Quel est selon vous le meilleur choix pour le paramètre de fenêtre h et le nombre de degrés d ?*

2.2 Position de séismes

On considère un ensemble de données qui correspondent aux positions (latitude, longitude) d'événements sismiques (suffisamment élevés) dans une région autour de Fiji depuis 1964. On voudrait connaître le lien qu'il existe entre la latitude et la longitude de ces séismes. Le code ci-dessous permet d'accéder à ces données.

```
data(quakes) x = quakes$long Y = quakes$lat

# Visualisation des données x11() plot(x,Y,type="p",pch=19)
```

Q. 6 *Utiliser un estimateur à noyau puis par polynômes locaux pour estimer la fonction de régression entre la latitude et la longitude des séismes. Quel est selon vous le meilleur choix pour le paramètre de fenêtre h et le nombre de degrés d ?*