

INITIATION AU LOGICIEL SAS

MASTER MQME

Nicolas Cabaj
Directeur Statistiques
EOS FRANCE

SOMMAIRE

1. Présentation du logiciel
2. Importation des données
3. L'étape Data et les proc print et contents
4. Les opérateurs arithmétiques et les fonctions SAS
5. Les fonctions conditionnelles et logiques
6. La proc sort
7. Les fusions de tables
8. La proc Format
9. La proc freq
10. La proc means
11. La proc univariate
12. Les Dates

Présentation du logiciel (1/4)

Présentation générale

SAS (Statistical Analysis System) est un logiciel créé par la société SAS® Institute dans les années 1970. C'est un logiciel possédant un langage de programmation puissant et permettant de réaliser des analyses statistiques.

Les fichiers de données

SAS travaille sur des fichiers de données qui lui sont propres : ce sont les bases de données SAS . Ces fichiers ont la forme suivante : nomdefichier.sas7bdat

Les noms de fichiers peuvent contenir au maximum 32 caractères et commencent par une lettre ou un underscore (_)

Les tables SAS sont des fichiers de données organisés comme suit :

- en ligne : les observations (individus, ménages, entreprises...)
- en colonne : les variables (sexe, âge, csp, chiffre d'affaires...)

On peut donc se représenter l'ensemble des données sous la forme d'un tableau où chaque individu occupe une ligne, et où ses caractéristiques occupent les différentes colonnes.

Nature des données

SAS ne travaille qu'avec deux types de données :

- Numeric : les données sont constituées de chiffres formant des nombres
- Character : les données sont constituées de tout caractère possible en informatique

Attention : si une variable qualitative est codée avec des chiffres (ex CSP), elle peut être déclarée comme numérique et SAS acceptera de calculer une moyenne sur cette variable (alors que cela n'a aucun sens) ! Il faut donc faire attention aux erreurs de manipulation et d'interprétation...

Présentation du logiciel (2/4)

Environnement de travail

SAS est composé de différentes fenêtres ayant des fonctions différentes. Il suffit de cliquer sur l'onglet correspondant pour rendre visibles ces fenêtres.

Editor (ou éditeur)

C'est la fenêtre de saisie des programmes que l'on veut soumettre. Une fois tapés, les programmes doivent être exécutés : il faut sélectionner le programme puis utiliser la touche F8 ou cliquer sur l'icône .

Log (ou journal)

Cette fenêtre affiche les instructions saisies dans l'editor et soumises à SAS. Y sont affichées toutes les erreurs de syntaxe ainsi que les informations relatives aux traitements effectués. Il est indispensable de consulter le log à chaque fois qu'un programme est soumis.

Output (ou sortie)

C'est la fenêtre d'affichage des résultats (tableaux...).

Explorer (ou explorateur)

Accessible via l'icône , l'explorer permet de visualiser les librairies de SAS.

Un double-clic sur une library l'ouvre et indique les bases de données qu'elle contient.

Un clic droit sur une base de données puis "open" (ou un double clic) permet de visualiser la base.

Un clic droit sur une base de données puis "view columns" permet notamment de visualiser :

- la liste des variables contenues dans la base
- le type des variables (text/number)
- la longueur à réserver pour stocker les données
- un label (=intitulé complet "en clair" de la variable)

Results (ou résultats)

Permet de visualiser rapidement les résultats obtenus au cours de la session.

Présentation du logiciel (3/4)

Étapes de traitement de données

Les programmes SAS comportent deux types d'étapes :

Les étapes DATA servent à créer ou modifier des tables SAS :

- Création de tables SAS
- Modification des tables SAS existantes (création de variables, fusion de tables...)
- Exportation des tables vers d'autres logiciels

Une étape DATA commence par le mot clé DATA et se termine par RUN ;

Les étapes PROC permettent d'analyser les données :

- Production de statistiques : FREQ, UNIVARIATE, MEANS, COOR...
- Gestion de bases de données : SORT, CONTENTS...
- Affichage et mise en forme des données : FORMAT, PRINT, TABULATE

Une étape PROC commence par le mot clé PROC et se termine par RUN ;

Les instructions et les procédures

Écrites dans l'editor, les instructions indiquent à SAS le travail à effectuer. Elles commencent par un nom de commande SAS et se terminent par un point virgule.

Une procédure est une suite d'instructions, elle se termine par le mot-clé RUN suivi d'un point-virgule.

L'exécution des programmes se fait par la touche F8 ou par le bouton 

Les commentaires

Il est souvent utile d'insérer des commentaires lors de la rédaction des procédures.

S'il n'y a qu'une ligne de commentaires, on ouvre la ligne de commentaires par une étoile et on la ferme par un point virgule. Exemple : ** une ligne de commentaire ;*

Si on écrit plusieurs lignes de commentaires, ils seront encadrés au début par /* et à la fin par */ Exemple : */*plusieurs lignes de commentaire */*

Présentation du logiciel (4/4)

Accès aux données : la notion de library

Pour accéder aux fichiers il faut indiquer à SAS où ils sont situés sur le disque dur de l'ordinateur. SAS utilise pour cela la notion de library. Il s'agit de définir un nom qui servira de résumé pour désigner le répertoire contenant les données et son chemin d'accès.

Il existe deux manières de définir une library :



- Utiliser l'explorer interne de SAS, accessible via l'icône

Il suffit ensuite de donner un nom à la library (rubrique "name") et d'indiquer le chemin d'accès au répertoire qui contient les données (rubrique "path" – puis cliquer sur "browse" et aller chercher le répertoire).

- Utiliser l'instruction **libname** (à taper dans l'editor de SAS) :

libname nom 'chemin du répertoire contenant les données' ;

Exemple : **libname** emploi 'c:\mesdocuments\enquetes' ;

Il faut définir les library à chaque nouvelle session SAS.

Remarques:

- un nom de library ne doit pas dépasser 8 caractères
- par défaut toutes les tables SAS sont créées dans la library WORK de SAS. Cette library est temporaire : lorsque l'on quitte SAS toutes les tables contenues dans la WORK sont effacées.

Application : créer une library « TP_SAS »

Importation de Données (1/5)

SAS ne travaille qu'avec des bases de données SAS. Habituellement on travaille avec des bases qui ont déjà le format SAS. Mais on peut avoir besoin d'importer des données qui ne sont pas des données SAS et les transformer en "SAS DATA SET". Les étapes DATA permettent de créer des bases de données SAS à partir de données existant sous un autre format : données contenues dans un tableur Excel, données listées avec ou sans séparateur...

Questions à se poser lors de la création d'une base SAS à partir de données externes :

- Quel nom donne-t-on à la base qui va être créée ?
- Le fichier sera-t-il temporaire ou permanent ?
 - Les fichiers temporaires seront créés dans la library "work" et seront effacés automatiquement à la fin de la session de travail SAS
 - Si on souhaite conserver les fichiers créés, il faut créer une library puis créer les fichiers dans cette library
- Où se trouvent les données ?
 - Dans un fichier externe
 - Dans le programme SAS
- Quelle est la nature des données et comment sont-elles organisées ?
 - Données de type Excel, dbase...
 - Données dans un fichier texte délimitées par un séparateur
 - Données dans un fichier texte non-délimitées par un séparateur mais ordonnées dans des colonnes distinctes

La réponse à ces questions engendrera des procédures d'importation de données différentes.

Importation de Données (2/5)

1. Importer des données d'Excel

Un assistant facilite l'importation des données d'Excel.

Il est accessible via le menu "File" puis "import DATA". Il faut que le fichier se présente ainsi : chaque observation (individu, ménage, entreprise...) représente une ligne, et les variables sont en colonne.

Il faut alors préciser dans les fenêtres de dialogue successives :

- le type des données sources : ici Excel, mais on peut également importer des données txt
- la localisation des données : il faut indiquer où sont situées les données Excel
- L'étape suivante consiste à indiquer la feuille du classeur Excel qu'on souhaite importer ☐
- Le bouton "options" permet de préciser si, dans le fichier d'origine, le nom des variables figure - ou non – sur la première ligne du fichier de données. Il faut alors cocher – ou non – l'option "Use DATA in the first row as SAS variable names"
- Il faut ensuite choisir l'emplacement dans SAS où sera créée la base de données : il faut indiquer la library (celle que vous avez déjà créée ou la library par défaut "work") et attribuer un nom à cette nouvelle base de données (dans la rubrique "member").
- Enfin, une dernière fenêtre permet d'enregistrer si on le souhaite la procédure d'importation (pour la réutiliser par exemple) : SAS créera alors un fichier en extension ".sas" qui contiendra cette procédure (un proc import). Si on souhaite que ce fichier soit créé, il faut lui donner un nom et définir un emplacement sur le disque dur pour qu'il soit enregistré. L'explorer de SAS permet de vérifier que la base a bien été créée sous le nom choisi et dans la library désignée.

L'explorer de SAS permet de vérifier que la base a bien été créée sous le nom choisi et dans la library désignée.

Importation de Données (3/5)

2. Importer des données en mode « liste »

On dispose de données qui sont rangées, "listées" (d'où l'appellation "mode liste") les unes à la suite des autres, les variables étant distinguées par un "séparateur", c'est-à-dire un espace, un point-virgule ... Les valeurs manquantes sont remplacées par un point.

Exemple de données :

```
1 abraham 59000 1 13 40 150
2 benjamine 59650 2 13 45 155
3 colin 59650 1 9 35 130
4 dorien 59650 1 10 30 135
```

Les différentes étapes à respecter pour créer une base de données sont :

- **Nommer le fichier (data)**
- **Décrire la nature et l'organisation des données (input)**
- **Définir la localisation des données**

1er cas : on copie les données dans l'editor : l'instruction cards permet d'introduire les données

```
DATA club1 ;
input ident prenom $ codpost sexe $ age poids taille ;
cards ;
1 abraham 59000 1 13 40 150
2 benjamine 59650 2 13 45 155
3 colin 59650 1 9 35 130
4 dorien 59650 1 10 30 135
;
run ;
```

Importation de Données (4/5)

2ème cas : les données sont stockées dans un fichier externe à SAS

Il faut alors utiliser l'instruction *infile*. Cette instruction suit toujours la ligne de programmation commençant par *DATA* et précède toujours la ligne de programmation commençant par *input*. Après le mot-clé *infile* il faut indiquer le nom du fichier de données avec son chemin d'accès.

```
DATA club2 ;  
infile 'c://mesdocuments/données/club.txt' ;  
input ident prenom $ codpost sexe $ age poids taille ;  
run ;
```

L'instruction *infile* ne concerne que des fichiers externes à SAS et JAMAIS des fichiers qui sont déjà des fichiers SAS.

Cas où le séparateur de données est un point-virgule

On utilise l'instruction *infile datalines4 dlm=' ; ' ;*

```
DATA club3 ;  
infile datalines4 dlm=' ; ' ;  
input ident prenom $ codpost sexe $ age poids taille ;  
datalines4 ;  
1;Abraham;59000;H;13;40;150  
2;Benjamine;59650;F;13;45;155  
3;Colin;59650;H;9;35;130  
4;Dorien;59650;H;10;30;135  
;;;   
run;  
  
DATA club4 ;  
infile 'c://mesdocuments/données/club.txt' DLM=' ; ' ;  
input ident prenom $ codpost sexe $ age poids taille ;  
run ;
```

Importation de Données (5/5)

3ème cas : importer des données en mode colonne

Dans le cas de données en mode "colonne", on dispose de données qui sont rangées les unes à la suite des autres, et l'emplacement des valeurs dans les colonnes de chaque ligne est identique.

Il va falloir indiquer à SAS dans quelles colonnes précises se trouvent les données.

Particularité : l'ordre dans lequel on choisit les variables n'a pas d'importance.

Exemple de données :

1	Abraham	H	13	40	150
2	Benjamine	F	13	45	155
3	Dorien	H	10	30	135
4	Elanie	F	11	30	135

Comme en mode liste, il faut nommer les variables qu'on veut importer (instruction input), et préciser le type de chaque variable : lorsqu'une variable est de type caractère, il faudra faire suivre le nom de la variable du signe \$. Attention ici les données sont situées dans des colonnes : il faut indiquer à SAS précisément dans quelles colonnes se trouvent les variables qu'on veut importer. Pour identifier les numéros de colonne, le plus simple est d'inscrire une ligne de nombres. Cela va servir à numéroter les colonnes et donc à pouvoir identifier plus facilement l'emplacement des variables.

Le début de la programmation sera donc la suivante :

```
DATA club5 ;  
input num 1 prenom $ 7-18 sexe $ 19 age 25-26 poids 31-32 taille 38-40 ;  
run;
```

Si les données sont stockées dans un fichier externe:

```
DATA club7 ;  
infile 'c://mesdocuments/données/club.txt' ;  
input num 1 prenom $ 7-18 sexe $ 19 age 25-26 poids 31-32 taille 38-40 ;
```

L'étape DATA et les proc print et contents(1/2)

L'étape Data est la base de la programmation en langage SAS.

Cette étape permet de créer des tables et de les modifier (ajout de variables, suppression de lignes, renommer des variables).

Il est possible de créer (ou modifier) des tables SAS à partir de tables SAS existantes (instruction set).

Syntaxe:

```
Data B; set A;  
run;
```

Ici, on crée la table B qui est identique à la table A.

Il est possible de rajouter des lignes de programmation au sein d'un étape Data pour modifier la table existante.

Exemple:

```
Data B; set A;  
var3=var1+var2;  
run;
```

Ici, on crée la table B à partir de la table A en ajoutant la variable Var3 qui est la somme de Var1 et Var2.

Il est également possible d'ajouter des opérateurs logiques au sein d'une étape data :

Si (*condition=vraie*) Alors (*Action1*) Sinon (*Action2*) (cf chapitre opérateurs logiques)

Il est aussi possible d'écraser une table en la modifiant:

```
Data A; set A;  
var3=var1+var2;  
run;
```

L'étape DATA et les proc print et contents(2/2)

Quelques mots clés indispensables dans les étapes Data:

- **Keep** var1 var2 var3 : permet de ne prendre que les variables var1 var2 var3 dans la nouvelle table.
- **Drop** var4 : permet de supprimer la variable Var4 dans la nouvelle table.
- **Rename** ancien_Var = new_var : permet de renommer la variable anicen_var en new_var.
- **Where** variable = condition : permet de sélectionner les lignes remplissant la condition

Exemple :

```
Data B; set A;  
Var3 = Var1 + Var2;  
rename var2 = var4;  
where var1 = 10;  
keep var3 var4;  
run;
```

La proc print :

Elle permet d'afficher dans la fenêtre results la table SAS souhaitée.

Attention : par défaut la proc print affiche toutes les lignes de la table (gênant pour les grandes tables). Il faut utiliser l'option `obs=nb observations` pour afficher quelques observations.

Exemple:

```
proc print data= A (obs=5);  
Run;
```

La proc contents :

Elle permet d'afficher dans la fenêtre results les caractéristiques de la table (nom des variables, nombre de lignes)

```
proc contents data= A;  
Run;
```

Les opérateurs arithmétiques et les fonctions SAS (1/2)

OPERATEURS ARITHMETIQUES

<i>SYMBOLE</i>	<i>SIGNIFICATION</i>	<i>EXEMPLES</i>
**	Exponentiation	$Y = X^{**2};$
*	Multiplication	$Y = A * B;$
/	Division	$Y = A / B;$
+	Addition	$Y = A + B;$
-	Soustraction	$Y = A - B;$

OPERATEURS DE COMPARAISON

= ou **EQ** Egal à

NE Différent de

> ou **GT** Supérieur à

< ou **LT** Inférieur à

>= ou **GE** Supérieur à ou égal à

<= ou **LE** Inférieur à ou égal à

OPERATEURS LOGIQUES

AND Et

OR Ou

NOT Non

OPERATEURS SUR VARIABLES CARACTERES

|| Concaténation

Les opérateurs arithmétiques et les fonctions SAS (2/2)

Formule Générale:

Variables = *Nom fonction* (Liste d'arguments);

SUM Somme (les données non manquantes)

MEAN Moyenne

MAX Maximum

MIN Minimum

RANGE Etendue (MAX-MIN)

STD Ecart-type

VAR Variance

EXEMPLES

X = SUM (2,6); Résultat: X=8;

X = MEAN (2,6); X=4;

X = MIN (2,6); X=2;

X = RANGE (1,6); X=5;

Les arguments peuvent être des noms de variables.

Exemple:

X=SUM(VAR1,VAR2,VAR3);