

Data Mining

Partie I : Apprentissage non supervisé

Master 1 MIASHS

Informations générales

Cours Moodle : M1 MIASHS : Data Mining (S. Dabo)

Pour s'inscrire sur Moodle : `bu62ci`

Table des matières

0.1	Vue d'ensemble des thèmes	3
0.2	Pourquoi avons-nous besoin des statistiques ?	3
0.3	Production des données pour répondre aux questions	3
0.4	Selon l'objectif et le type de données d'intérêt	3
0.5	Selon la manière dont les analyses utilisent les données	4
0.6	Selon le type d'information fourni par les méthodes statistiques	4
0.7	Clustering	4
0.7.1	Objectif	4
0.7.2	Classification de données quantitatives	4
0.7.3	Distances : mesures de similarité pour données continues	4
0.8	Classification hiérarchique	5
0.8.1	Principe de l'algorithme Hclust	5
0.8.2	Choix de la distance entre deux classes C_i et C_j	5
0.8.3	Critère de Ward	5
0.9	Méthode des k-moyennes (K-means)	6
0.9.1	Algorithme	6
0.9.2	Remarques	6
0.10	Choix du nombre de classes	7
0.10.1	Méthode du coude	7
0.10.2	Silhouette	7
0.10.3	Statistique du Gap	7
0.11	Classification de données binaires	7
0.12	Similarité entre objets nominaux	8

Table des figures

0.1 Vue d'ensemble des thèmes

Partie I : Apprentissage non supervisé

- Introduction
- Clustering
- Applications avec Python

Partie II : Apprentissage supervisé

- Analyse discriminante linéaire et quadratique
- Classification : régression logistique
- Classification : arbres de régression, SVM, bagging, boosting, etc.
- Applications avec Python

0.2 Pourquoi avons-nous besoin des statistiques ?

Concepts en statistique. Fourni par : Open Learning Initiative. Disponible à l'adresse : <http://oli.cmu.edu>

0.3 Production des données pour répondre aux questions

- **Population** : il n'est pas possible de prendre des mesures sur l'ensemble des individus (de taille M) du centre médical.
- **Échantillon** : on effectue des mesures sur un sous-ensemble (de taille $N < M$) d'individus issus de la population.
- **Données d'apprentissage et données de test** : pour la modélisation, l'échantillon est divisé (souvent de manière aléatoire) en sous-ensembles disjoints afin de construire et d'évaluer les performances du modèle.
- La randomisation est couramment utilisée dans les études biologiques. Certaines exceptions dépendent de la population, des questions ou maladies médicales étudiées et de la procédure de modélisation.

0.4 Selon l'objectif et le type de données d'intérêt

- Tests statistiques
- Analyse explicative, régression
- Classification

0.5 Selon la manière dont les analyses utilisent les données

- **Non supervisée** : sélection des variables d'entrée X les plus informatives pour des approches supervisées ou division des observations en groupes relativement distincts.
- **Supervisée** : recherche (principalement par inférence) d'une fonction de correspondance f reliant un ensemble de prédicteurs X aux sorties Y .

0.6 Selon le type d'information fourni par les méthodes statistiques

- Statistique descriptive
- Inférence statistique

0.7 Clustering

0.7.1 Objectif

Le clustering permet de regrouper les individus en un nombre fini de classes selon leurs similarités. On distingue généralement deux grandes familles de méthodes :

- les méthodes basées sur l'optimisation de critères tels que les rapports de variance : méthode des centres mobiles (moyennes) ou des plus proches voisins ;
- les méthodes itératives basées sur le regroupement d'individus voisins reposant uniquement sur des notions de distance (similarité) entre individus : la classification hiérarchique ascendante.

0.7.2 Classification de données quantitatives

On observe p variables quantitatives $\xi_1, \dots, \xi_p$ sur n individus $X_1, \dots, X_n$. Les données sont donc présentées sous la forme d'un tableau individus-variables comportant n lignes et p colonnes. X_{ij} est la valeur de la variable ξ_j observée pour l'individu X_i .

0.7.3 Distances : mesures de similarité pour données continues

- **Euclidienne** :

$$d(X_i, X_j) = \sqrt{\sum_{k=1}^p (X_{ik} - X_{jk})^2}$$

- **Minkowski (norme L_m) :**

$$d_{ij} = \left(\sum_{k=1}^p |X_{ik} - X_{jk}|^m \right)^{1/m}$$

- **Correction par la variance :**

$$d_{ij} = \left(\sum_{k=1}^p \frac{|X_{ik} - X_{jk}|^m}{\sigma_k} \right)^{1/m}$$

- **Canberra :**

$$d(X_i, X_j) = \sum_{k=1}^p \frac{|X_{ik} - X_{jk}|}{X_{ik} + X_{jk}}$$

- **Czekanowski :**

$$d(X_i, X_j) = 1 - \frac{2 \sum_{k=1}^p \min(X_{ik}, X_{jk})}{\sum_{k=1}^p (X_{ik} + X_{jk})}$$

0.8 Classification hiérarchique

0.8.1 Principe de l'algorithme Hclust

La méthode itérative Hclust fonctionne comme suit :

- **Initialisation** : chaque individu constitue une classe. La partition initiale est donc composée de n classes (singletons).
- Calcul de la matrice des distances (avec une distance pertinente choisie) deux à deux.
- Répétition des deux étapes suivantes jusqu'à obtenir une seule classe :
 - regrouper les deux classes les plus proches selon une distance entre groupes ;
 - mettre à jour la matrice des distances. Chaque classe est représentée par son centre.

0.8.2 Choix de la distance entre deux classes C_i et C_j

- **Saut minimum** : $d(C_i, C_j) = \min_{k \in C_i, l \in C_j} d_{kl}$
- **Saut maximum** : $d(C_i, C_j) = \sup_{k \in C_i, l \in C_j} d_{kl}$
- **Saut moyen** :

$$d(C_i, C_j) = \frac{1}{\text{card}(C_i) + \text{card}(C_j)} \sum_{k \in C_i, l \in C_j} d_{kl}$$

0.8.3 Critère de Ward

Soient g_i et g_j les barycentres de deux classes de poids respectifs w_i et w_j .

- Distance entre barycentres : $d(C_i, C_j) = d(g_i, g_j)$
- Saut de Ward :

$$d(C_i, C_j) = \frac{w_i w_j}{w_i + w_j} d(g_i, g_j)$$

Ce critère est lié à la minimisation de l'augmentation de la variance inter-classe.

Le dendrogramme (arbre binaire) fournit la hauteur des branches, proportionnelle à l'indice de dissimilarité ou à la distance entre deux objets regroupés. La classification hiérarchique est souvent appliquée aux composantes d'une ACP, d'une AFC ou d'une ACM.

0.9 Méthode des k-moyennes (K-means)

La méthode des k-moyennes est un algorithme de réallocation dynamique fondé sur la maximisation d'un critère global (le rapport de l'inertie intra-classe à l'inertie inter-classe). Contrairement à la classification hiérarchique, le nombre de classes K est choisi à l'avance.

0.9.1 Algorithme

- Initialisation : choix du nombre de classes K et des centres (points choisis aléatoirement parmi les n individus).
- Répétition jusqu'à stabilisation du critère d'inertie inter-classe :
 - affecter chaque individu X_i à la classe k telle que $d(X_i, g_k) \leq d(X_i, g_j)$ pour tout $j \neq k$;
 - recalculer les centres de gravité g_k des K classes.

0.9.2 Remarques

- L'algorithme converge car le critère ne peut pas augmenter à chaque itération.
- La solution obtenue est un optimum local.
- La partition finale dépend des centres initiaux choisis.
- L'algorithme peut être relancé avec différents centres initiaux, et la meilleure partition est retenue, par exemple via la mesure de cohésion :

$$\sum_{k=1}^K \sum_{X_i \in C_k} d(X_i, g_k)$$

- La classification hiérarchique est souvent utilisée pour initialiser les centres des k-moyennes.
- Si la taille des données est importante, on peut appliquer la classification hiérarchique sur un échantillon aléatoire.
- En général, la distance utilisée est la distance euclidienne.

0.10 Choix du nombre de classes

0.10.1 Méthode du coude

La recherche d'une rupture dans la décroissance de la variance inter-classe (critère de Ward) fournit une indication heuristique du nombre de classes.

0.10.2 Silhouette

Pour un individu X_i appartenant à une classe A (de cardinal supérieur ou égal à 2), on définit :

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}, \quad -1 \leq s(i) \leq 1$$

avec

$$a(i) = \frac{1}{\text{card}(A) - 1} \sum_{X_j \in A, j \neq i} d(X_i, X_j)$$

$$b(i) = \min_{C \neq A} \frac{1}{\text{card}(C)} \sum_{X_k \in C} d(X_i, X_k)$$

La moyenne des $s(i)$ constitue un indicateur global de la qualité de la partition.

0.10.3 Statistique du Gap

Soit D_r la somme des distances prises deux à deux entre les observations appartenant à une même classe C_r , pour $r = 1, \dots, K$. On note W_K la moyenne pondérée (par la taille des classes) de ces sommes.

La plus grande déviation du graphe de $\log(W_K)$ par rapport à une distribution de référence obtenue par simulation (Monte Carlo) selon une loi uniforme est un indicateur global de la qualité de la partition.

0.11 Classification de données binaires

On considère des observations $X_i = (X_{i1}, \dots, X_{ip})$ avec $X_{ik} \in \{0, 1\}$. Les mesures de similarité sont définies par :

$$d_{ij} = \frac{a_1 + \lambda a_4}{a_1 + \lambda a_4 + \mu(a_2 + a_3)}$$

où

$$a_1 = \sum_{k=1}^p 1_{(X_{ik}=X_{jk}=1)}, \quad a_2 = \sum_{k=1}^p 1_{(X_{ik}=0, X_{jk}=1)},$$

$$a_3 = \sum_{k=1}^p 1_{(X_{ik}=1, X_{jk}=0)}, \quad a_4 = \sum_{k=1}^p 1_{(X_{ik}=X_{jk}=0)}$$

Les paramètres λ et μ permettent de pondérer l'importance des similarités ou des différences.

- $\lambda = 0, \mu = 1$: indice de Jaccard
- $\lambda = 1, \mu = 1$: indice de Russell et Rao

0.12 Similarité entre objets nominaux

Si les objets sont nominaux :

- on utilise une table de contingence (distance du χ^2) ;
- ou une table disjonctive complète (similarité binaire).

Pour classer des données catégorielles, on peut utiliser les similarités précédentes ou effectuer une classification sur les composantes factorielles d'une AFC ou d'une ACM.