

Régressions linéaire, K-nn, Noyau, Polynômes Locaux

Soit le modèle de régression

$$Y = f(X) + \epsilon, X = (X^1, X^2, \dots, X^p), X \in \mathcal{X}.$$

Nous avons vu que le choix de f qui minimise $E[(Y - g(x))^2 | X = x]$ pour tout X est $f(x) = E(Y | X = x)$

$\epsilon = Y - f(x)$ est l'erreur irréductible, et pour toute estimation $\hat{f}(x)$ de $f(x)$,

$$E[(Y - \hat{f}(X))^2 | X = x] = [f(x) - \hat{f}(x)]^2 + Var(\epsilon)$$

Le premier terme du côté droit est l'erreur réductible, c'est-à-dire qu'elle diminue lorsque l'estimation se rapproche de la vraie fonction f , tandis que le deuxième terme est irréductible, lié à la dispersion des données.

Soit un ensemble d'entraînement $S = \{x_1, \dots, x_n\}$, donné.

- $\mathcal{X}$ est appelé domaine des instances
- $x_i \in \mathcal{X}$ est appelé entrée ou instance d'apprentissage
- $\mathcal{Y}$ est l'ensemble des étiquettes possibles.
- $y_i \in \mathcal{Y}$ est appelé sortie, cible, ou label d'apprentissage

Régressions linéaire et par les k plus proches voisins (k-NN)

La régression linéaire est suppose une forme paramétrique linéaire de f . Les méthodes non paramétriques ne font pas de telles hypothèses, ce qui offre une manière plus flexible d'effectuer une régression :

$$f(X) = \beta^\top \mathbf{X}, \beta = (\beta_0, \dots, \beta_p), \mathbf{X} = (1, X^1, \dots, X^p)^\top$$

Dans de nombreux cas, il y a très peu de points à $X_i = x$, nous pouvons donc calculer $f(x)$ en utilisant les points dans le voisinage de x . On l'appelle la moyenne des voisins les plus proches ou la moyenne locale.

La régression des (k-NN) est une des méthodes non-paramétriques les plus usuelles. Le k-NN estime $f(x)$ en prenant la moyenne des K observations d'entraînement les plus proches.

$$\hat{f}(x) = \frac{1}{k} \sum_{x_i \in \mathcal{N}_x} y_i,$$

avec $x_1, \dots, x_n$ l'ensemble d'apprentissage, $\mathcal{N}_x$ est l'ensemble des k instances d'entraînement les plus proches de x d'après une distance pré-définie (euclidienne,...).

Régression par Noyau

L'estimateur à noyau de la régression est

$$\hat{f}(x) = \frac{\sum_{i=1}^n y_i K\left(\frac{x-x_i}{h}\right)}{\sum_{i=1}^n K\left(\frac{x-x_i}{h}\right)}.$$

Remarque : On utilise plus généralement des noyaux réguliers qui permettent d'obtenir des estimateurs réguliers. Le plus souvent, on utilise un noyau symétrique :

Exemples de noyaux :

- Le noyau triangulaire $K(x) = (1 - |x|)1_{\{|x| \leq 1\}}$.
- Le noyau rectangulaire $K(u) = (1/2)1_{\{|u| \leq 1\}}$.
- Le noyau gaussien $K(x) = \frac{1}{\sqrt{2\pi}}e^{-x^2/2}$.
- Le noyau parabolique (Epanechnikov) $K(u) = \frac{3}{4}(1 - u^2)1_{\{|u| \leq 1\}}$.
- ...

Régression par Polynômes Locaux

L'idée est d'estimer $r(\cdot)$ ($y_i = f(x_i) + \varepsilon_i$) en un point x à partir des (x_i, y_i) pour lesquelles x_i (déterministe) est "proche" de x . Plus généralement, on introduit une fonction de poids ($w_i(x)$) construite à partir d'un noyau : $w_i(x) = K((x_i - x)/h)$ qui va attribuer un poids plus important aux (x_i, Y_i) pour lesquelles x_i est "proche" de x , et on minimise (en a) la somme des carrés pondérée :

$$\sum_{i=1}^n w_i(x)(y_i - a)^2.$$

La solution est donnée par

$$a = \hat{f}_n(x) = \frac{\sum_{i=1}^n w_i(x)y_i}{\sum_{i=1}^n w_i(x)}, \quad (1)$$

ce qui correspond à l'estimateur à noyau de la fonction de régression !

On peut généraliser cet estimateur à noyau en remplaçant la constante a par un polynôme de degré p : on se donne un point x en lequel on souhaite estimer r . Pour u dans un voisinage de x , on considère le polynôme

$$P_x(u, a) = a_0 + a_1(u - x) + \dots + \frac{a_p}{p!}(u - x)^p.$$

On cherche à estimer r au voisinage de x par le polynôme $P_x(u, a)$ où le vecteur $a = (a_0, \dots, a_p)$ est obtenu par minimisation de la somme des carrés pondérée :

$$\sum_{i=1}^n w_i(x)(Y_i - a_0 - a_1(x_i - x) - \dots - \frac{a_p}{p!}(x_i - x)^p)^2.$$

La solution obtenue est le vecteur $\hat{a}(x) = (\hat{a}_0(x), \dots, \hat{a}_p(x))$, l'estimateur local de la fonction de régression s est

$$\hat{r}_n(u) = \hat{a}_0(x) + \hat{a}_1(x)(u - x) + \dots + \frac{\hat{a}_p(x)}{p!}(u - x)^p.$$

Au point x , où l'on souhaite réaliser l'estimation, on obtient :

$$\hat{r}_n(u) = \hat{a}_0(x).$$

Classification : Logistique, Knn, Noyau, AFD, LDA, QDA, Naive-Bayes

Prenons l'exemple d'une banque qui doit attribuer une note (score) à un demandeur de crédit, en mesurant le risque ou la probabilité de défaut du demandeur. Il ne s'agit pas seulement de classer les clients potentiels en deux catégories, les bons et les mauvais payeurs, mais de produire un indicateur quantitatif du risque individuel que présente chaque client. Très souvent, les méthodes employées sont fondées sur un questionnaire visant à mesurer la solvabilité du client et sa capacité financière à rembourser. On tente aussi de mesurer la stabilité psychologique et sociale de l'individu, perçue comme un signal pertinent de sa volonté de rembourser.

Le plus souvent, les questions concernent les éléments suivants :

- salaire, ressources diverses
- dépenses mensuelles régulières
- nombre de personnes à charge
- revenu net disponible
- activité professionnelle
- statut matrimonial
- durée de l'emploi actuel
- durée de l'adresse actuelle
- autres crédits en cours

Considérons l'exemple suivant où nous notons les caractéristiques individuelles du client :

- X_1 revenu par personne (variable quantitative)
- X_2 statut matrimonial (variable qualitative)
- X_3 nombre d'enfants (variable quantitative)
- X_4 statut dans le logement (variable qualitative)
- X_5 profession (variable qualitative)
- X_6 ancienneté dans le travail (variable quantitative)

Pour chaque individu i , on peut définir une variable binaire Y_i :

- $Y_i = 1$ si l'individu i est bon payeur
- $Y_i = 0$ si l'individu i est mauvais payeur

Y_i est une variable à priori non observable et on cherche à en prédire la valeur à l'aide des caractéristiques de l'individu $X_i = (x_{i1}, x_{i2}, \dots, x_{ip})$.

Régression logistique

Les modèles LOGIT et PROBIT reposent sur l'existence d'un *modèle latent*. Soit Y^* une variable latente (c'est-à-dire non observable) représentant la propension de l'individu à rembourser son crédit. On suppose que celle-ci dépend de manière linéaire des caractéristiques individuelles X et de facteurs non observables u :

$$Y^* = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p + u = X\beta + u$$

Si cette propension à rembourser est suffisamment grande, alors l'individu rembourse, sinon il ne rembourse pas.

Si $Y^* > s$, alors $Y = 1$

Si $Y^* \leq s$, alors $Y = 0$

Comme u est non observable, il est naturel de supposer qu'il suit une loi d'espérance nulle, de fonction de répartition F . Lorsque celle-ci est normale, on obtient le modèle PROBIT, lorsqu'elle est logistique, on obtient le modèle LOGIT. Notons F la fonction de répartition de la variable réduite u :

$$F(x) = P\left(\frac{u}{\sigma} < x\right)$$

où $V(u) = \sigma^2$. Rappelons également la propriété importante des fonctions de répartition : $F(-x) = 1 - F(x)$.

On a :

$$\begin{aligned} P(Y = 0 \mid X) &= P(Y^* \leq s \mid X) = P(X\beta + u \leq s) \\ &= P\left(\frac{u}{\sigma} \leq \frac{s - X\beta}{\sigma}\right) \\ &= F\left(\frac{s - X\beta}{\sigma}\right) = 1 - F\left(X\frac{\beta}{\sigma} - \frac{s}{\sigma}\right) \\ P(Y = 1 \mid X) &= P(Y^* > s \mid X) = P(X\beta + u > s) \\ &= P\left(\frac{u}{\sigma} > \frac{s - X\beta}{\sigma}\right) \\ &= 1 - P\left(\frac{u}{\sigma} \leq \frac{s - X\beta}{\sigma}\right) = 1 - F\left(\frac{s - X\beta}{\sigma}\right) \\ &= F\left(X\frac{\beta}{\sigma} - \frac{s}{\sigma}\right) \end{aligned}$$

Les paramètres s, β, σ ne sont pas identifiables, seules les quantités :

$$\theta_0 = \frac{\beta_0 - s}{\sigma} \quad \text{et} \quad \theta_i = \frac{\beta_i}{\sigma}$$

peuvent être estimées. On a donc :

$$\begin{aligned} P(Y = 0 \mid X) &= 1 - F(X\theta) \\ P(Y = 1 \mid X) &= F(X\theta) \end{aligned}$$

— Exemple 1 : le modèle LOGIT :

$$P(Y = 1 | X) = \frac{1}{1 + \exp(-X\theta)}$$

— Exemple 2 : le modèle PROBIT

$$P(Y = 1 | X) = \int_{-\infty}^{X\theta} \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} du$$

Dans les deux cas (LOGIT ou PROBIT), la log-vraisemblance est trop compliquée pour qu'on puisse trouver une solution explicite à sa maximisation. Il faut donc utiliser des logiciels spécialisés.

Sous des hypothèses assez générales, les estimateurs obtenus par maximum de vraisemblance sont convergents et asymptotiquement gaussiens. Certains logiciels fournissent pour les coefficients des statistiques T qu'on interprète de la manière usuelle avec des seuils issus des tables de la loi normale.

Voici un exemple d'estimation. La base de données comporte 950 observations et la seule variable explicative utilisée est l'âge du client.

Modèle 1 : Estimation Logit utilisant les 950 observations 1-950
Variable dépendante : Y

Variable	Coefficient	Erreur std.	Statistique- t
const	-1,5457	0,382057	-4,0459
AGE	0,04105	0,00845282	4,8560

Dans cet exemple LOGIT, on a :

$$\hat{P}[Y = 1 | AGE] = \frac{1}{1 + e^{1,5457 - 0,04105AGE}}$$

Le coefficient $\hat{\theta}_1 = 0,04105$ étant positif, la probabilité d'être un bon payeur est une fonction croissante de l'âge.

On peut utiliser cette fonction pour évaluer la probabilité d'être un bon payeur pour toute valeur de l'âge.

Concernant le modèle latent donnant la propension à rembourser en fonction de l'âge :

$$y^* = \beta_0 + \beta_1 AGE + u,$$

comme :

$$\theta_0 = \frac{\beta_0 - s}{\sigma} \quad \text{et} \quad \theta_1 = \frac{\beta_1}{\sigma}$$

On a :

$$-1,5457 = \frac{\hat{\beta}_0 - \hat{s}}{\hat{\sigma}} \quad \text{et} \quad 0,04105 = \frac{\hat{\beta}_1}{\hat{\sigma}}$$

On voit bien qu'il est impossible de retrouver la valeur des paramètres structurels $\beta_0, \beta_1, \sigma, s$ à partir des valeurs estimées par la procédure LOGIT. En revanche, comme σ est un écart-type, il est toujours positif et on déduit que $\hat{\beta}_1$ est du même signe que $\hat{\theta}_1$, c'est-à-dire positif. La variable AGE a donc un effet positif sur la propension à rembourser.

Modèle 2 : Estimation Probit utilisant les 950 observations 1-950

Variable dépendante : Y

Variable	Coefficient	Erreur std.	Statistique-t
const	-0,9541	0,234642	-4,0666
AGE	0,0253	0,00517215	4,9049

Cela signifie que :

$$\hat{P}[Y = 1 \mid AGE] = \int_{-\infty}^{-0,9541+0,0253AGE} \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} du$$

Cette fonction étant la fonction de répartition de la loi normale centrée réduite, on voit bien que la probabilité augmente avec l'âge puisque le coefficient $\hat{\theta}_1 = 0,25369$ est positif.

Remarque sur l'interprétation des coefficients : Notons que les estimateurs obtenus en maximisant la vraisemblance, $\hat{\theta}$, ne peuvent pas s'interpréter comme les coefficients du modèle latent puisqu'ils sont obtenus à un facteur σ près. Néanmoins, comme σ est positif, on a :

$$\beta_i = 0 \Leftrightarrow \theta_i = 0, \quad i \neq 0$$

$$\beta_i > 0 \Leftrightarrow \theta_i > 0, \quad i \neq 0$$

$$\beta_i < 0 \Leftrightarrow \theta_i < 0, \quad i \neq 0$$

Le signe et la significativité des coefficients restent donc interprétables.

Odds-ratios : Lorsqu'on utilise un modèle LOGIT, on voit souvent apparaître des quantités appelées "Odds-ratios". Supposons qu'on dispose d'une seule variable explicative qualitative :

$$X_i = \begin{cases} 1 & \text{si l'individu } i \text{ est propriétaire de son logement} \\ 0 & \text{sinon} \end{cases}$$

On peut calculer pour les deux types de clients la probabilité d'être un bon ou un mauvais payeur :

$$P(Y_i = 1 \mid X_i = 1) = \frac{1}{1+e^{-\theta_0-\theta_1}}$$

$$P(Y_i = 0 \mid X_i = 1) = \frac{e^{-\theta_0-\theta_1}}{1+e^{-\theta_0-\theta_1}}$$

$$P(Y_i = 1 \mid X_i = 0) = \frac{1}{1+e^{-\theta_0}}$$

$$P(Y_i = 0 \mid X_i = 0) = \frac{e^{-\theta_0}}{1+e^{-\theta_0}}$$

- On a donc, pour les propriétaires :

$$\frac{P(Y_i = 1 \mid X_i = 1)}{P(Y_i = 0 \mid X_i = 1)} = e^{\theta_0 + \theta_1}$$

et pour les non propriétaires :

$$\frac{P(Y_i = 1 \mid X_i = 0)}{P(Y_i = 0 \mid X_i = 0)} = e^{\theta_0}$$

Autrement dit, pour un propriétaire, on a $e^{\theta_0 + \theta_1}$ fois plus de chance d'être un bon payeur qu'un mauvais payeur. Et pour un non propriétaire, ce pourcentage de chances est e^{θ_0} . Le rapport entre ces deux quantités est le Odds-Ratio (rapport de chances) :

$$OR = \frac{\frac{P(Y_i=1|X_i=1)}{P(Y_i=0|X_i=1)}}{\frac{P(Y_i=1|X_i=0)}{P(Y_i=0|X_i=0)}} = e^{\theta_1}$$

Courbe de Roc

On définit la *sensibilité*. Celle-ci donne la proportion de clients bien détectés comme bons payeurs dans la population des clients qui sont réellement bons payeurs. Ce sont les "vrais positifs" :

$$Se(s) = P[\hat{Y}_i(X_i) = 1 \mid Y = 1] = P[S(X_i) > s \mid Y = 1]$$

$S(X_i)$ est le score par exemple βX_i .

On peut l'estimer par :

$$Se(s) = \frac{n_1(s)}{n_1(s) + n_3(s)}$$

On définit aussi la *spécificité*. Celle-ci donne la proportion de clients bien détectés comme mauvais payeurs dans la population des clients qui sont réellement mauvais payeurs. Ce sont les "vrais négatifs" :

$$Sp(s) = P[\hat{Y}_i(X_i) = 0 \mid Y = 0] = P[S(X_i) \leq s \mid Y = 0]$$

On l'estime par :

$$Sp(s) = \frac{n_4(s)}{n_2(s) + n_4(s)}$$

$1 - Sp(s)$ est la part de clients prédits comme bons payeurs alors qu'en réalité ce sont de mauvais payeurs. C'est donc le taux de faux positifs. On centre souvent l'analyse sur les clients prédits comme bons payeurs et on considère la courbe ROC, c'est-à-dire la courbe paramétrée :

$$(1 - Sp(s), Se(s)).$$

Cette courbe nous permet de choisir une valeur de s offrant un compromis entre un taux élevé de vrais positifs et un taux faible de faux positifs.

Si on affecte au hasard les individus dans les catégories " $\hat{Y}_i(X_i) = 1$ " et " $\hat{Y}_i(X_i) = 0$ ", on aura, pour toute valeur du seuil s :

$$1 - Sp(s) = Se(s) = P[\widehat{Y}_i(X_i) = 1 \mid Y = 0] = P[\widehat{Y}_i(X_i) = 1 \mid Y = 1]$$

et la courbe ROC est une droite dont la pente est $\frac{1}{2}$.

$1 - Sp(s)$ est la part de clients prédits comme bons payeurs alors qu'en réalité ce sont de mauvais payeurs. C'est une quantité qu'on souhaite la plus faible possible. Au contraire $Se(s)$ est une quantité qu'on souhaite la plus grande possible. Une courbe ROC correspondant à un score de bonne qualité doit donc avoir une pente à l'origine la plus grande possible.

D'autres courbes peuvent également être produites. Tout d'abord la *courbe de performance*. Il s'agit également d'une courbe paramétrée

$$\left(P(S > s); \frac{P(Y = 0 \mid S > s)}{P(Y = 0)} \right)$$

La quantité $P(S > s)$ donne la part de clients retenus pour un choix de seuil s . La quantité $P(Y = 0 \mid S > s)$ donne la part de mauvais payeurs dans la clientèle retenue avec un seuil s . Celle-ci est ramenée à la part totale de mauvais payeurs $P(Y = 0)$ dans l'ensemble de la population.

On s'attend à ce que $\frac{P(Y=0|S>s)}{P(Y=0)}$ reste faible tant que la part de clients sélectionnés reste petite, c'est-à-dire tant qu'on se limite à des clients ayant un score élevé.

Plus on choisit un seuil s élevé et plus le risque de sélectionner des mauvais payeurs dans la clientèle grandit. Un score performant est un score pour lequel ce risque ne grandit pas trop vite.

On utilise également la *courbe de sélection* :

$$(P(S > s); P(S > s \mid Y = 0))$$

Celle-ci nous dit comment la proportion de scores élevés parmi les mauvais payeurs évolue lorsque la part de clients sélectionnés augmente.

Classification k-NN (K plus proches voisins) ou Noyau/Polynômes Locaux

La classification k-NN est similaire à la régression

$$\hat{f}(x) = \frac{1}{k} \sum_{x_i \in \mathcal{N}_x} y_i,$$

$\hat{f}(x)$ est la proportion des $y_i = 1$ dont les x_i sont les plus proches de x et donc si $\hat{f}(x) > s$ (par exemple $s = 0.5$) $\hat{y} = 1$.

On fait de même pour la classification par noyau ou Polynômes Locaux.

Modèles additifs

Cette approche est utile et/ou plus précise (comparée à la régression logistique) lorsque la séparation entre les classes est grande, la distribution des prédicteurs est proche de la normale dans chaque classe, ou le nombre de classes de réponse est plus grand que 2.

Disons que nous avons K classes, alors par le théorème de Bayes,

$$P(Y = k|X = x) = \frac{P(X = x|Y = k) \cdot P(Y = k)}{P(X = x)}$$

ou dans une notation équivalente,

$$p_k(x) = \frac{P(X = x|Y = k) \cdot P(Y = k)}{\sum_{l=1}^K P(X = x|Y = l) \cdot P(Y = l)}$$

Si $f_k(x) = P(X = x|Y = k)$ est connu, le classificateur de Bayes peut être utilisé (taux d'erreur minimum). Il existe plusieurs méthodes pour estimer cette valeur. Les suivantes seront discutées : l'analyse discriminante linéaire, l'analyse discriminante quadratique et le naïf de Bayes.

L'analyse discriminante linéaire : LDA

Supposons que nous ayons un seul prédicteur. Nous supposons que $f_k(x)$ est normale, ce qui donne pour une dimension,

$$f_k(x) = \frac{1}{\sqrt{2\pi}\sigma_k} e^{-\frac{1}{2\sigma_k^2}(x-\mu_k)^2}.$$

Supposons que toutes les variances soient égales ($\sigma_i = \sigma, \forall i$) et en notant $\pi_k \equiv P(Y = k)$,

$$p_k(x) = \frac{\pi_k \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(x-\mu_k)^2}}{\sum_{l=1}^K \pi_l \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(x-\mu_l)^2}}.$$

En prenant le logarithme de l'équation ci-dessus, le classificateur de Bayes attribue l'observation à la classe pour laquelle l'équation ci-dessous est maximisée :

$$\delta_k(x) = x \frac{\mu_k}{\sigma^2} - \frac{\mu_k^2}{2\sigma^2} + \log(\pi_k).$$

(Pour la fonction discriminante linéaire, l'estimation $\hat{\delta}_k(x)$ est une fonction linéaire de x .)

Pour deux classes avec une probabilité égale, la frontière de décision de Bayes prend une équation simple $x = \frac{\mu_1 + \mu_2}{2}$.

Si $X = (X_1, X_2, \dots, X_P)$ est maintenant une distribution normale multivariée. Elle a une moyenne spécifique à la classe et une matrice de covariance commune.

Dans ce cas, la valeur maximale pour

$$\delta_k(x) = x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log \pi_k$$

détermine à quelle classe l'observation $X = x$ est assignée par le classificateur de Bayes, où Σ représente la matrice de covariance commune.

La frontière de décision est définie par le point où $\delta_k(x) = \delta_l(x)$, ainsi,

$$x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k = x^T \Sigma^{-1} \mu_l - \frac{1}{2} \mu_l^T \Sigma^{-1} \mu_l$$

pour des observations d'entraînement égales, c'est-à-dire pour des π_k égaux.

L'analyse discriminante quadratique : QDA

En QDA, nous relâchons l'hypothèse de covariance égale telle que $X \sim N(\mu_k, \Sigma_k)$. Ainsi, cette méthode étiquette l'observation à la classe pour laquelle l'équation ci-dessous est maximale :

$$\delta_k(x) = -\frac{1}{2}(x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k) - \frac{1}{2} \log |\Sigma_k| + \log \pi_k$$

Contrairement à LDA, l'équation pour QDA est quadratique en x .

Naïf Bayes

Au lieu de faire des hypothèses sur la distribution de X , nous faisons une seule hypothèse d'indépendance : que dans chaque classe, les prédicteurs sont tous indépendants, ce qui signifie que pour chaque classe k

$$f_k(x) = f_{k1}(x_1) \times \dots \times f_{kp}(x_p),$$

où f_{kj} est la fonction de densité du j -ème prédicteur pour les observations appartenant à la classe k , donc la probabilité a posteriori peut être calculée comme

$$P(Y = k | X = x) = \frac{\pi_k \times f_{k1}(x_1) \times \dots \times f_{kp}(x_p)}{\sum_{l=1}^K \pi_l \times f_{l1}(x_1) \times \dots \times f_{lp}(x_p)}$$

Pour estimer f_{kj} :

- si X_j est quantitative, $X_j | Y = k \sim N(\mu_{jk}, \sigma_{jk}^2)$. (Cela est équivalent au QDA avec une covariance diagonale.) ou utiliser une estimation non paramétrique pour f_{kj} en faisant un histogramme des observations, ou en utilisant un estimateur de densité de noyau.
- si X_j est qualitative, compter la proportion d'observations correspondant à chaque classe.

C'est une bonne méthode pour les cas où n n'est pas trop grand par rapport à p , de sorte que la distribution conjointe ne peut pas être bien estimée.

Analyse factorielle discriminante : AFD

Sur données quantitatives

On observe p variables quantitatives $\xi_1, \dots, \xi_p$ et une variable qualitative Y (regroupant les observations en classes et prenant ses valeurs dans $\{1, \dots, K\}$) sur n individus. Les données quantitatives se présentent donc sous forme d'un tableau X individus-variables à n lignes et p colonnes, et d'une matrice A d'indicatrices de la variable qualitative du genre

$$A = \begin{array}{c|cccccc} & 1 & 2 & \dots & j & \dots & K \\ \hline 1 & 1 & 0 & \dots & 0 & \dots & 0 \\ 2 & 0 & 1 & \dots & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \dots & \vdots & \dots & \vdots \\ i & 0 & 0 & \dots & 0 & \dots & 1 \\ \vdots & \vdots & \vdots & \dots & \vdots & \dots & \vdots \\ n & 1 & 0 & \dots & 0 & \dots & 0 \end{array}$$

L'objectif de l'AFD est chercher de nouvelles variables (discriminantes) qui séparent le mieux (en projection) les K groupes

K nuages de points

- Soit x_{ij} la valeur de la variable quantitative ξ_j observée sur l'observation (l'individu) x_i .
- Les x_i constituent un nuage de points E dans $\mathbb{R}^p$ de centre de gravité g qui peut être partagé en K sous-nuages $E_1, \dots, E_K$ de centres de gravité $g_1, \dots, g_K$
 - x_i est affecté d'un poids m_i
 - Soit n_k le nombre d'individus du nuage E_k ($Y = k$), chaque centre de gravité g_k est affecté d'un poids $p_k = \sum_{x_i \in E_k} m_i$
 - On a

$$g_k = \frac{1}{p_k} \sum_{x_i \in E_k} m_i x_i, \quad g = \sum_{j=1}^K p_j g_j$$

- Soit $S_k = \frac{1}{p_k} \sum_{x_i \in E_k} m_i (x_i - g_k)(x_i - g_k)^\top$, la matrice de variance du nuage E_k , $k = 1, \dots, K$.
- $\mathbf{D} = \sum_{k=1}^K p_k S_k$ est la matrice de variance intra-classe (la moyenne des S_j).
- La matrice des variances du nuage des K centres de gravité g_k est $\mathbf{B} = \sum_{k=1}^K p_k (g_k - g)(g_k - g)^\top$, c'est la matrice de variance inter-classe
- La matrice de variance totale est $\mathbf{V} = \mathbf{B} + \mathbf{D}$

Inerties Intra, Inertie inter

Soit M une métrique de $\mathbf{R}^n$

- Les inerties inter-classe et intra-classe (par rapport à M) sont respectivement $M\mathbf{B}M$ et $M\mathbf{D}M$
- Les inerties inter-classe et intra-classe des nuages projetés sur un axe u sont $u^\top M\mathbf{B}Mu$ et $u^\top M\mathbf{D}Mu = \sum_{k=1}^K p_k u^\top M S_k M u$ avec u un vecteur M -normé

AFD=ACP particulière

- On cherche à maximiser $u^\top M\mathbf{B}Mu$ ou minimiser $u^\top M\mathbf{D}Mu$
- Le critère est la maximisation du rapport d'inertie inter sur l'inertie totale

$$\arg \max_u \frac{u^\top M\mathbf{B}Mu}{u^\top M\mathbf{V}Mu}$$

Le maximum est atteint si u est le vecteur propre normé associé la plus grande valeur propres λ_1 de $(M\mathbf{V}M)^{-1}M\mathbf{B}M = M^{-1}\mathbf{V}^{-1}\mathbf{B}M$,

- Le facteur correspondant $v = Mu$ est vecteur propre de $\mathbf{V}^{-1}\mathbf{B}$; $\mathbf{V}^{-1}\mathbf{B}v = \lambda_1 v$, il est indépendant de M
- Les autres valeurs propres et axes sont déterminés comme en ACP
- Les composantes ou variables discriminantes Xv sont également indépendantes de M

Choix de $M = \mathbf{V}^{-1}$

Par commodité on choisit $M = \mathbf{V}^{-1}$ ce qui donne

$$\mathbf{B}\mathbf{V}^{-1}u = \lambda_1 u, \quad \mathbf{V}^{-1}\mathbf{B}v = \lambda_1 v$$

- On a $0 \leq \lambda_1 \leq 1$, car λ_1 est la quantité (le rapport des inerties) à maximiser
- $\lambda_1 = 1$, équivaut à la nullité de l'inertie intra classe projetée. Les K nuages de points E_k sont dans un hyperplan orthogonal à u
- Si $\lambda_1 = 0$, les centres de gravités g_k sont confondus

Choix de $M = \mathbf{D}^{-1}$: AFD à l'anglo-saxon

Si $p = 1$, il y a une seule variable quantitative, on peut mesurer son pouvoir de séparation des groupes à l'aide de l'analyse de la variance (ANOVA) ordinaire à 1 facteur en considérant la statistique

$$F = \frac{\mathbf{B}/(K-1)}{\mathbf{D}/(n-K)}$$

Si $p > 1$, on généralise en cherchant le vecteur (facteur) v qui maximise le rapport

$$\frac{v^\top \mathbf{B}v}{v^\top \mathbf{D}v}$$

La solution vérifie $\mathbf{D}^{-1}\mathbf{B}v = \mu v$ avec la valeur propre μ maximale

- Les vecteurs propres de $\mathbf{D}^{-1}\mathbf{B}$ sont les mêmes que ceux de $\mathbf{V}^{-1}\mathbf{B}$ de valeur propre λ , $\mu = \frac{\lambda}{1-\lambda}$ la valeur propre de $\mathbf{D}^{-1}\mathbf{B} \mathbf{V}^{-1}\mathbf{B}$.
- En effet, $\mathbf{V}^{-1}\mathbf{B}v = \lambda v$ implique que $\mathbf{B} = \lambda \mathbf{V}v = \lambda(\mathbf{B} + \mathbf{D})v$ et $\mathbf{D}^{-1}\mathbf{B}v = \mu v$
- Comme $0 \leq \lambda \leq 1$ on a $0 \leq \mu \leq \infty$

Affectation d'un nouvel individu

On affecte usuellement un nouvel individu z à un groupe ($Y = k$) en calculant toutes les distances de z aux centres g_k

$$d^2(z, g_k) = (z - g_k)^\top \mathbf{D}^{-1}(z - g_k)$$

avec la métrique **Mahalanobis Fisher** $\mathbf{D}^{-1}$.

On affecte l'individu z au groupe ayant la plus petite distance.

Arbres de décision (CART)

On observe un échantillon

$$\{(x_i, y_i)\}_{i=1}^n, \quad x_i = (x_i^1, \dots, x_i^p)^T \in \mathbb{R}^p$$

Un arbre de décision est une structure hiérarchique binaire composée :

- d'une racine,
- de nœuds internes (règles de décision),
- de feuilles (prédictions).

Chaque nœud correspond à une règle de la forme :

$$x^j < c$$

avec $j \in \{1, \dots, p\}$ et $c \in \mathbb{R}$.

1 Régression par arbre

Dans le cas de la régression, la prédiction dans une feuille est la moyenne :

$$\hat{y} = \frac{1}{N_R} \sum_{x_i \in R} y_i$$

où R est une région définie par les coupures successives.

1.1 Critère de coupure

Pour une coupure (j, c) :

$$R_1(j, c) = \{x : x^j < c\}, \quad R_2(j, c) = \{x : x^j \geq c\}$$

On minimise la somme des carrés :

$$E(j, c) = \sum_{x_i \in R_1} (y_i - \bar{y}_{R_1})^2 + \sum_{x_i \in R_2} (y_i - \bar{y}_{R_2})^2$$

On choisit (j^*, c^*) tel que :

$$(j^*, c^*) = \arg \min_{j, c} E(j, c)$$

2 Classification par arbre

Dans le cas de la classification, on utilise par exemple l'indice de Gini.

Pour une région R :

$$G(R) = 1 - \sum_{k=1}^K p_k^2$$

où p_k est la proportion de la classe k dans R .
Le critère de coupure devient :

$$G(j, c) = \frac{n_1}{n}G(R_1) + \frac{n_2}{n}G(R_2)$$

On choisit (j, c) minimisant $G(j, c)$.

3 Élagage (Pruning)

Un arbre trop profond sur-apprend.
On introduit une pénalisation de complexité :

$$C_\alpha(T) = \sum_{m=1}^{|T|} N_m Q_m + \alpha |T|$$

où :

- $|T|$ = nombre de feuilles,
- Q_m = erreur dans la feuille m ,
- α = paramètre de pénalisation.


On sélectionne l'arbre optimal par validation croisée.

Exemple simple

Considérons un exemple où nous cherchons à prédire si un individu achète un produit ($Y = 0$ ou $Y = 1$) en fonction de son âge (X_1) et de son revenu (X_2). Les données sont les suivantes :

X_1 (Âge)	X_2 (Revenu)	Y (Achat)
25	50K	0
45	80K	1
35	60K	1
20	30K	0

Pour construire l'arbre, nous devons déterminer les divisions qui minimisent une mesure de pureté des nœuds comme l'entropie ou l'indice de Gini. Supposons que la meilleure division se fasse sur $X_1 = 40$ (l'âge) créant ainsi deux sous-ensembles : ceux dont l'âge est inférieur ou égal à 40 et ceux ayant un âge supérieur. L'arbre de décision obtenu pourrait ressembler à ceci :



4 Random Forest

Une forêt aléatoire est un ensemble de M arbres construits ainsi :

- Tirage bootstrap de m observations
- À chaque nœud : sélection aléatoire de q variables parmi p
- Choix de la meilleure coupure parmi ces q variables

Valeurs usuelles :

$$M = 300, \quad m = \frac{2}{3}n, \quad q = \sqrt{p}$$

Prédiction en régression :

$$\hat{y}(x) = \frac{1}{M} \sum_{m=1}^M \hat{y}_m(x)$$

En classification : vote majoritaire.

Algorithm 1 Random Forest

```
for  $m = 1$  to  $M$  do
  Tirer bootstrap
  for chaque nœud do
    Sélectionner  $q$  variables aléatoires
    Choisir meilleure coupure parmi ces  $q$ 
  end for
end for
Agréger les prédictions
```

5 Bagging

Le Bagging (Bootstrap Aggregating) consiste à :

- construire plusieurs arbres sur des échantillons bootstrap,
- agréger leurs prédictions.

Erreur OOB (Out-Of-Bag) : estimation interne de l'erreur en utilisant les observations non tirées.

Algorithm 2 Bagging

```
for  $m = 1$  to  $M$  do
  Tirer un échantillon bootstrap
  Construire un arbre  $\hat{f}_m$ 
end for
return  $\hat{f}(x) = \frac{1}{M} \sum_{m=1}^M \hat{f}_m(x)$ 
```

6 Boosting

Le Boosting construit les arbres séquentiellement :

- chaque arbre corrige les erreurs du précédent,
- pondération adaptative des observations.

Méthodes populaires :

- AdaBoost
- Gradient Boosting

Perceptron, SVM

7 Perceptron

Le perceptron est un algorithme d'apprentissage supervisé destiné à la classification binaire. On considère un ensemble d'apprentissage $S = \{(x_i, y_i)\}_{i=1}^n$ avec $x_i \in \mathbb{R}^d$ et $y_i \in \{-1, 1\}$.

Modèle

Le perceptron cherche à apprendre une fonction de seuil donnée par

$$\hat{y} = \begin{cases} 1 & \text{si } \sum_{j=1}^d \beta_j x_j > -\beta_0 \\ -1 & \text{sinon} \end{cases}$$

En introduisant le vecteur augmenté $\tilde{x} = (1, x_1, \dots, x_d)$ et $\beta = (\beta_0, \beta_1, \dots, \beta_d)$, la règle de décision s'écrit

$$\hat{y} = \text{sign}(\tilde{x}^T \beta).$$

Principe d'apprentissage

L'idée est de modifier les poids β uniquement lorsque la prédiction est erronée.

- Si la prédiction est correcte, les poids restent inchangés.
- Si la prédiction est incorrecte, les poids sont ajustés de manière à déplacer l'hyperplan de séparation dans la direction appropriée.

Algorithme

1. Initialiser $\beta^{(0)} = 0$.
2. Pour chaque exemple $(x^{(t)}, y^{(t)})$:
 - calculer $\hat{y}^{(t)} = \text{sign}(\tilde{x}^{(t)T} \beta^{(t)})$
 - si $\hat{y}^{(t)} \neq y^{(t)}$, alors
$$\beta^{(t+1)} = \beta^{(t)} + y^{(t)} \tilde{x}^{(t)}$$
 - sinon, poser $\beta^{(t+1)} = \beta^{(t)}$.
3. Reprendre le processus jusqu'à convergence ou jusqu'à atteindre un nombre maximal d'itérations.

Garantie théorique

Lorsque les données sont **linéairement séparables** et que les vecteurs d'entrée sont bornés, l'algorithme du perceptron converge en un nombre fini d'itérations vers un hyperplan qui sépare parfaitement les données.

Plus précisément, si $\|x_i\| \leq r$ et s'il existe un vecteur v tel que $y_i(v^T x_i) \geq \gamma$ pour une marge $\gamma > 0$, alors le nombre de mises à jour est majoré par

$$M \leq \frac{r^2}{\gamma^2}.$$

8 Support Vector Machines (SVM)

Les SVM sont des méthodes d'apprentissage supervisé utilisées pour la classification et la régression. Elles visent à trouver, dans un espace de grande dimension, l'hyperplan qui sépare au mieux deux classes en maximisant la distance entre l'hyperplan et les points les plus proches de chaque classe.

Modèle linéaire

Considérons un ensemble d'apprentissage

$$S = \{(x_i, y_i)\}_{i=1}^n$$

où $x_i \in \mathbb{R}^d$ désigne un vecteur de caractéristiques de dimension d , et $y_i \in \{-1, 1\}$ la variable cible binaire associée.

Un hyperplan séparateur dans l'espace des caractéristiques est défini par

$$f(x) = w^T x + b,$$

où $w \in \mathbb{R}^d$ est le vecteur de poids (ou paramètres) et $b \in \mathbb{R}$ est le terme de biais.

La règle de décision associée au classifieur linéaire s'écrit alors

$$\hat{y} = \text{sign}(w^T x + b),$$

où $\hat{y}$ représente la classe prédite pour l'exemple x .

Principe de la marge maximale

Parmi l'ensemble des hyperplans séparateurs qui réalisent une séparation correcte des données d'apprentissage, les machines à vecteurs de support (Support Vector Machines, SVM) sélectionnent celui qui **maximise la marge w** , définie comme la distance minimale entre l'hyperplan de décision et les exemples d'apprentissage qui lui sont les plus proches. Ces exemples particuliers sont appelés **vecteurs de support**.

Ce principe conduit au problème d'optimisation suivant :

$$\min_{w,b} \frac{1}{2} \|w\|^2$$

sous les contraintes de séparation linéaire

$$y_i(w^T x_i + b) \geq w, \quad i = 1, \dots, n.$$

Maximiser la marge euclidienne revient à minimiser la norme euclidienne de w tout en respectant les contraintes de classification correcte des exemples d'apprentissage.

Données non séparables

En pratique, les ensembles de données ne sont que rarement linéairement séparables. On introduit alors des variables d'assouplissement (ou *slack*) $\xi_i \geq 0$ qui autorisent une certaine proportion d'erreurs de classification ou de violations de la marge.

Le problème d'optimisation devient

$$\min_{w,b,\xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i$$

sous les contraintes

$$y_i(w^T x_i + b) \geq \mathbf{w} - \xi_i, \quad \xi_i \geq 0, \quad i = 1, \dots, n.$$

Le paramètre de régularisation $C > 0$ contrôle le compromis entre la maximisation de la marge (complexité du classifieur) et la pénalisation des erreurs de classification ou des marges violées.

Formulation duale

Ce problème peut être réécrit sous forme duale en introduisant des multiplicateurs de Lagrange α_i associés aux contraintes de marge. La solution du problème d'optimisation conduit alors à une fonction de décision de la forme

$$f(x) = \sum_{i=1}^n \alpha_i y_i x_i^T x + b.$$

Seuls certains multiplicateurs de Lagrange α_i sont strictement positifs. Les observations correspondantes sont appelées **vecteurs de support** et sont précisément celles qui déterminent l'hyperplan séparateur optimal.

SVM et Noyau : Kernel Trick

Pour traiter des données non linéairement séparables dans l'espace d'entrée, les SVM recourent à des **fonctions noyau**. Ces dernières définissent implicitement un plongement des données dans un espace de caractéristiques de dimension potentiellement très élevée, au sein duquel une séparation linéaire peut devenir possible.

La fonction de décision s'écrit alors

$$f(x) = \sum_{i=1}^n \alpha_i y_i K(x_i, x) + b$$

où $K(x_i, x)$ désigne une fonction noyau symétrique, généralement définie positive, qui joue le rôle de produit scalaire dans l'espace de caractéristiques induit.

Exemples usuels de noyaux :

- **noyau linéaire** : $K(x, z) = x^T z$
- **noyau polynomial** : $K(x, z) = (x^T z + c)^p$, avec $c \in \mathbb{R}$ et $p \in \mathbb{N}$

— **noyau gaussien (RBF) :**

$$K(x, z) = \exp\left(-\frac{\|x - z\|^2}{2\sigma^2}\right), \quad \sigma > 0$$