

Université de Lille
DATA MINING : M1 MIASHS

Exercice 1 : On considère la base de données CRSC.XLS. Celle-ci contient des données réelles issues de l'organisme de crédit XX qui ont été modifiées pour des raisons de confidentialité. Les variables sont les suivantes :

Y	1 si le client est bon payeur, 0 sinon
AGE	âge de l'individu, en années
NCARTES	nombre de cartes et de produits bancaires détenus par le client
PROP	1 si le client est propriétaire de son logement, 0 sinon
PROF	profession du client
	1 : agriculteur
	2 : artisan
	3 : cadre
	4 : profession intermédiaire
	5 : employé
	6 : ouvrier
	7 : retraité
	8 : autre

1. Faites une étude statistique exploratoire des données, fournissez quelques tableaux synthétiques.
2. Y a-t-il des écarts significatifs entre les bons payeurs et les mauvais payeurs en ce qui concerne :
 - (a) leur âge moyen ?
 - (b) leur statut de propriétaire ou non ?
3. Rédigez une brève note (1 A4 recto-verso max) à destination du directeur commercial de l'organisme de crédit XX pour mettre en évidence les points les plus pertinents de votre travail. Attention à la qualité de la communication dans cette note ! N'oubliez pas que le directeur commercial ne connaît rien en statistique...
4. Estimez un modèle LOGIT avec l'âge (et une constante) comme seule variable explicative. Interprétez les résultats.
5. Estimez un modèle LOGIT avec PROP (et une constante) comme seule variable explicative. Interprétez les résultats.
6. On cherchera ensuite à obtenir un modèle où les coefficients sont significatifs ($\alpha = 10\%$) et où le pourcentage de bien classés est le meilleur possible.

Exercice 2 :

Idem avec des modèles k-NN, Naïf-Bayes, LDA, QDA.