

TP – Nettoyage et transformation de données avec KNIME

Contexte

Vous disposez d'un jeu de données socio-démographiques synthétique contenant un grand nombre d'individus. Ce jeu de données est volontairement brut et imparfait afin de simuler un cas réel de données avant analyse.

Objectifs pédagogiques

- 1 Importer et explorer un jeu de données dans KNIME
- 2 Identifier les problèmes de qualité des données
- 3 Nettoyer et transformer les données
- 4 Créer de nouvelles variables exploitables

Données

Fichier fourni : **dataviz_dataset.csv** (séparateur ;). Le jeu de données contient des informations socio-démographiques, économiques et comportementales.

Partie 1 – Importation et exploration

- 1 Créer un nouveau workflow KNIME
- 2 Importer le fichier avec le nœud CSV Reader
- 3 Observer le nombre de lignes, de colonnes et les types de variables

Partie 2 – Détection des problèmes de qualité

À l'aide des nœuds Data Explorer, Statistics et Missing Value, identifier les valeurs manquantes, les valeurs aberrantes et les incohérences.

Partie 3 – Nettoyage des données

- 1 Traitement des valeurs manquantes (moyenne, médiane, mode)
- 2 Correction des types de données
- 3 Suppression ou filtrage des valeurs aberrantes

Partie 4 – Transformation des données

- 1 Création de classes d'âge avec Rule Engine
- 2 Création de niveaux de salaire

- 3 Normalisation de variables numériques (optionnel)

Partie 5 – Export

Exporter le jeu de données nettoyé au format CSV sous le nom **dataviz_dataset_clean.csv**.

Livrables attendus

- 1 Workflow KNIME (.knwf)
- 2 Fichier CSV nettoyé
- 3 Compte-rendu d'une page maximum