

Ablaye SOW : M1 MIASHS

Nœuds du workflow :

- **CSV Reader** : utiliser pour importer le jeu données avec l'extension **csv**.
- **Statistic view** : important de démarrer avec ce nœud pour avoir une vision globale sur les données : valeurs manquantes et statistiques.
- **Column Filter** : nœud intéressant lorsqu'on souhaite faire une analyse sur des colonnes précises. Dans notre cas on n'a pas fait recours à ce nœud car ne faisant pas l'objet de ce TP.
- **Missing Value** : utiliser pour remplacer les valeurs manquantes d'une colonne donnée. Par exemple dans notre cas on a remplacé tous les missing value de « **Marque de véhicule** » par **Non véhiculé** par garder la cohérence des données.
- **Duplicate Row Filter** : nœud très important car il nous permet de garder l'atomicité des enregistrement (suppression des doublons). Cela garantit aussi la correction des valeurs du calcul statistique(mean, mode ...).
- **Number to String** : une fois les doublons supprimer, il est important de faire recours à la conversion des variables avec des types appropriés. Dans notre cas, nous avons modifier le type de « **ID** » en string pour garder un peu la logique.
- **Row Filter** : après conversion de type, nous avons effectuer un filtre sur l'age des employés en gardant que les actifs. Pour ce faire, on extrait de la base tout employé dont l'age est supérieur stricte à 64 ans(retraité).
- **Rule Engine** : nœud très important car permet de mettre en place une nouvelle colonne à partir des variables de départ avec des conditions que nous mettons en place. Dans notre cas, on a effectuer une segmentation des employé selon leurs ages (nouvelle colonne **Niveau**). Pour les moins de 30 ans (Junior), ceux entre 30 et 50 ans (Senior) et ceux de plus de 50 ans (Expert). Cette segmentation n'est pas définitif car rien ne justifie qu'un jeune employé a moins de maîtrise qu'un employé plus âgé. Mais nous avons pris cette règle pour garder la logique du milieu professionnel.
- **Normalizer** : nœud important pour normaliser les valeurs numérique à une échelle de 0 1. Étape très important lorsque nous souhaitons effectuer certains algo de machine learning. Par exemple effectuer une classification (K-means par exemple) en utilisant les données normalisées semble beaucoup plus facile : représentation graphique et calcul de distance.
- **CSV Writer** : une fois fini notre travail, il est important de stocker notre table finale pour des futures analyses. Ainsi à l'aide de ce nœud, nous sauvegardons notre base finale dans un format souhaité.