

Projet de Marketing Quantitatif

- Par groupe de 3 personnes Maximum
- À rendre sous forme de notebook R et/ou Python (ne pas oublier de nommer les membres du groupe)
- Date limite du rendu : 8 Mars 23h59 par mail (1 mail par groupe) à emile.rousseau2@gmail.com
- En cas de problème, vous pouvez me joindre sur ce même mail pour m'en faire part

Sujet :

Nous étudions les ventes de billet pour différents événements. Nous remarquons que de nombreux clients ne consomment plus nos produits et nous souhaitons que cela change. Pour cela, nous avons demandé une extraction de la base de ventes des clients pour une catégorie spécifique d'événement, et avons reçu le fichier *data_projet.csv*. Ces données ont été nettoyées au paravant, traitant toutes les valeurs manquantes et aberrantes afin d'accélérer notre processus de traitement

Notre but : Optimiser la prochaine campagne de relance client à ne pas perdre en mettant en place des outils de scoring client.

Pour cela, nous identifieront sur une période qui sont les clients à ne pas perdre, puis sur une seconde période, lesquels ont à nouveau effectué un achat parmi eux. Nous entraîneront un classifieur sur cette catégorie de client et chercherons à optimiser notre profit sur cette campagne

Partie I - Création de la base de données

1. Chargez la base de données jointe au sujet
2. Construisez deux tables : une *table client* à partir des transactions effectuées avant août 2025 (table « ancienne »), et une avec toutes les transactions (table « complète »)
3. Pour chacune de ces tables, calculez le score RFM de chaque client
4. Identifiez dans la table dite ancienne, les clients qui ont un profil « à ne pas perdre »
5. Dans la table dite complète, identifiez parmi les clients que vous avez listés dans la question précédente, lesquels ont effectué un achat depuis Août 2025
6. À partir de la table des anciennes transactions, créez une table agrégée au client avec uniquement les clients à ne pas perdre. Créez une variable cible dans cette table qui indique 1 si le client a effectué un achat depuis Août 2025, 0 sinon. Libre à vous de créer toutes les variables que vous souhaitez pour définir les clients

Partie II - Traitement des données

À partir de la table que vous venez de créer :

1. Réalisez une analyse univariée des variables de la table. Commentez les graphiques que vous considérez les plus pertinents
2. Réalisez une analyse bivariable des variables explicatives vers la variable cible uniquement. Interprétez les graphiques en utilisant le tableau d'analyse des interactions (variables liées ou non, fortement ou légèrement)
3. Entraînez sur ces données 3 classificateurs (plus si l'envie vous prend) : Modèle logistique, Modèle logistique optimisé avec Stepwise, modèle de votre choix mais forcément non logistique
4. Évaluez ces modèles. Sachant que réactiver un client est considéré comme cher, quel métrique est la plus pertinente à optimiser selon vous?

5. On considère que relancer un client à ne pas perdre coûte 4€ par client, et en réactiver un nous rapporte 30€. Créez les courbes de profit relatives à chacun des modèles que vous avez créés. Commenter ce graphique
6. Quel est le gain maximal attendu par cette campagne ? Grâce à quel modèle ? Pour quel proportion de la clientèle à contacter ?