

COURS DE MARKETING QUANTITATIF

Émile Roussel

SCORING CLIENT 2

Qu'est-ce que c'est? À quoi ça sert?



PLUS LOIN DANS LE SCORING

05.



Contexte :

- Nous avons nos données préparées. Nous cherchons maintenant à créer un classifieur pour optimiser le résultat de notre campagne
- Problème : comment choisir un bon classifieur ? Pourquoi l'un et pas un autre ?

Méthode :

- Objectif : Maximiser l'efficiency d'une campagne (meilleur rapport résultat / coût possible). Exemple : Obtenir le plus d'achat possible pour un budget donné
- Nous devons créer des classifieurs, et les comparer sur des critères quantitatifs, de manière cohérente à chaque campagne
- Deux axes : Évaluation des prédictions du modèle, Montant maximal de la courbe de Gain

ÉVALUATION DES PRÉDICTIONS

Premier axe de comparaison

- À partir de notre modèle entraîné, nous classons les prédictions effectuées aux observations réelles. On créer une matrice de confusion

		Predicted Class	
		Yes	No
Actual Class	Yes	TP	FN
	No	FP	TN


- À l’aide de cettre matrice de confusion, nous pouvons construire les scores suivant :

Accuracy :	$\frac{TP+ TN}{TP+ TN+FP+FN}$	Indique la qualité prédictive globale du modèle → Utile pour un modèle ayant des classes équilibrés (label 0 aussi important que 1)
Precision :	$\frac{TP}{TP+ FP}$	Qualité de prédiction de l’issue souhaitée → Utile lorsque l’impact d’un faux positif est élevé (ex : coût de démarchage élevé)
Recall :	$\frac{TP}{TP+ FN}$	Quantité de prédiction correcte parmi celles détectées comme positive → Utile pour capter le plus d’individu positif possible (ex : client à forte valeur)
F1-score :	$\frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$	Mesure équilibrant la précision avec le recall pour optimiser leur interaction → Utile pour comparer deux modèles quand il y a déséquilibre de classe

ÉVALUATION DES PRÉDICTIONS

Premier axe de comparaison

- La matrice de confusion peut cependant être altérée par le seuil que nous fixons pour effectuer nos confusions. Par défaut ce seuil est de 0,5 (si la proba $< 0,5 \rightarrow 0$, sinon 1)
- Faire varier ces seuils nous donnent un modèle qui sera soit :
 - (seuil $> 0,5$) La sensibilité du modèle augmente $\rightarrow$ On augmente la quantité d'individu classé comme positif
 - (seuil $< 0,5$) La spécificité du modèle augmente $\rightarrow$ On restreint la quantité d'individu classé comme positif
- Pour chaque seuil (entre 0 et 1), on peut construire la ROC courbe suivante :



- Chaque point correspond en y au recall, et x à 1-recall
- En calculant l'aire sous cette courbe, on peut déterminer la qualité prédictive globale du modèle (peut importe le seuil fixé)

UTILISATION DU SCORING CLIENT

Développement de la phase d'analyse des données



APPLICATION DU MODÈLE

05.



À notre disposition

- Nous avons un modèle de classification entraîné et optimisé selon notre objectif
- Un jeu de données où chaque ligne représente un individu différent, au même format que l'échantillon d'entraînement

Ce que nous faisons


- Nous utilisons notre modèle de prédiction pour attribuer à chaque individu sa probabilité d'être classer comme positif → Il s'agit de notre score
- Nous ordonnons nos individus du plus grand score au plus petit score
- Nous déterminons une quantité d'individu à contacter : 20% de la base, tout ceux ayant une probabilité $>$ à $x\%$, quantité maximisant le profit espéré, etc...
- On évalue le résultat de notre campagne

ÉVALUATION DES PRÉDICTIONS

Deuxième axe de comparaison

La courbe de Profit

- En sachant :
 - Le coût pour le contact d'un individu
 - Le gain (moyen) pour chaque individu positif
- On peut construire la courbe de profit avec :
 - En abscisse, la proportion des individus contacté (de 0 à 100%)
 - En ordonnée, la quantité de répondant positif x le gain associé à chaque individu positif



→ Permet d'obtenir un montant final optimisé du profit retiré par la campagne