

Projet Séries Temporelles

Consommation mensuelle des ménages en énergie, eau et déchets
Master 1 MIASHS — Université de Lille

Ablaye SOW

10 mai 2026

Contents

1	Partie 1 : Présentation de la série temporelle et visualisation	3
1.1	Présentation de la série temporelle	3
1.2	Importation et préparation des données	3
1.3	Visualisation de la série temporelle	4
1.4	Analyse du graphique de la série temporelle	5
2	Partie 2 : Méthodes de décomposition	5
2.0.1	Modèles classiques de décomposition	5
2.1	Calcul de la tendance : Moyenne mobile d'ordre 12	6
2.1.1	Formulation théorique	6
2.2	Calcul des données sans la tendance	6
2.2.1	Formulation théorique	6
2.3	calcul des moyennes mensuelles et des variations saisonnières	7
2.3.1	(Méthode additive)	7
2.4	calcul de la serie corrigée (CVS)	8
2.4.1	Formulation théorique	8
2.5	Découpage de la série brute en échantillons d'estimation et de prévision	9
3	Partie 3 : Méthodes de lissage	9
3.1	La méthode Holt	9
3.1.1	Formulation théorique	9
3.1.2	Interprétation	9
3.1.3	Estimations des paramètres qui minimisent le MAP	9
3.1.4	Prévision à l'aide de la méthode Holt	11
3.1.5	Visualisation des prévisions et données observées sur les échantillons d'estimation . . .	12

3.2	La méthode de Holt-Winters additive	12
3.2.1	Formulation théorique	12
3.2.2	Interprétation	13
3.2.3	Estimations des paramètres qui minimisent le MAPE	13
3.2.4	Prévision à l'aide de la méthode de Holt-Winters additive	13
3.2.5	Visualisation des prévisions et données observées sur les échantillons d'estimation . . .	14
3.3	La méthode de Holt-Winters multiplicative	15
3.3.1	Formulation théorique	15
3.3.2	Interprétation	16
3.3.3	Estimations des paramètres qui minimisent le MAPE	16
3.3.4	Prévision à l'aide de la méthode de Holt-Winters multiplicative	16
3.3.5	Visualisation des prévisions et données observées sur les échantillons d'estimation . . .	17
3.4	Comparaison des méthodes de lissage	18
3.5	choix de la meilleure méthode de lissage	18
3.6	Prévision sur l'échantillon de prévision à l'aide de la méthode holt	19
3.6.1	Graphique final sur l'ensemble de l'échantillon comportant les observations et les prévisions	19
4	Partie 4 : Méthodes Box-Jenkins	20
4.1	Analyses de la série de l'échantillon d'estimation	20
4.1.1	Visuation de la série temporelle de l'échantillon d'estimation	20
4.1.2	Analyse du graphique de la série	21
4.1.3	Tests de stationnarité	21
4.1.4	Identification du modèle ARMA	23
4.1.5	Confirmation et sélection du modèle final	24
4.2	Prévision à l'aide du modèle ARIMA(1,1,2) contraint	28
4.2.1	Prévision des 12 dernières observations	28
4.2.2	Calcul du MAPE sur l'échantillon de prévision	28
4.3	Comparaison des prévisions : lissage vs Box-Jenkins	29
4.3.1	Graphique des observations et des prévisions	29
4.3.2	Tableau comparatif des prévisions et MAPE	29
4.4	Conclusion	30

1 Partie 1 : Présentation de la série temporelle et visualisation

1.1 Présentation de la série temporelle

La série étudiée dans ce travail est la **consommation mensuelle des ménages en biens d'énergie, eau et déchets** en France métropolitaine (type de produit : DE — Énergie, eau et déchets), publiée par l'INSEE sous l'identifiant **idBank 011794485**.

Il s'agit d'une série en **valeurs absolues**, exprimée en **milliards d'euros**, aux **volumes aux prix de l'année précédente, chaînés depuis 2020** (base 100 = 2020).

La série couvre la période de **janvier 1980 à janvier 2026**, soit **549 observations mensuelles**. Elle est mise à jour régulièrement, la dernière mise à jour datant du **30 avril 2026**.

Source : INSEE — Comptes nationaux trimestriels, série idBank 011794485.

Disponible à l'adresse : <https://www.insee.fr/fr/statistiques/serie/011794485>

Note importante : La consommation d'énergie, d'eau et de déchets des ménages reflète à la fois les comportements de consommation des ménages et les conditions climatiques (chauffage, climatisation), ce qui en fait un indicateur sensible aux chocs conjoncturels et aux évolutions structurelles du pouvoir d'achat.

1.2 Importation et préparation des données

```
## https://www.insee.fr/fr/statistiques/serie/011794485#Telechargement
# Charger les données
data <- read.csv(
  file.path(
    "/home/layedev/Documents/miashs2026/MQME2026_SEMESTRE2",
    "Méthodes de prévision",
    "projet_2026",
    "valeurs_mensuelles.csv"
  ),
  header = TRUE,
  dec = "."
)
## nettoyage des données : suppression des 4 premières lignes et de la 3ème colonne
data <- data[5:nrow(data), -3]
colnames(data) <- c("Date", "Valeur")

## On ordonne les données par date croissante
data <- data[order(data$Date), ]

## conversion de la colonne Valeur en numérique
data$Valeur <- as.numeric(data$Valeur)
## conversion de la colonne Date en format Date
data$Date <- as.Date(paste0(data$Date, "-01"))


knitr::kable(head(data, 10), caption = "Aperçu des données")
```

Table 1: Aperçu des données

	Date	Valeur
557	1980-01-01	2.403
556	1980-02-01	2.412
555	1980-03-01	2.420
554	1980-04-01	2.428
553	1980-05-01	2.434
552	1980-06-01	2.440
551	1980-07-01	2.445
550	1980-08-01	2.450
549	1980-09-01	2.454
548	1980-10-01	2.457

1.3 Visualisation de la série temporelle

```
plot(data$Date, data$Valeur, type = "l", col = "blue",
      xlab = "Date", ylab = "Valeur (milliards d'euros)",
      main = "Consommation mensuelle des ménages en énergie,
eau et déchets (1980-2026)")
```



1.4 Analyse du graphique de la série temporelle

L'observation de la série sur la période 1980–2026 met en évidence plusieurs caractéristiques structurelles et conjoncturelles :

- Une **tendance haussière de long terme** entre 1980 et 2013 environ, reflétant la croissance progressive de la consommation d'énergie et d'eau des ménages français, corrélée à l'augmentation du niveau de vie et à l'équipement des foyers.
- Un **pic autour de 2012–2013** (environ 5,3 milliards d'euros), suivi d'une **tendance baissière** jusqu'en 2026, qui traduit vraisemblablement les effets conjugués des politiques d'efficacité énergétique, de la hausse des prix de l'énergie incitant à la sobriété, et des hivers plus doux liés au changement climatique.
- Un **creux ponctuel en avril 2020** (environ 4,22 milliards d'euros), imputable au premier confinement lié à la pandémie de Covid-19, qui a brutalement modifié les comportements de consommation.
- Une **forte volatilité en 2021–2022** associée à la crise énergétique mondiale, avec des pics de consommation inhabituels en lien avec la flambée des prix.

2 Partie 2 : Méthodes de décomposition

2.0.1 Modèles classiques de décomposition

Soit une série chronologique $(X_t, t = 1, \dots, T)$. Le modèle classique de décomposition distingue trois composantes :

$$\boxed{X_t = T_t + I_t + \varepsilon_t} \quad (\text{modèle additif})$$

$$\boxed{X_t = T_t \times I_t \times \varepsilon_t} \quad (\text{modèle multiplicatif})$$

où :

- T_t est la **tendance** (composante fondamentale de long terme),
- I_t est la **composante saisonnière** déterministe,
- ε_t est la **composante résiduelle** aléatoire.

Le modèle additif est adapté quand l'amplitude des variations saisonnières est **constante** au fil du temps. Le modèle multiplicatif est préférable quand cette amplitude est **proportionnelle au niveau** de la série. Le passage de l'un à l'autre se fait par transformation logarithmique :

$$\log(X_t) = \log(T_t) + \log(I_t) + \log(\varepsilon_t)$$

Dans ce travail, nous retenons le **modèle additif**, la série présentant une amplitude saisonnière résiduelle relativement stable.

2.1 Calcul de la tendance : Moyenne mobile d'ordre 12

2.1.1 Formulation théorique

Pour des données **mensuelles** ($s = 12$), la tendance est estimée par une **moyenne mobile d'ordre 12 centrée**, définie par :

$$T_t = \frac{1}{24}X_{t-6} + \frac{1}{12} \sum_{k=-5}^5 X_{t+k} + \frac{1}{24}X_{t+6}$$

Cette formule est un cas particulier de la moyenne mobile d'ordre p pair. Pour p pair en général :

$$T_t = \frac{1}{p} \left(\frac{1}{2}X_{t-p/2} + X_{t-p/2+1} + \dots + X_{t+p/2-1} + \frac{1}{2}X_{t+p/2} \right)$$

La moyenne mobile a un **effet lissant** : elle atténue les irrégularités et élimine les mouvements saisonniers de période s . En contrepartie, les valeurs de T_t ne sont pas disponibles pour les **6 premières et 6 dernières** observations.

```
n <- length(data$Date)

Tendance <- matrix(data = NA, nrow = n, ncol = 1)

## calcul de la moyenne mobile d'ordre 12
for (i in 7:(n-6)) {
  Tendance[i, 1] <- (1/24) * (data$Valeur[i-6] + data$Valeur[i+6]) +
    (1/12) * sum(data$Valeur[(i-5):(i+5)])
}
```

2.2 Calcul des données sans la tendance

2.2.1 Formulation théorique

Une fois la tendance T_t estimée, on calcule la **série sans tendance** (modèle additif) :

$$X_t - T_t = I_t + \varepsilon_t$$

Ces résidus sont reportés dans le **tableau de Buys-Ballot**, qui organise les données en **lignes = mois** et **colonnes = années**. Pour chaque mois $i \in \{1, \dots, 12\}$, on calcule la moyenne sur toutes les années disponibles :

$$\bar{m}_i = \frac{1}{N_i} \sum_j (X_{i+12(j-1)} - T_{i+12(j-1)})$$

où N_i est le nombre d'années disponibles pour le mois i .

On corrige ensuite ces moyennes pour satisfaire la **contrainte de conservation des aires** (principe d'identification) :

$$I_i = \bar{m}_i - \bar{m}_\bullet \quad \text{avec} \quad \bar{m}_\bullet = \frac{1}{12} \sum_{i=1}^{12} \bar{m}_i$$

Ce qui garantit que :

$$\sum_{i=1}^{12} I_i = 0$$

Les coefficients I_i s'appliquent identiquement à toutes les années : $I_1 = I_{13} = I_{25} = \dots = I_{\text{Janvier}}$, etc.

```
data_sans_tendance <- data$Valeur - Tendance[, 1]

annees = 1980:2026
tableau <- matrix(data = NA, nrow = 12, ncol = length(annees))
Buys_Ballot <- matrix(data = NA, nrow = 12, ncol = length(annees))

for(i in 1:12) {
  for (j in 1:length(annees)) {
    if(i*j > n) {
      tableau[i, j] <- NA
    }
    else {
      tableau[i, j] <- data_sans_tendance[i + 12*(j-1)]
      Buys_Ballot[i, j] <- data$Valeur[i + 12*(j-1)]
    }
  }
}

tableau <- as.data.frame(tableau)
colnames(tableau) <- annees
mois = c("Janvier", "Février", "Mars", "Avril", "Mai", "Juin", "Juillet",
  "Août", "Septembre", "Octobre", "Novembre", "Décembre")
rownames(tableau) <- mois
```

2.3 calcul des moyennes mensuelles et des variations saisonnières

2.3.1 (Méthode additive)

```
moyennes <- rowMeans(tableau, na.rm = TRUE)
tableau <- cbind(tableau, moyennes)
colnames(tableau)[ncol(tableau)] <- "Moyenne"

moyenne_globale <- mean(tableau$Moyenne, na.rm = TRUE)
var_saisonniere <- tableau$Moyenne - moyenne_globale
tableau <- cbind(tableau, var_saisonniere)
colnames(tableau)[ncol(tableau)] <- "It"

knitr::kable(tableau[, c(1:6, ncol(tableau)-1, ncol(tableau))],
  caption = "Tableau de Buys-Ballot (extrait)",
  digits = 3)
```

Table 2: Tableau de Buys-Ballot (extrait)

	1980	1981	1982	1983	1984	1985	Moyenne	It
Janvier	NA	0.002	-0.022	-0.051	0.000	0.430	0.018	0.019
Février	NA	-0.066	-0.187	0.049	-0.018	-0.098	0.032	0.033
Mars	NA	-0.163	0.033	-0.058	0.067	0.083	-0.035	-0.035
Avril	NA	-0.096	0.000	0.130	-0.015	-0.049	0.002	0.002
Mai	NA	0.075	0.024	0.092	0.147	0.092	0.027	0.027
Juin	NA	0.036	-0.025	-0.070	0.020	-0.045	-0.004	-0.004
Juillet	0.005	0.042	0.001	-0.048	-0.033	-0.035	-0.003	-0.003
Août	0.010	0.048	0.001	-0.049	-0.080	-0.084	-0.005	-0.005
Septembre	0.021	0.019	-0.018	-0.039	0.031	-0.084	0.013	0.013
Octobre	0.033	0.027	0.058	-0.026	-0.046	-0.159	-0.013	-0.013
Novembre	0.034	0.055	-0.044	-0.017	-0.221	0.195	0.001	0.001
Décembre	0.028	0.022	-0.015	0.009	-0.075	-0.135	-0.036	-0.035

2.4 calcul de la serie corrigée (CVS)

2.4.1 Formulation théorique

Pour obtenir la **série CVS** (corrigée des variations saisonnières), on retranche à chaque observation le coefficient saisonnier du mois correspondant :

$$X_t^{CVS} = X_t - I_t$$

La série CVS ne contient plus que la tendance et le résidu :

$$X_t^{CVS} = T_t + \varepsilon_t$$

```

Buys_Ballot <- Buys_Ballot - rep(tableau$It, each = length(annees))
Buys_Ballot = as.data.frame(Buys_Ballot)
colnames(Buys_Ballot) = annees
row.names(Buys_Ballot) = mois
knitr::kable(Buys_Ballot[, 1:8],
              caption = "Série CVS - Tableau de Buys-Ballot corrigé (extrait)",
              digits = 3)

```

Table 3: Série CVS — Tableau de Buys-Ballot corrigé (extrait)

	1980	1981	1982	1983	1984	1985	1986	1987
Janvier	2.384	2.420	2.457	2.535	2.749	3.368	3.074	3.614
Février	2.393	2.357	2.293	2.644	2.748	2.853	3.393	3.215
Mars	2.401	2.265	2.516	2.547	2.853	3.041	3.095	3.406
Avril	2.409	2.336	2.489	2.743	2.791	2.913	3.595	3.059
Mai	2.415	2.514	2.517	2.716	2.961	3.082	3.024	3.374
Juin	2.421	2.481	2.470	2.570	2.839	2.976	3.078	3.269
Juillet	2.426	2.491	2.501	2.609	2.816	2.978	3.094	3.252
Août	2.431	2.496	2.519	2.622	2.800	2.940	2.981	3.176
Septembre	2.435	2.475	2.516	2.651	2.923	2.964	3.189	3.157

	1980	1981	1982	1983	1984	1985	1986	1987
Octobre	2.438	2.500	2.604	2.680	2.859	2.920	3.005	3.180
Novembre	2.440	2.534	2.521	2.702	2.694	3.300	3.014	3.224
Décembre	2.441	2.501	2.562	2.737	2.851	2.972	3.122	3.223

2.5 Découpage de la série brute en échantillons d'estimation et de prévision

```
# échantillon d'estimation
estimation <- data$Valeur[1:(n-12)]
# échantillon de prévision
prevision <- data$Valeur[(n-11):n]
# conversion en série temporelle
data_ts <- ts(estimation, frequency = 12)
```

3 Partie 3 : Méthodes de lissage

3.1 La méthode Holt

3.1.1 Formulation théorique

La méthode de Holt permet de construire des **prévisions linéaires** pour des séries présentant une tendance, sans composante saisonnière. La prévision à l'horizon h faite en T est :

$$\hat{Y}_T(h) = S_T + h \cdot T_T, \quad h = 1, 2, \dots$$

où S_t est la **composante de niveau** et T_t est la **composante de tendance**, mises à jour récursivement par :

$$S_t = \alpha Y_t + (1 - \alpha)(S_{t-1} + T_{t-1})$$

$$T_t = \beta(S_t - S_{t-1}) + (1 - \beta)T_{t-1}$$

avec $0 < \alpha < 1$ la constante de lissage du niveau et $0 < \beta < 1$ la constante de lissage de la tendance.

Initialisation : $S_1 = Y_1$ et $T_1 = 0$.

3.1.2 Interprétation

- S_t est une moyenne pondérée de l'observation courante Y_t et de la prévision précédente $(S_{t-1} + T_{t-1})$.
- T_t est une moyenne pondérée de l'accroissement récent du niveau $(S_t - S_{t-1})$ et de la tendance passée T_{t-1} .
- Un α proche de 1 donne plus de poids aux observations récentes ; un β proche de 1 fait réagir rapidement la tendance aux changements.

3.1.3 Estimations des paramètres qui minimisent le MAP

```

# Fonction qui calcule le MAPE pour des alpha et beta donnés
calcul_mape_holt <- function(alpha, beta, serie) {
  n <- length(serie)
  St <- numeric(n)
  Tt <- numeric(n)
  Prev <- numeric(n)

  # Initialisation
  St[1] <- serie[1]
  Tt[1] <- 0
  Prev[1] <- serie[1]

  # Récurrence
  for (t in 2:n) {
    Prev[t] <- St[t-1] + Tt[t-1]
    St[t] <- alpha * serie[t] + (1 - alpha) * (St[t-1] + Tt[t-1])
    Tt[t] <- beta * (St[t] - St[t-1]) + (1 - beta) * Tt[t-1]
  }

  # MAPE (on exclut t=1 car pas de prévision possible)
  mape <- mean(abs((serie[-1] - Prev[-1]) / serie[-1])) * 100
  return(mape)
}

# Recherche sur grille (pas de 0.01)
grille <- seq(0.01, 0.99, by = 0.01)

resultats <- data.frame(
  alpha = numeric(),
  beta = numeric(),
  MAPE = numeric()
)

best_mape <- Inf
best_alpha <- NA
best_beta <- NA

for (alpha in grille) {
  for (beta in grille) {
    mape <- calcul_mape_holt(alpha, beta, estimation)

    if (mape < best_mape) {
      best_mape <- mape
      best_alpha <- alpha
      best_beta <- beta
    }
  }
}

cat("=== Résultats de l'optimisation Holt (MAPE) ===\n")

```

```
## === Résultats de l'optimisation Holt (MAPE) ===
```

```
cat("Alpha optimal :", best_alpha, "\n")
```

```
## Alpha optimal : 0.25
```

```
cat("Beta optimal :", best_beta, "\n")
```

```
## Beta optimal : 0.01
```

3.1.4 Prédiction à l'aide de la méthode Holt

```
# Initialisation des vecteurs pour les composantes de niveau, de tendance et  
# les prévisions  
  
# St_holt[t] : composante de niveau à l'instant t de meme longueur que  
# l'échantillon d'estimation  
St_holt <- c(estimation[1], rep(0, length(estimation) - 1))  
  
# Tt_holt[t] : composante de tendance à l'instant t de meme longueur que  
# l'échantillon d'estimation  
Tt_holt <- c(0, rep(0, length(estimation) - 1))  
  
# Prevt_holt[t] : prévision à l'instant t de meme longueur que les données de départ  
Prevt_holt <- c(estimation[1], rep(0, n-1))  
  
for (t in 2:length(estimation)) {  
  St_holt[t] <- best_alpha * estimation[t] + (1 - best_alpha) * (St_holt[t-1] +  
    Tt_holt[t-1])  
  
  Tt_holt[t] <- best_beta * (St_holt[t] - St_holt[t-1]) +  
    (1 - best_beta) * Tt_holt[t-1]  
  
  Prevt_holt[t] <- St_holt[t-1] + Tt_holt[t-1]  
}  
mape_holt <- mean(abs((estimation - Prevt_holt[1:(n-12)]) / estimation)) * 100  
## Affichage du MAPE et des paramètres optimaux  
cat("MAPE pour la méthode Holt :", mape_holt, "%\n")
```

```
## MAPE pour la méthode Holt : 2.865647 %
```

```
cat("Paramètre alpha optimal :", best_alpha, "\n")
```


```
## Paramètre alpha optimal : 0.25
```

```
cat("Paramètre beta optimal :", best_beta, "\n")
```

```
## Paramètre beta optimal : 0.01
```

3.1.5 Visualisation des prévisions et données observées sur les échantillons d'estimation

```
plot(data$Date[1:(n-12)], estimation, type = "l", col = "blue", xlab = "Date",  
      ylab = "Valeur", main = "Données observées et prévisions Holt")  
lines(data$Date[1:(n-12)], Prevt_holt[1:(n-12)], col = "green")  
legend("topleft", legend = c("Données réelles", "Prévision"),  
      col = c("blue", "green"), lty = 1)
```



3.2 La méthode de Holt-Winters additive

3.2.1 Formulation théorique

La méthode de Holt-Winters additive étend la méthode de Holt en ajoutant une **composante saisonnière additive** I_t . La prévision à l'horizon h est :

$$\hat{Y}_T(h) = S_T + h \cdot T_T + I_{T+h-s}$$

où $s = 12$ est la période saisonnière (données mensuelles). Les trois composantes sont mises à jour par :

$$S_t = \alpha(Y_t - I_{t-s}) + (1 - \alpha)(S_{t-1} + T_{t-1})$$

$$T_t = \beta(S_t - S_{t-1}) + (1 - \beta)T_{t-1}$$

$$I_t = \delta(Y_t - S_t) + (1 - \delta)I_{t-s}$$

avec $0 < \alpha < 1$, $0 < \beta < 1$ et $0 < \delta < 1$.

Initialisation : Pour $t = 0, -1, \dots, -(s-1)$:

- $S_0 = \bar{Y}_{1:s}$ (moyenne des s premières observations)
- $T_0 = 0$
- $I_{-k} = Y_{s-k} - S_0$ pour $k = 0, 1, \dots, s-1$

3.2.2 Interprétation

Dans le modèle additif, la saisonnalité est exprimée en **écart absolu** par rapport au niveau. Elle est appropriée lorsque l'amplitude des oscillations saisonnières est **constante** au fil du temps (indépendante du niveau de la série).

3.2.3 Estimations des paramètres qui minimisent le MAPE

```
library(forecast)
model_hw <- hw(data_ts, seasonal = "additive", h = 12)
best_alpha_hw <- model_hw$model$par["alpha"]
best_beta_hw <- model_hw$model$par["beta"]
best_gamma_hw <- model_hw$model$par["gamma"]
```

3.2.4 Prévision à l'aide de la méthode de Holt-Winters additive

```
St_hw <- c(rep(mean(data$Valeur[1:12]), 12), rep(0, length(estimation)))
Tt_hw <- c(rep(0, 12), rep(0, length(estimation)))
It_hw <- c(rep(0, 12), rep(0, length(estimation)))
Prev_t_hw <- c(estimation[1], rep(0, n - 1))

for (i in 1:12) {
  It_hw[i] <- data$Valeur[i] - St_hw[i]
}

for (t in 13:length(St_hw)) {
  St_hw[t] <- best_alpha_hw * (estimation[t-12] - It_hw[t-12]) +
    (1 - best_alpha_hw) * (St_hw[t-1] + Tt_hw[t-1])

  Tt_hw[t] <- best_beta_hw * (St_hw[t] - St_hw[t-1]) +
    (1 - best_beta_hw) * Tt_hw[t-1]

  It_hw[t] <- best_gamma_hw * (estimation[t-12] - St_hw[t]) +
    (1 - best_gamma_hw) * It_hw[t-12]

  if(t>13) {
    Prev_t_hw[t-12] <- St_hw[t-1] + Tt_hw[t-1] + It_hw[t-12]
  }
}
```

```

}
mape_hw <- mean(abs((estimation - Prevt_hw[1:(n-12)]) / estimation)) * 100
## Affichage du MAPE et des paramètres optimaux
cat("MAPE pour la méthode Holt-Winters additive :", mape_hw, "%\n")

```

```
## MAPE pour la méthode Holt-Winters additive : 2.866428 %
```

```
cat("Paramètre alpha optimal :", best_alpha_hw, "%\n")
```

```
## Paramètre alpha optimal : 0.2340547
```

```
cat("Paramètre beta optimal :", best_beta_hw, "%\n")
```

```
## Paramètre beta optimal : 0.001595205
```

```
cat("Paramètre gamma optimal :", best_gamma_hw, "%\n")
```

```
## Paramètre gamma optimal : 0.0001000929
```


3.2.5 Visualisation des prévisions et données observées sur les échantillons d'estimation

```

plot(data$Date[1:(n-12)], estimation, type = "l", col = "blue", xlab = "Date",
      ylab = "Valeur", main = "Données observées et prévisions Holt-Winters")
lines(data$Date[1:(n-12)], Prevt_hw[1:(n-12)], col = "red")
legend("topleft", legend = c("Données réelles", "Prévision"),
      col = c("blue", "red"), lty = 1)

```

Données observées et prévisions Holt–Winters



3.3 La méthode de Holt-Winters multiplicative

3.3.1 Formulation théorique

La méthode de Holt-Winters multiplicative est adaptée aux séries dont l'amplitude saisonnière **croît proportionnellement** au niveau. La prévision à l'horizon h est :

$$\hat{Y}_T(h) = (S_T + h \cdot T_T) \times I_{T+h-s}$$

Les trois composantes sont mises à jour par :

$$S_t = \alpha \left(\frac{Y_t}{I_{t-s}} \right) + (1 - \alpha)(S_{t-1} + T_{t-1})$$

$$T_t = \beta(S_t - S_{t-1}) + (1 - \beta)T_{t-1}$$

$$I_t = \delta \left(\frac{Y_t}{S_t} \right) + (1 - \delta)I_{t-s}$$

avec $0 < \alpha < 1$, $0 < \beta < 1$ et $0 < \delta < 1$.

Initialisation : Pour $t = 0, -1, \dots, -(s-1)$:

- $S_0 = \bar{Y}_{1:s}$ (moyenne des s premières observations)
- $T_0 = 0$
- $I_{-k} = Y_{s-k}/S_0$ pour $k = 0, 1, \dots, s-1$

3.3.2 Interprétation

La différence fondamentale avec le cas additif réside dans la façon dont la saisonnalité intervient : par **multiplication** dans la prévision et par **division** dans la mise à jour du niveau. Les coefficients saisonniers I_t sont sans unité et oscillent autour de 1 (contre 0 pour le cas additif).

3.3.3 Estimations des paramètres qui minimisent le MAPE

```
model_hw_mult <- hw(data_ts, seasonal = "multiplicative", h = 12)
best_alpha_hw_mult <- model_hw_mult$model$par["alpha"]
best_beta_hw_mult <- model_hw_mult$model$par["beta"]
best_gamma_hw_mult <- model_hw_mult$model$par["gamma"]
```

3.3.4 Prévision à l'aide de la méthode de Holt-Winters multiplicative

```
St_hw_mult <- c(rep(mean(data$Valeur[1:12]), 12), rep(0, length(estimation)))
Tt_hw_mult <- c(rep(0, 12), rep(0, length(estimation)))
It_hw_mult <- c(rep(0, 12), rep(0, length(estimation)))
Prevt_hw_mult <- c(estimation[1], rep(0, n - 1))

for (i in 1:12) {
  It_hw_mult[i] <- data$Valeur[i] / St_hw_mult[i]
}

for (t in 13:length(St_hw_mult)) {
  St_hw_mult[t] <- best_alpha_hw_mult * (estimation[t-12] / It_hw_mult[t-12]) +
    (1 - best_alpha_hw_mult) * (St_hw_mult[t-1] + Tt_hw_mult[t-1])

  Tt_hw_mult[t] <- best_beta_hw_mult * (St_hw_mult[t] - St_hw_mult[t-1]) +
    (1 - best_beta_hw_mult) * Tt_hw_mult[t-1]

  It_hw_mult[t] <- best_gamma_hw_mult * (estimation[t-12] / St_hw_mult[t]) +
    (1 - best_gamma_hw_mult) * It_hw_mult[t-12]

  if(t>13) {
    Prevt_hw_mult[t-12] <- (St_hw_mult[t-1] + Tt_hw_mult[t-1])*It_hw_mult[t-12]
  }
}

mape_hw_mult <- mean(abs((estimation -
                          Prevt_hw_mult[1:(n-12)])/estimation))*100
## Affichage du MAPE et des paramètres optimaux
cat("MAPE pour la méthode Holt-Winters multiplicative :", mape_hw_mult, "%\n")

## MAPE pour la méthode Holt-Winters multiplicative : 2.916829 %
```



```
cat("Paramètre alpha optimal :", best_alpha_hw_mult, "\n")
```

```
## Paramètre alpha optimal : 0.2372037
```

```
cat("Paramètre beta optimal :", best_beta_hw_mult, "\n")
```


```
## Paramètre beta optimal : 0.001481928
```

```
cat("Paramètre gamma optimal :", best_gamma_hw_mult, "\n")
```

```
## Paramètre gamma optimal : 0.0001064867
```

3.3.5 Visualisation des prévisions et données observées sur les échantillons d'estimation

```
plot(data$Date[1:(n-12)], estimation, type = "l",  
col = "blue", xlab = "Date", ylab = "Valeur",  
main = "Données observées et prévisions Holt-Winters multiplicative")  
lines(data$Date[1:(n-12)], Prevt_hw_mult[1:(n-12)], col = "orange")  
legend("topleft", legend = c("Données réelles", "Prévision"),  
col = c("blue", "orange"), lty = 1)
```




3.4 Comparaison des méthodes de lissage

```
mape_values <- c(mape_holt, mape_hw, mape_hw_mult)
print(mape_values)
```

```
## [1] 2.865647 2.866428 2.916829
```

```
barplot(mape_values,
        names.arg = c("Holt", "HW Additif", "HW Multiplicatif"),
        col = c("green", "red", "orange"),
        main = "Comparaison des MAPE des méthodes de lissage",
        ylab = "MAPE (%)",
        ylim = c(0, max(mape_values) * 1.2))
text(x = c(0.7, 1.9, 3.1),
     y = mape_values + 0.05,
     labels = round(mape_values, 4),
     cex = 0.9)
```



3.5 choix de la meilleure méthode de lissage

D'après les résultats obtenus, la méthode holt présente le MAPE le plus faible, ce qui indique qu'elle est la meilleure méthode de lissage pour notre série temporelle. Par conséquent, nous allons utiliser la méthode holt pour faire les prévisions sur l'échantillon de prévision.

3.6 Prédiction sur l'échantillon de prévision à l'aide de la méthode holt


```
# Prédiction pour les 12 prochains mois
for(h in 1:12) {
  Prevt_holt[length(estimation) + h] <- St_holt[length(estimation)] +
  h * Tt_holt[length(estimation)]
}
#### 2.6.1 Calcul du MAPE sur l'échantillon de prévision
mape_prevision <- mean(abs((prevision -
                          Prevt_holt[(n-11):(n)])) / prevision)) * 100
cat("MAPE pour la prévision sur l'échantillon de prévision :",
mape_prevision, "%\n")
```

```
## MAPE pour la prévision sur l'échantillon de prévision : 1.895599 %
```

3.6.1 Graphique final sur l'ensemble de l'échantillon comportant les observations et les prévisions

```
plot(data$Date, data$Valeur, type = "l", col = "blue", xlab = "Date",
ylab = "Valeur", main = "Données observées et prévisions Holt")
lines(data$Date[1:(n-12)], Prevt_holt[1:(n-12)], col = "green")
lines(data$Date[(n-11):n], Prevt_holt[(n-11):n], col = "red")
legend("topleft", legend = c("Données réelles", "Prédiction (estimation)",
"Prédiction (prédiction)"), col = c("blue", "green", "red"), lty = 1)
```

Données observées et prévisions Holt




4 Partie 4 : Méthodes Box-Jenkins

4.1 Analyses de la série de l'échantillon d'estimation

4.1.1 Visuation de la série temporelle de l'échantillon d'estimation

```
plot(data$Date[1:(n-12)], estimation, type = "l", col = "blue", xlab = "Date", ylab = "Valeur",  
main = "Série temporelle de l'échantillon d'estimation")
```

Série temporelle de l'échantillon d'estimation



4.1.2 Analyse du graphique de la série

La série temporelle de l'échantillon d'estimation présente une tendance à la hausse entre 1980 et 2012 suivie d'une baisse entre 2012 et 2026. Cette tendance suggère que la série n'est pas stationnaire, ce qui est confirmé par les tests de stationnarité que nous allons effectuer par la suite.

4.1.3 Tests de stationnarité

```
library(tseries)
```

```
## Registered S3 method overwritten by 'quantmod':  
##   method      from  
##   as.zoo.data.frame zoo
```


```
estimation_ts <- ts(estimation, frequency = 12)  
adf_test <- adf.test(estimation_ts)  
print(adf_test)
```

```
##  
## Augmented Dickey-Fuller Test  
##  
## data: estimation_ts
```

```
## Dickey-Fuller = -1.1254, Lag order = 8, p-value = 0.9185
## alternative hypothesis: stationary
```

Le test de Dickey-Fuller augmenté (ADF) indique que la série n'est pas stationnaire, car la p-value est supérieure à 0.05. Par conséquent, nous allons différencier la série pour la rendre stationnaire.

```
diff_estimation_ts <- diff(estimation_ts)
plot(diff_estimation_ts, type = "l", col = "blue", xlab = "Date",
     ylab = "Différencié de la valeur",
     main = "Série temporelle différenciée de l'échantillon d'estimation")
```



```
adf_test_diff <- adf.test(diff_estimation_ts)
```

```
## Warning in adf.test(diff_estimation_ts): p-value smaller than printed p-value
```


```
print(adf_test_diff)
```

```
##
## Augmented Dickey-Fuller Test
##
## data: diff_estimation_ts
## Dickey-Fuller = -10.916, Lag order = 8, p-value = 0.01
## alternative hypothesis: stationary
```

Après différenciation, le test ADF indique que la série est désormais stationnaire, car la p-value est inférieure à 0.05. Nous pouvons donc procéder à l'identification du modèle ARMA pour la série différenciée.


4.1.4 Identification du modèle ARMA

```
library(forecast)
acf(diff_estimation_ts, main = "ACF de la série différenciée")
```



```
pacf(diff_estimation_ts, main = "PACF de la série différenciée")
```

PACF de la série différenciée



L'analyse de la fonction d'autocorrélation (ACF) de la série différenciée montre un pic significatif au retard 1, suivi d'une extinction rapide des autocorrélations.

La fonction d'autocorrélation partielle (PACF) ne présente pas de coupure nette mais une décroissance progressive.

Ces résultats suggèrent que la série suit un processus MA(1), ce qui conduit à considérer un modèle final : ARIMA(0,1,1).

4.1.5 Confirmation et sélection du modèle final

4.1.5.1 Étape 1 : Test du modèle initial ARIMA(0,1,1) L'analyse des ACF et PACF suggérait un modèle ARIMA(0,1,1). Nous estimons ce modèle et testons la qualité de ses résidus via le test de Ljung-Box.

```
# Estimation du modèle initial
model_011 <- arima(estimation_ts, order = c(0,1,1))
print(model_011)
```

```
##
## Call:
## arima(x = estimation_ts, order = c(0, 1, 1))
##
## Coefficients:
##          ma1
##        -0.7242
## s.e.      0.0318
```



```
##
## sigma^2 estimated as 0.03097: log likelihood = 171.57, aic = -339.14
```

```
# Test de Ljung-Box sur les résidus
lb_011 <- Box.test(model_011$residuals, lag = 20, type = "Ljung-Box")
cat("Ljung-Box ARIMA(0,1,1) - statistique X² =", round(lb_011$statistic, 3),
    "| p-value =", round(lb_011$p.value, 4), "\n")
```

```
## Ljung-Box ARIMA(0,1,1) - statistique X² = 37.553 | p-value = 0.01
```

La p-value du test de Ljung-Box est $0.010 < 0.05$: on rejette H_0 , les résidus présentent encore de l'autocorrélation. Le modèle ARIMA(0,1,1) n'est donc **pas validé** et nous devons explorer des modèles plus complexes.

4.1.5.2 Étape 2 : Comparaison de modèles candidats Nous comparons six modèles ARIMA sur la base de l'AIC et du test de Ljung-Box (lag = 20) afin de sélectionner le meilleur candidat.

```
modeles <- list(
  "ARIMA(0,1,1)" = arima(estimation_ts, order = c(0,1,1)),
  "ARIMA(1,1,1)" = arima(estimation_ts, order = c(1,1,1)),
  "ARIMA(0,1,2)" = arima(estimation_ts, order = c(0,1,2)),
  "ARIMA(1,1,2)" = arima(estimation_ts, order = c(1,1,2)),
  "ARIMA(2,1,1)" = arima(estimation_ts, order = c(2,1,1)),
  "ARIMA(2,1,2)" = arima(estimation_ts, order = c(2,1,2))
)

resultats <- data.frame(
  Modele      = names(modeles),
  AIC         = sapply(modeles, AIC),
  LjungBox_pvalue = sapply(modeles, function(m) {
    Box.test(m$residuals, lag = 20, type = "Ljung-Box")$p.value
  })
)

resultats$Residus <- ifelse(resultats$LjungBox_pvalue > 0.05,
  "Bruit blanc", "Autocorrele")
resultats <- resultats[order(resultats$AIC), ]

knitr::kable(resultats,
  caption = "Comparaison des modèles ARIMA candidats",
  digits = 4,
  col.names = c("Modèle", "AIC", "p-value Ljung-Box", "Résidus"),
  row.names = FALSE)
```

Table 4: Comparaison des modèles ARIMA candidats

Modèle	AIC	p-value Ljung-Box	Résidus
ARIMA(1,1,2)	-340.6932	0.0629	Bruit blanc
ARIMA(2,1,2)	-340.2780	0.0721	Bruit blanc
ARIMA(0,1,2)	-339.7403	0.0493	Autocorrele
ARIMA(1,1,1)	-339.7331	0.0498	Autocorrele
ARIMA(0,1,1)	-339.1385	0.0100	Autocorrele

Modèle	AIC	p-value	Ljung-Box	Résidus
ARIMA(2,1,1)	-337.7333		0.0498	Autocorrele

Seuls **ARIMA(1,1,2)** (AIC = -340.69, p = 0.063) et **ARIMA(2,1,2)** (AIC = -340.28, p = 0.072) produisent des résidus non autocorrélés. ARIMA(1,1,2) est préféré sur la base de l'AIC le plus faible.

```
model_112 <- arima(estimation_ts, order = c(1,1,2))

coefs_112 <- model_112$coef
se_112 <- sqrt(diag(model_112$var.coef))
tstat_112 <- coefs_112 / se_112
pval_112 <- 2 * (1 - pnorm(abs(tstat_112)))

knitr::kable(data.frame(
  Coefficient = round(coefs_112, 5),
  Std_Error = round(se_112, 5),
  t_stat = round(tstat_112, 3),
  p_value = round(pval_112, 4),
  Significatif = ifelse(pval_112 < 0.05, "Oui", "Non")
), caption = "Significativité des coefficients ARIMA(1,1,2)",
  row.names = TRUE)
```

4.1.5.3 Étape 3 : Vérification des coefficients ARIMA(1,1,2)

Table 5: Significativité des coefficients ARIMA(1,1,2)

	Coefficient	Std_Error	t_stat	p_value	Significatif
ar1	-0.84863	0.15094	-5.622	0.0000	Oui
ma1	0.16508	0.13533	1.220	0.2225	Non
ma2	-0.66679	0.08760	-7.612	0.0000	Oui

Le coefficient **ma1** n'est pas significatif (p = 0.22 > 0.05). Conformément au **principe de parcimonie**, nous estimons un modèle contraint en fixant ma1 = 0, ne conservant que les paramètres ar1 et ma2.

```
model_contraint <- arima(estimation_ts,
  order = c(1,1,2),
  include.mean = FALSE,
  fixed = c(NA, 0, NA))

# Extraire uniquement les paramètres non fixés
coefs <- model_contraint$coef[c("ar1", "ma2")]
se <- sqrt(diag(model_contraint$var.coef))
t_stat <- coefs / se
p_values <- 2 * (1 - pnorm(abs(t_stat)))
```

```
knitr::kable(data.frame(
  Coefficient = round(coefs, 5),
  Std_Error   = round(se, 5),
  t_stat      = round(t_stat, 3),
  p_value     = round(p_values, 4),
  Significatif = ifelse(p_values < 0.05, "Oui", "Non")
), caption = "Coefficients du modèle final ARIMA(1,1,2) contraint (ma1 = 0)",
  row.names = TRUE)
```

4.1.5.4 Étape 4 : Modèle contraint ARIMA(1,1,2) avec $ma1 = 0$

Table 6: Coefficients du modèle final ARIMA(1,1,2) contraint ($ma1 = 0$)

	Coefficient	Std_Error	t_stat	p_value	Significatif
ar1	-0.67435	0.03764	-17.917	0	Oui
ma2	-0.56048	0.04398	-12.744	0	Oui

```
lb_contraint <- Box.test(model_contraint$residuals, lag = 20, type = "Ljung-Box")
cat("AIC du modèle contraint :", round(AIC(model_contraint), 4), "\n")
```

```
## AIC du modèle contraint : -341.9533
```


```
cat("Ljung-Box -  $X^2$  =", round(lb_contraint$statistic, 3),
    "| p-value =", round(lb_contraint$p.value, 4), "\n")
```

```
## Ljung-Box -  $X^2$  = 29.601 | p-value = 0.0766
```


Les deux coefficients **ar1** et **ma2** sont hautement significatifs ($p < 0.001$). La p-value du test de Ljung-Box est supérieure à 0.05 : les résidus constituent un **bruit blanc**. Le modèle est donc validé.

```
par(mfrow = c(1, 2))
acf(model_contraint$residuals,
    main = "ACF des résidus
    ARIMA(1,1,2) contraint")
pacf(model_contraint$residuals,
    main = "PACF des résidus
    ARIMA(1,1,2) contraint")
```

**ACF des résidus
ARIMA(1,1,2) contraint**



**PACF des résidus
ARIMA(1,1,2) contraint**



```
par(mfrow = c(1, 1))
```

Le modèle final retenu s'écrit :

$$(1 + 0.674B)(1 - B)X_t = (1 - 0.560B^2)\varepsilon_t$$

où B est l'opérateur retard, $\hat{\phi}_1 = -0.674$ le coefficient autorégressif et $\hat{\theta}_2 = -0.560$ le coefficient de moyenne mobile d'ordre 2.

4.2 Prévision à l'aide du modèle ARIMA(1,1,2) contraint

4.2.1 Prévision des 12 dernières observations

```
forecast_arima <- forecast(model_contraint, h = 12)
Prev_arima     <- forecast_arima$mean
```

4.2.2 Calcul du MAPE sur l'échantillon de prévision


```
mape_arima <- mean(abs((prevision - Prev_arima) / prevision)) * 100
cat("MAPE - ARIMA(1,1,2) contraint :", round(mape_arima, 4), "%\n")
```

```
## MAPE - ARIMA(1,1,2) contraint : 1.888 %
```

4.3 Comparaison des prévisions : lissage vs Box-Jenkins

4.3.1 Graphique des observations et des prévisions

```
plot(data$Date, data$Valeur, type = "l", col = "blue",  
      xlab = "Date", ylab = "Valeur (milliards d'euros)",  
      main = "Observations et previsions (1980-2026)")  
lines(data$Date[(n-11):n], Prevt_holt[(n-11):n], col = "red", lwd = 2)  
lines(data$Date[(n-11):n], as.numeric(Prev_arima), col = "green", lwd = 2)  
legend("topleft", legend = c("Observations", "Holt", "ARIMA(1,1,2)"),  
      col = c("blue", "red", "green"), lty = 1)
```



4.3.2 Tableau comparatif des prévisions et MAPE

```
comparaison_data <- data.frame(  
  Date = format(data$Date[(n-11):n], "%Y-%m"),  
  Observe = round(prevision, 3),  
  Prevision_Holt = round(Prevt_holt[(n-11):n], 3),  
  Prevision_ARIMA = round(as.numeric(Prev_arima), 3),  
  Erreur_Holt = round(abs(prevision - Prevt_holt[(n-11):n])  
    / prevision * 100, 2),  
  Erreur_ARIMA = round(abs(prevision - as.numeric(Prev_arima))
```

```

/ prevision * 100, 2)
)

knitr::kable(comparaison_data,
  caption = "Prévisions sur les 12 dernières observations (milliards d'euros)",
  col.names = c("Date", "Observe (Md euros)", "Holt",
    "ARIMA(1,1,2) contraint",
    "Erreur Holt (%)", "Erreur ARIMA (%)"),
  row.names = FALSE)

```

Table 7: Prévisions sur les 12 dernières observations (milliards d'euros)

Date	Observe (Md euros)	Holt	ARIMA(1,1,2) contraint	Erreur Holt (%)	Erreur ARIMA (%)
2025-02	4.700	4.592	4.594	2.30	2.26
2025-03	4.589	4.591	4.598	0.05	0.20
2025-04	4.200	4.590	4.595	9.29	9.41
2025-05	4.442	4.589	4.597	3.32	3.49
2025-06	4.597	4.589	4.596	0.18	0.03
2025-07	4.581	4.588	4.597	0.15	0.34
2025-08	4.574	4.587	4.596	0.28	0.48
2025-09	4.603	4.586	4.596	0.37	0.14
2025-10	4.721	4.585	4.596	2.88	2.64
2025-11	4.602	4.584	4.596	0.38	0.12
2025-12	4.450	4.584	4.596	3.00	3.29
2026-01	4.608	4.583	4.596	0.55	0.25

```

# Tableau des MAPE
knitr::kable(data.frame(
  Methode = c("Holt (meilleur lissage)",
    "ARIMA(1,1,2) contraint (ma1 = 0)"),
  MAPE_prevision = paste0(round(c(mape_prevision, mape_arima), 4), " %")
), caption = "MAPE sur l'échantillon de prevision (12 observations)",
  col.names = c("Methode", "MAPE"),
  row.names = FALSE)

```

Table 8: MAPE sur l'échantillon de prevision (12 observations)

Methode	MAPE
Holt (meilleur lissage)	1.8956 %
ARIMA(1,1,2) contraint (ma1 = 0)	1.888 %

4.4 Conclusion

Ce travail a porté sur l'analyse et la prévision de la consommation mensuelle des ménages en énergie, eau et déchets (idBank INSEE 011794485) sur la période janvier 1980 – janvier 2026, à l'aide de deux approches : le **lissage exponentiel** (méthodes de Holt et Holt-Winters) et la **modélisation Box-Jenkins** (ARIMA).

Stratégie Box-Jenkins : L'identification a suivi une démarche progressive en quatre étapes : (1) test ADF confirmant la non-stationnarité ($p = 0.919$), (2) différenciation d'ordre 1 rendant la série stationnaire ($p <$

0.01), (3) lecture des ACF/PACF suggérant $\text{ARIMA}(0,1,1)$, invalidé par le test de Ljung-Box ($p = 0.010$), (4) comparaison de six modèles candidats conduisant au modèle contraint $\text{ARIMA}(1,1,2)$ avec $\text{ma1} = 0$, dont tous les coefficients sont significatifs et les résidus constituent un bruit blanc.

Comparaison finale : Sur l'échantillon de prévision (12 dernières observations), la méthode **$\text{ARIMA}(1,1,2)$ contraint ($\text{ma1} = 0$)** présente le MAPE le plus faible (**1.888 %** contre 1.896 % pour l'autre approche) et constitue donc la **méthode retenue**.

Sur la méthode Holt : Sa simplicité (deux paramètres) la rend robuste pour des séries à tendance linéaire stable. Elle est adaptée au court terme mais ne capture pas les effets saisonniers résiduels.

Sur le modèle $\text{ARIMA}(1,1,2)$ contraint : Ce modèle, sélectionné après une stratégie d'identification rigoureuse, capture efficacement la structure de dépendance à court terme de la série différenciée. La contrainte $\text{ma1} = 0$ garantit la parcimonie et la significativité de tous les paramètres estimés.

Perspective d'amélioration : Compte tenu du profil de la série (tendance non linéaire, saisonnalité résiduelle possible), une extension naturelle serait d'explorer un modèle **$\text{SARIMA}(\mathbf{p},\mathbf{d},\mathbf{q})(\mathbf{P},\mathbf{D},\mathbf{Q})_{12}$** , capable de modéliser explicitement la composante saisonnière et susceptible d'améliorer la qualité des prévisions à moyen terme.