


Séries temporelles et méthodes de prévision

Université de Lille

Introduction

Série temporelle ou chronologique :

- Suite d'observations indicées par le temps.
- série chronologique = série temporelle = chronique
- Objectif : décrire l'évolution d'un phénomène, l'expliquer, le modéliser, formuler des prévisions.
- L'ordre dans lequel on observe les données est très important
- Joindre les points du graphique
- **Processus stochastique ou aléatoire :**
 - temps discret : $Y_1, Y_2, \dots, Y_t, \dots$
 - temps continu : $\{Y_t, t > 0\}$
- Série temporelle = réalisation d'un processus stochastique.




Communiqué de presse du CCFA du 3 août 2009

- Juillet 2009 : + 3,1%. En juillet 2009, avec 188 635 immatriculations, le marché français des voitures particulières neuves est en hausse de 3,1% avec le même nombre de jours ouvrables par rapport à juillet 2008 (22 jours en 2009 comme en 2008).
- 7 MOIS 2009 (Janvier à juillet) : +0,6% / +2,0% c.j.o. Sur le cumul de janvier à juillet, avec 1 319 950 immatriculations, le marché français des voitures particulières neuves est stable (+0,6%) en données brutes et en hausse de 2,0% à nombre de jours ouvrables comparable par rapport à la même période de 2008 (145 jours en 2009 et 147 jours en 2008).

L'interprétation des chiffres n'est donc pas toujours directe. Ici, le CCFA tient compte du nombre de jours ouvrables du mois pour effectuer des comparaisons.


Le CCFA publie la mise à jour de cette série le 1er jour ouvrable de chaque mois à 12h. Le lendemain, l'INSEE publie une autre série, après un traitement de correction des jours ouvrables et des variations saisonnières.

**Nombre d'immatriculations de voitures particulières neuves en France, en milliers,
série corrigée pour les jours ouvrables et pour les variations saisonnières**



Communiqué de l'INSEE - Juillet 2009

En juillet 2009, les immatriculations de voitures particulières neuves baissent de 1,9% par rapport à juin 2009 (174 913 contre 178 346 véhicules) en données corrigées des effets de jours ouvrables et des variations saisonnières (CVS-CJO). Par rapport au mois de juillet 2008, le chiffre brut progresse de 3,1% (188 635 contre 182 954 véhicules).

Nombre d'immatriculations de voitures particulières neuves en France, en milliers

Les composantes d'une série chronologique

Les deux séries :

- informent sur la même variable
- sont très différentes

Représenter l'évolution d'un indicateur économique n'est pas une démarche aussi directe et simple qu'il peut y paraître à première vue.

Classiquement, on utilisait des **méthodes de décomposition**.
Celles-ci considèrent qu'une série possède plusieurs **composantes** :

- La tendance, le cycle
- Le mouvement saisonnier
- Les variations accidentelles - les valeurs aberrantes

La tendance, le cycle


La **tendance** donne une idée du comportement global de la série, de son évolution durable (par exemple globalement croissante ou décroissante). Pour les séries économiques, on distingue la tendance du cycle (par exemple : "croissance, dépression").


Pour distinguer la tendance du cycle, il faut disposer de données sur une très longue période. Les mouvements cycliques ont le plus souvent une amplitude de plusieurs années.

Le mouvement saisonnier

Il est dû au rythme des saisons, des facteurs humains, etc. Les fluctuations sont assez régulières sur une période assez courte, par exemple une semaine, une année.

Le nombre d'observations sur cette période est appelée la saison. Un mouvement saisonnier annuel sur données mensuelles correspond à une saison égale à 12. On obtient la saison en comptant le nombre de périodes séparant les pics et/ou les creux.



Nombre de passagers sur les lignes aériennes internationales, en milliers

- Tendence croissante
- Mouvement saisonnier de période 12
- Pics tous les étés en juillet et en août et creux en novembre
- Amplitude croissante du mouvement saisonnier

Les variations accidentelles - les valeurs aberrantes

Variations ponctuelles correspondant à des évènements extérieurs qui ont influencé la valeur de la variable, comme les grèves, les guerres, les sécheresses, etc.

Attention aux erreurs de calcul ou de saisie (correction des valeurs)


Sinon, lorsque les phénomènes exceptionnels à l'origine des valeurs aberrantes ne sont pas au coeur de la problématique de l'étude, on corrige la série pour faire comme si ces évènements ne s'étaient pas produits.

Tableaux de Buys-Ballot

- Pour les séries présentant à la fois tendance et mouvement saisonnier
- Tableau donnant deux dimensions au temps : une dimension annuelle et une dimension mensuelle.
- Il s'accompagne souvent d'un graphique où chaque année donne lieu à une courbe.


	1949	1950	1951	1952	1953	1954	1955	1956	1957	1958	1959	1960	moyenne
janv.	112	115	145	171	196	204	242	284	315	340	360	417	242
févr.	118	126	150	180	196	188	233	277	301	318	342	391	235
mars	132	141	178	193	236	235	267	317	356	362	406	419	270
avril	129	135	163	181	235	227	269	313	348	348	396	461	267
mai	121	125	172	183	229	234	270	318	355	363	420	472	272
juin	135	149	178	218	243	264	315	374	422	435	472	535	312
juillet	148	170	199	230	264	302	364	413	465	491	548	622	351
août	148	170	199	242	272	293	347	405	467	505	559	606	351
sept.	136	158	184	209	237	259	312	355	404	404	463	508	302
oct.	119	133	162	191	211	229	274	306	347	359	407	461	267
nov.	104	114	146	172	180	203	237	271	305	310	362	390	233
déc.	118	140	166	194	201	229	278	306	336	337	405	432	262
moyenne	127	140	170	197	225	239	284	328	368	381	428	476	

Nombre de passagers transportés sur les lignes aériennes internationales, en milliers



Profil saisonnier assez similaire.

Nombre d'immatriculations de voitures particulières neuves en France, en milliers



Les modèles classiques de décomposition d'une chronique

Considérons une série $(X_t, t = 1, \dots, T)$. Le modèle classique de décomposition est :

$$X_t = T_t + I_t + \varepsilon_t$$

où

- T_t est une tendance déterministe (composante fondamentale)
- I_t est une composante saisonnière déterministe
- ε_t est la composante résiduelle aléatoire.

On peut généraliser ce modèle classique : $X_t = f(t, \varepsilon_t)$.

La décomposition peut se faire, principalement, selon les schémas suivants

- additif : $X_t = T_t + I_t + \varepsilon_t$
- multiplicatif : $X_t = T_t \times I_t \times \varepsilon_t$
- mixte : $X_t = T_t \times I_t + \varepsilon_t$

La tendance et la saisonnalité ne sont pas toujours faciles à détecter. Parfois, elles n'apparaissent qu'après avoir transformé les données.


Choix entre modèles additif et multiplicatif : On préconise de tracer deux courbes joignant les maxima (minima) distants de s périodes. Si ces deux courbes sont à peu près parallèles, on choisit un modèle additif.


Un passage au logarithme du modèle multiplicatif le ramène à un modèle additif :

$$\log(X_t) = \log(T_t) + \log(I_t) + \log(\varepsilon_t)$$

Pour la série du nombre de passagers transportés sur les lignes aériennes internationales, un modèle multiplicatif est plus adapté.

Nombre de passagers transportés sur les lignes aériennes internationales, en milliers



Nombre de passagers sur les lignes aériennes internationales, en milliers, en log

Détermination de la tendance (ou courbe de croissance)

C'est une fonction régulière du temps :

- La droite : $T_t = a + b.t$
- La tendance quadratique : $T_t = a + b.t + c.t^2$
- La tendance polynomiale d'ordre p : $T_t = a_0 + a_1.t + \dots + a_p.t^p$
- La tendance logarithmique : $T_t = a + b.\log(t)$
- La tendance exponentielle : $T_t = a.b^t + c$
- La tendance de Gompertz : $T_t = e^{a.b^t+c}$
- La tendance logistique : $T_t = \frac{1}{a.b^t+c}$

Ces courbes sont obtenues par moindres carrés ordinaires ou par des méthodes spécifiques.


Par exemple, pour la droite de tendance :

$$\min_{a,b} \sum_{t=1}^T (X_t - a - b.t)^2$$

certaines sont disponibles directement dans Excel.

On peut aussi les estimer à l'aide d'un logiciel statistique comme *R*, Gretl, SAS etc.

Sur Excel



Avec *R*

```
*****
> BJSERG<-read.table("C:/BJSERG.TXT",header=TRUE)
> Trend<-1:144
> DATABJ<-data.frame(Trend,BJSERG)
> ts(data=DATABJ,start=c(1949,1),frequency=12)
> BJ.lm<-lm(BJ ~ 1+Trend,data=BJSERG)
> summary(BJ.lm)
```

Call:

```
lm(formula = BJ ~ 1 + Trend, data = BJSERG)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	87.65278	7.71635	11.36	<2e-16 ***
Trend	2.65718	0.09233	28.78	<2e-16 ***

Pour une courbe de croissance quadratique : $T_t = a + b.t + c.t^2$

```
*****
> BJSERG<-read.table("C:/BJSERG.TXT",header=TRUE)
> Trend<-1:144
> Trend2<-Tr*Tr
> DATABJ<-data.frame(Trend,Trend2,BJSERG)
> ts(data=DATABJ,start=c(1949,1),frequency=12)
> BJ.lm<-lm(BJ~1+Trend+Trend2,data=BJSERG)
> summary(BJ.lm)
Call:
lm(formula = BJ ~ 1 + Tr + Tr2, data = BJSERG)
```


Coefficients:


	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.124e+02	1.138e+01	9.872	< 2e-16 ***
Trend	1.641e+00	3.625e-01	4.527	1.26e-05 ***
Trend2	7.008e-03	2.421e-03	2.894	0.00441 **


```
*****
```

On peut augmenter le nombre de paramètres :

$$T_t = a_0 + a_1.t + a_2.t^2 + \dots + a_p.t^p$$







Détermination d'une courbe de tendance par filtrage par moyenne mobile

On calcule la moyenne des données adjacentes :

- Moyenne mobile d'ordre 3

$$T_t = \frac{1}{3} (X_{t-1} + X_t + X_{t+1})$$

- Moyenne mobile d'ordre 5

$$T_t = \frac{1}{5} (X_{t-2} + X_{t-1} + X_t + X_{t+1} + X_{t+2})$$

- Moyenne mobile d'ordre 4

$$T_t = \frac{1}{4} \left(\frac{1}{2} X_{t-2} + X_{t-1} + X_t + X_{t+1} + \frac{1}{2} X_{t+2} \right)$$

Moyenne mobile d'ordre p :

- p impair

$$T_t = \frac{1}{p} \left(X_{t-(p-1)/2} + \cdots + X_{t+(p-1)/2} \right)$$

- p pair


$$T_t = \frac{1}{p} \left(\frac{1}{2} X_{t-p/2} + X_{t-p/2+1} + \cdots + X_{t+p/2} + \frac{1}{2} X_{t+p/2} \right)$$


Pour des données mensuelles, on considère la moyenne d'ordre 12 :


$$T_t = \frac{1}{24}X_{t-6} + \frac{1}{12}(X_{t-5} + \cdots + X_{t+5}) + \frac{1}{24}X_{t+6}$$

La moyenne mobile a un effet lissant sur la série, elle "rabote" les irrégularités. Elle atténue, voire élimine les mouvements saisonniers.

Notons qu'on ne disposera pas des valeurs de la tendance pour les premières et les dernières dates.







Les variations saisonnières

Pour estimer les variations saisonnières, on peut commencer par enlever la tendance :

- pour le modèle additif : $X_t - T_t$
- pour le modèle multiplicatif : X_t / T_t

On reporte ensuite ces valeurs sans tendance sur le tableau de Buys-Ballot qui va servir à calculer les coefficients saisonniers I_t .

Modèle additif pour les données CCFA d'immatriculations, avec une tendance moyenne mobile d'ordre 12.

Tableau des données brutes X_t :

	2000	2001	2002	2003	2004	2005	2006	2007	2008	2009
janv.	169,634	191,203	192,089	175,107	154,193	164,116	168,589	171,651	162,116	149,372
févr.	181,552	177,412	173,064	159,385	155	159,642	160,537	157,672	175,126	152,066
mars	211,015	210,285	198,302	187,159	197,691	202,475	197,376	189,87	188,879	204,018
avril	185,264	201,359	207,891	180,784	173,612	194,651	181,647	172,621	198,558	184,475
mai	196,549	203,831	186,265	161,779	169,545	183,462	177,343	172,32	184,463	206,247
juin	183,697	220,321	200,835	204,946	217,797	223,397	223,737	216,476	219,754	235,137
juillet	186,842	208,338	199,321	187,287	168,408	159,465	151,549	183,34	182,954	188,635
août	156,576	148,165	121,781	103,055	105,795	113,843	113,955	111,249	103,35	
sept.	150,191	153,044	153,069	155,41	154,328	165,698	143,634	148,164	160,565	
oct.	184,721	198,527	188,209	184,643	169,585	159,668	173,137	188,877	174,939	
nov.	176,351	182	164,789	149,236	175,966	172,003	158,296	169,757	145,893	
déc.	151,492	160,247	159,456	160,455	171,82	169,369	150,749	182,548	153,686	

Les valeurs des tendances moyenne mobile d'ordre 12 : T_t

	2000	2001	...	2006	2007	2008	2009
janv.		185,111	...	170,443	165,652	176,053	171,295
févr.		185,656	...	170,118	166,864	175,708	
mars		185,425	...	169,203	166,940	175,896	
avril		186,119	...	168,845	167,785	175,832	
mai		186,929	...	168,835	168,918	174,256	
juin		187,530	...	167,488	170,720	172,060	
juillet	178,722	187,931	...	166,840	171,648	170,326	
août	179,449	187,787	...	166,848	171,978	168,834	
sept.	179,246	187,107	...	166,416	172,664	168,504	
oct.	179,886	186,879	...	165,727	173,703	168,548	
nov.	180,860	186,420	...	165,142	175,290	168,869	
déc.	182,689	184,876	...	164,630	175,933	170,418	

Les données sans tendance $X_t - T_t$

	2000	2001	...	2006	2007	2008	2009	moyenne	I_t
janv.		6,09	...	-1,854	5,999	-13,937	-21,923	-3,732	-3,716
févr.		-8,24	...	-9,581	-9,192	-0,582		-8,814	-8,798
mars		24,86	...	28,173	22,930	12,983		23,184	23,200
avril		15,24	...	12,802	4,836	22,727		15,566	15,583
mai		16,90	...	8,508	3,402	10,207		6,762	6,778
juin		32,79	...	56,249	45,756	47,695		42,941	42,957
juil.	8,12	20,41	...	-15,291	11,692	12,628		7,411	7,427
août	-22,87	-39,62	...	-52,893	-60,729	-65,484		-53,441	-53,424
sept.	-29,05	-34,06	...	-22,782	-24,500	-7,939		-19,235	-19,218
oct.	4,83	11,65	...	7,410	15,174	6,391		7,268	7,285
nov.	-4,51	-4,42	...	-6,846	-5,533	-22,976		-6,997	-6,980
déc.	-31,20	-24,63	...	-13,881	6,615	-16,732		-11,110	-11,093
							moyenne	-0,017	0,000

- On calcule la moyenne des données sans tendance pour chaque mois
- On corrige les coefficients obtenus pour qu'ils aient une moyenne nulle (principe de conservation des aires).
- On obtient les coefficients saisonniers I_t en soustrayant $-0,017$ aux moyennes mensuelles.

Les coefficients I_t s'appliquent de manière égale tous les ans :


$$I_1 = I_{13} = I_{25} = \dots = I_{Janvier} = -3,716$$

$$I_2 = I_{14} = I_{26} = \dots = I_{Février} = -8,798$$

etc. avec $\frac{1}{12} \sum_{t=1}^{12} I_t = 0$.

Pour obtenir la série corrigées variations saisonnières (CVS), on calcule $X_t - I_t$:

	2000	2001	...	2006	2007	2008	2009
janv.	173,350	194,919	...	172,305	175,367	165,832	153,088
févr.	190,350	186,210	...	169,335	166,470	183,924	160,864
mars	187,815	187,085	...	174,176	166,670	165,679	180,818
avril	169,681	185,776	...	166,064	157,038	182,975	168,892
mai	189,771	197,053	...	170,565	165,542	177,685	199,469
juin	140,740	177,364	...	180,780	173,519	176,797	192,180
juillet	179,415	200,911	...	144,122	175,913	175,527	181,208
août	210,000	201,589	...	167,379	164,673	156,774	
sept.	169,409	172,262	...	162,852	167,382	179,783	
oct.	177,436	191,242	...	165,852	181,592	167,654	
nov.	183,331	188,980	...	165,276	176,737	152,873	
déc.	162,585	171,340	...	161,842	193,641	164,779	

Nombre d'immatriculations de voitures particulières neuves en France, en milliers

Modèle multiplicatif pour les passagers des lignes aériennes internationales, avec une droite de tendance MCO. Tableau des données brutes X_t .

	1949	1950	1951	1952	1953	1954	1955	1956	1957	1958	1959	1960
janv.	112	115	145	171	196	204	242	284	315	340	360	417
févr.	118	126	150	180	196	188	233	277	301	318	342	391
mars	132	141	178	193	236	235	267	317	356	362	406	419
avril	129	135	163	181	235	227	269	313	348	348	396	461
mai	121	125	172	183	229	234	270	318	355	363	420	472
juin	135	149	178	218	243	264	315	374	422	435	472	535
juillet	148	170	199	230	264	302	364	413	465	491	548	622
août	148	170	199	242	272	293	347	405	467	505	559	606
sept.	136	158	184	209	237	259	312	355	404	404	463	508
oct.	119	133	162	191	211	229	274	306	347	359	407	461
nov.	104	114	146	172	180	203	237	271	305	310	362	390
déc.	118	140	166	194	201	229	278	306	336	337	405	432

Les valeurs des tendances : $T_t = 87,6528 + 2,65718.t$

	1949	1950	1951	...	1956	1957	1958	1959	1960
janv.	90,31	122,20	154,08	...	313,51	345,40	377,29	409,17	441,06
févr.	92,97	124,85	156,74	...	316,17	348,06	379,94	411,83	443,71
mars	95,62	127,51	159,40	...	318,83	350,71	382,60	414,49	446,37
avril	98,28	130,17	162,05	...	321,48	353,37	385,26	417,14	449,03
mai	100,94	132,82	164,71	...	324,14	356,03	387,91	419,80	451,69
juin	103,60	135,48	167,37	...	326,80	358,69	390,57	422,46	454,34
juillet	106,25	138,14	170,03	...	329,46	361,34	393,23	425,11	457,00
août	108,91	140,80	172,68	...	332,11	364,00	395,89	427,77	459,66
sept.	111,57	143,45	175,34	...	334,77	366,66	398,54	430,43	462,32
oct.	114,22	146,11	178,00	...	337,43	369,31	401,20	433,09	464,97
nov.	116,88	148,77	180,65	...	340,08	371,97	403,86	435,74	467,63
déc.	119,54	151,43	183,31	...	342,74	374,63	406,51	438,40	470,29

Les données sans tendance : X_t/T_t

	1949	1950	1951	...	1957	1958	1959	1960	moyenne	I_t
janv.	1,24	0,94	0,94	...	0,91	0,90	0,88	0,95	0,93	0,92
févr.	1,27	1,01	0,96	...	0,86	0,84	0,83	0,88	0,91	0,90
mars	1,38	1,11	1,12	...	1,02	0,95	0,98	0,94	1,03	1,02
avril	1,31	1,04	1,01	...	0,98	0,90	0,95	1,03	1,00	0,99
mai	1,20	0,94	1,04	...	1,00	0,94	1,00	1,04	0,99	0,98
juin	1,30	1,10	1,06	...	1,18	1,11	1,12	1,18	1,12	1,11
juillet	1,39	1,23	1,17	...	1,29	1,25	1,29	1,36	1,24	1,23
août	1,36	1,21	1,15	...	1,28	1,28	1,31	1,32	1,23	1,21
sept.	1,22	1,10	1,05	...	1,10	1,01	1,08	1,10	1,06	1,05
oct.	1,04	0,91	0,91	...	0,94	0,89	0,94	0,99	0,92	0,91
nov.	0,89	0,77	0,81	...	0,82	0,77	0,83	0,83	0,80	0,79
déc.	0,99	0,92	0,91	...	0,90	0,83	0,92	0,92	0,89	0,88
	moyenne								1,01	1,00

- On calcule la moyenne des données sans tendance pour chaque mois
- On corrige les coefficients obtenus pour qu'ils aient une moyenne égale à 1 (principe de conservation des aires).
- On obtient donc les coefficients saisonniers I_t en divisant par 1,01 les moyennes mensuelles.

Les coefficients I_t s'appliquent de manière égale tous les ans :

$$I_1 = I_{13} = I_{25} = \dots = I_{Janvier} = 0,92$$


$$I_2 = I_{14} = I_{26} = \dots = I_{Février} = 0,91$$

etc. avec $\frac{1}{12} \sum_{t=1}^{12} I_t = 1$.

Pour obtenir la série corrigée des variations saisonnières (CVS), on calcule X_t/I_t :

	1949	1950	...	1955	1956	1957	1958	1959	1960
janv.	121,56	124,81	...	262,65	308,23	341,87	369,01	390,71	452,58
févr.	130,75	139,62	...	258,19	306,94	333,54	352,37	378,97	433,26
mars	129,01	137,81	...	260,95	309,82	347,94	353,80	396,81	409,51
avril	130,48	136,55	...	272,09	316,59	351,99	351,99	400,54	466,29
mai	123,19	127,26	...	274,88	323,75	361,42	369,56	427,59	480,53
juin	121,93	134,57	...	284,50	337,78	381,13	392,88	426,29	483,19
juillet	120,64	138,58	...	296,71	336,66	379,04	400,24	446,70	507,02
août	121,94	140,07	...	285,91	333,69	384,78	416,09	460,58	499,30
sept.	129,67	150,64	...	297,47	338,47	385,19	385,19	441,44	484,35
oct.	130,45	145,80	...	300,36	335,44	380,38	393,54	446,16	505,35
nov.	131,75	144,42	...	300,23	343,31	386,38	392,71	458,59	494,06
déc.	133,49	158,38	...	314,49	346,17	380,11	381,24	458,17	488,71

Nombre de passagers transportés sur les lignes aériennes internationales, en milliers



Une fois la série corrigée des variations saisonnières, on ré-évalue la tendance. On peut ensuite évaluer à nouveau les coefficients saisonniers, recalculer une nouvelle série CVS, etc. Il est rarement

utile de faire ces opérations plus de deux fois. Par exemple, on peut ré-évaluer la tendance sur la série CVS. On obtient la droite des moindres carrés :

$$T_t = 87,77 + 2,6544.t$$

très proche de celle qui avait été obtenue avant la désaisonnalisation :

$$T_t = 87,65 + 2,6572.t$$

Un nouveau calcul des coefficients saisonniers n'apporte pas de modification sensible à deux décimales.

Pour cet exemple, nous avons finalement la décomposition suivante :

$$X_t = T_t \times I_t \times \varepsilon_t$$

où : $T_t = 87,77 + 2,6544.t$,

$I_{janvier} = 0,92$, $I_{février} = 0,90$, $I_{mars} = 1,02$, $I_{avril} = 0,99$,

$I_{mai} = 0,98$, $I_{juin} = 1,11$, $I_{juillet} = 1,23$, $I_{août} = 1,21$,

$I_{septembre} = 1,05$, $I_{octobre} = 0,91$, $I_{novembre} = 0,79$, $I_{décembre} = 0,88$.

Calcul des prévisions


Il suffit de calculer la tendance pour $T + 1, \dots, T + 12$, puis de multiplier par le coefficient saisonnier.

	t	T_t	I_t	$T_t \times I_t$
1961	145	472,66	0,92	435,50
	146	475,31	0,90	428,95
	147	477,97	1,02	489,04
	148	480,62	0,99	475,17
	149	483,28	0,98	474,69
	150	485,93	1,11	538,03
	151	488,58	1,23	599,38
	152	491,24	1,21	596,21
	153	493,89	1,05	518,01
	154	496,55	0,91	452,97
	155	499,20	0,79	394,06
	156	501,86	0,88	443,62

Décomposition multiplicative avec moyenne mobile d'ordre 12 :

```
*****
> DATABJ<-read.table("C:/BJSERG.TXT",header=TRUE)
> attach(DATABJ)
> names(DATABJ)
[1] "Date" "X"
> BJX<-ts(data=X, start=c(1949,1),frequency=12)
> BJMM<-decompose(BJX,type="multiplicative")
> summary(resmm)
      Length Class  Mode
x          144    ts   numeric
seasonal  144    ts   numeric
trend     144    ts   numeric
random    144    ts   numeric
figure     12  -none- numeric
type        1  -none- character
> plot.ts(BJMM$trend)
> BJMM$figure
[1] 0.9102304 0.8836253 1.0073663 0.9759060 0.9813780 1.1127758 1.2265555 1.2199110
1.0604919
[10] 0.9217572 0.8011781 0.8988244
> mean(resmm$figure)
[1] 1
> plot(BJMM)
*****
```

Decomposition of multiplicative time series



La prévision

On a trois types de prévision :

- ponctuelle
- par intervalle
- par distribution

La prévision ponctuelle : $\widehat{X}_t(h)$

- prévision faite à la date t pour l'horizon h .
- la prévision est faite en t : elle est fondée sur l'information disponible en t : $X_1, X_2, \dots, X_t$.
- la prévision est faite pour l'horizon h , c'est-à-dire pour la date $t + h$.

$\widehat{X}_t(h)$ est la prévision de X_{t+h} faite sur la base de l'information disponible en t .

$h = 1$: court terme.

La prévision par intervalle :

Intervalle (A, B) tel que

$$\mathbb{P}(A < X_{t+h} < B) = 1 - \alpha,$$

pour un niveau α dans $(0, 1)$.

La prévision par distribution :

Donne une distribution de probabilité pour la valeur future X_{t+h} .

Permet le calcul d'intervalle de prévision, de moyennes, de quantiles etc.

Mesure de la qualité prédictive

On dispose de données :

$$X_1, X_2, \dots, X_T$$

et de valeurs prédites (à court terme) :

$$\widehat{X}_0(1), \widehat{X}_1(1), \dots, \widehat{X}_{T-1}(1)$$

Généralement, on a des erreurs de prévision

$$e_t = X_t - \widehat{X}_{t-1}(1)$$

Comment juger de la qualité de la méthode de prévision ?

- l'erreur moyenne

$$\bar{e} = \frac{1}{T} \sum_{t=1}^T e_t$$

- l'erreur en moyenne absolue

$$MAE = \bar{e} = \frac{1}{T} \sum_{t=1}^T |e_t|$$

- le carré moyen des erreurs

$$MSE = \frac{1}{T} \sum_{t=1}^T e_t^2$$

- la variance empirique de l'erreur

$$V_{emp}(e) = \frac{1}{T} \sum_{t=1}^T (e_t - \bar{e})^2$$

- l'erreur moyenne absolue en pourcentage

$$MAPE = \frac{1}{T} \sum_{t=1}^T \left| \frac{e_t}{X_t} \right|$$

- le U de Theil :

$$U = \frac{\sum_{t=2}^T \left(\frac{e_t}{X_{t-1}} \right)^2}{\sum_{t=2}^T \left(\frac{X_t - X_{t-1}}{X_{t-1}} \right)^2}$$

- Approche "ajustement" :
On utilise l'ensemble des données et on calcule un critère, rétrospectivement sur l'ensemble de ces données.
- Approche "prévision" :
On garde les dernières données qui ne sont pas utilisées pour calibrer la méthode de prévision retenue ("données fraîches") et on calcule le critère sur ces dernières dates seulement.

Le lissage exponentiel

- Introduite par Holt :
Holt, Charles C. (1957). "Forecasting Trends and Seasonal by Exponentially Weighted Averages". Office of Naval Research Memorandum. 52 et par Winters :
Peter R. Winters, "Forecasting Sales by Exponentially Weighted Moving Averages", Management Science, vol. 6, 1960, pp. 324-342.
- Popularisées par le livre de Brown en 1963 :
Brown, Robert Goodell (1963). Smoothing Forecasting and Prediction of Discrete Time Series. Englewood Cliffs, NJ : Prentice-Hall.
- Méthodes très simples à utiliser et performantes
- Donnent un poids plus important aux données plus récentes
- Méthodes d'extrapolation, destinée à la prévision à court terme
- Avec ou sans tendance, avec ou sans saisonnalité.


Le lissage exponentiel simple

- Pour les séries sans variations saisonnières ni tendance.
- série uniquement caractérisée par des variations irrégulières autour d'un niveau localement constant.

Exemple : la proportion d'énergie renouvelable dans la consommation intérieure brute en France (source : Eurostat).

1996	1997	1998	1999	2000	2001	2002	2003	2004	2005	2006	2007
7,3	7,1	7	7,2	7	6,9	6,3	6,5	6,5	6,3	6,6	7

Proportion des énergies renouvelables dans la consommation brute d'énergie intérieure en France



Une prévision possible pour 2008 est la moyenne des données :

$$\hat{Y}_{12}(1) = \bar{Y} = \frac{1}{12} \sum_{t=1}^{12} Y_t = 6,8$$

On donne ainsi un poids **égal** à toutes les observations. Plus généralement :

$$\hat{Y}_T(h) = \frac{1}{T} \sum_{t=1}^T Y_t = \frac{1}{T} \sum_{i=0}^{T-1} Y_{T-i}, \quad h = 1, 2, \dots$$

On souhaite donner un **poids plus important aux données récentes** :

$$\hat{Y}_T(h) = \alpha \sum_{i=0}^{T-1} (1 - \alpha)^i Y_{T-i}$$

où $0 < \alpha < 1$ est appelée la **constante de lissage**.

$$\hat{Y}_T(h) = \alpha \sum_{i=0}^{T-1} (1 - \alpha)^i Y_{T-i}$$

- Cette prévision ne dépend pas de l'horizon h .
- Les poids $\alpha(1 - \alpha)^i$ dépendent du choix de α .
- L'information récente a un poids toujours plus élevé que l'information plus ancienne. Lorsque α est proche de 1, le poids de l'information récente est encore plus élevé.

Sur l'exemple :

$$\hat{Y}_{12}(h) = \alpha \sum_{i=0}^{11} (1 - \alpha)^i Y_{12-i}$$

$\alpha(1 - \alpha)^i$	i	α					poids égaux moyenne
		0,1	0,2	0,4	0,6	0,8	
2007	0	0,1	0,2	0,4	0,6	0,8	0,083
2006	1	0,09	0,16	0,24	0,24	0,16	0,083
2005	2	0,081	0,128	0,144	0,096	0,032	0,083
2004	3	0,073	0,102	0,086	0,038	0,006	0,083
2003	4	0,066	0,082	0,052	0,015	0,001	0,083
2002	5	0,059	0,066	0,031	0,006	0,000	0,083
2001	6	0,053	0,052	0,019	0,002	0,000	0,083
2000	7	0,048	0,042	0,011	0,001	0,000	0,083
1999	8	0,043	0,034	0,007	0,000	0,000	0,083
1998	9	0,039	0,027	0,004	0,000	0,000	0,083
1997	10	0,035	0,021	0,002	0,000	0,000	0,083
1996	11	0,031	0,017	0,001	0,000	0,000	0,083

$$\hat{Y}_T(h) = \alpha \sum_{i=0}^{T-1} (1 - \alpha)^i Y_{T-i}$$

La somme des coefficients de la pondération vaut :

$$\alpha \sum_{i=0}^{T-1} (1 - \alpha)^i = \alpha \frac{1 - (1 - \alpha)^T}{1 - (1 - \alpha)} = 1 - (1 - \alpha)^T$$

Cette somme ne vaut pas 1 mais s'approche de 1 quand T grandit.
Elle vaut 1 dans le cas limite où $T = \infty$

Autre écriture de la méthode

$$\begin{aligned}\hat{Y}_T(h) &= \alpha \sum_{i=0}^{T-1} (1 - \alpha)^i Y_{T-i} \\ &= \alpha Y_T + \alpha \sum_{i=1}^{T-1} (1 - \alpha)^i Y_{T-i} \\ &= \alpha Y_T + (1 - \alpha) \left(\alpha \sum_{i=1}^{T-1} (1 - \alpha)^{i-1} Y_{T-i} \right) \\ &= \alpha Y_T + (1 - \alpha) \left(\alpha \sum_{j=0}^{T-2} (1 - \alpha)^j Y_{T-1-j} \right) \\ &= \alpha Y_T + (1 - \alpha) \hat{Y}_{T-1}(h).\end{aligned}$$

$$\hat{Y}_T(h) = \alpha Y_T + (1 - \alpha) \hat{Y}_{T-1}(h).$$

- La prévision $\hat{Y}_T(h)$ est la moyenne pondérée de la dernière observation Y_T et de la dernière prévision $\hat{Y}_{T-1}(h)$.
- Le poids de la dernière observation est d'autant plus élevé que α est grand
- Le cas limite $\alpha = 1$ correspond à la prévision naïve : $\hat{Y}_T(h) = Y_T$. Dans ce cas, la prévision est égale à la dernière valeur observée.
- Problème d'initialisation des formules : le plus simple est de prendre $\hat{Y}_0(h) = Y_1$ ou $\hat{Y}_0(h) = \bar{Y}$.

Interprétation

Recherchons pour Y une prévision constante par moindres carrés ordinaires sur l'ensemble de la série et notons a cette constante.

$$\min_a \sum_{i=0}^{T-1} (Y_{T-i} - a)^2$$

On a alors

$$\begin{aligned} \frac{d}{da} \sum_{i=0}^{T-1} (Y_{T-i} - a)^2 &= -2 \sum_{i=0}^{T-1} (Y_{T-i} - a) \\ &= 2T \cdot a - 2 \sum_{i=0}^{T-1} Y_{T-i} \end{aligned}$$

On obtient donc

$$a = \frac{1}{T} \sum_{i=0}^{T-1} Y_{T-i} = \bar{Y}$$

Recherchons maintenant a par moindres carrés escomptés, en introduisant des poids décroissants (β^i avec $0 < \beta < 1$) :

$$\min_a \sum_{i=0}^{T-1} \beta^i (Y_{T-i} - a)^2.$$

$$\begin{aligned} \frac{d}{da} \sum_{i=0}^{T-1} \beta^i (Y_{T-i} - a)^2 &= -2 \sum_{i=0}^{T-1} \beta^i Y_{T-i} + 2a \sum_{i=0}^{T-1} \beta^i \\ &= -2 \sum_{i=0}^{T-1} \beta^i Y_{T-i} + 2a \frac{1 - \beta^T}{1 - \beta} \end{aligned}$$

On obtient donc

$$a = \frac{1 - \beta}{1 - \beta^T} \sum_{i=0}^{T-1} \beta^i Y_{T-i}$$

Pour T grand, et en posant $\beta = 1 - \alpha$, on retrouve la prévision du lissage exponentiel simple : $\hat{Y}_T(h) = \alpha \sum_{i=0}^{T-1} (1 - \alpha)^i Y_{T-i}$.

On peut interpréter cette prévision comme une prévision localement constante, ou au voisinage de t , puisque dans la minimisation, l'influence des observations diminue lorsqu'on s'éloigne de T .

La méthode du lissage exponentiel simple ne sera donc pas appropriée pour les séries avec tendance ou avec mouvements saisonniers.

Mise en oeuvre de la méthode

Sur l'exemple des énergies renouvelables.

On calcule la prévision à l'horizon 1, $\hat{Y}_{12}(1)$, c'est-à-dire la **prévision pour Y_{13} faite sur la base des données des périodes 1 à 12** :

$$\hat{Y}_{12}(1) = \alpha Y_{12} + (1 - \alpha) \hat{Y}_{11}(1)$$

$$\hat{Y}_{11}(1) = \alpha Y_{11} + (1 - \alpha) \hat{Y}_{10}(1)$$

$$\vdots$$

$$\hat{Y}_1(1) = \alpha Y_1 + (1 - \alpha) \underbrace{\hat{Y}_0(1)}_{Y_1}$$

en choisissant d'initialiser les formules par $\hat{Y}_0(1) = Y_1$.

Par exemple, pour $\alpha = 0,9$:

	date t	valeur observée Y_t	valeur prédite pour Y_t et $t - 1$ $\hat{Y}_{t-1}(1)$
1996	1	7,3	7,300
1997	2	7,1	7,300
1998	3	7	7,120
1999	4	7,2	7,012
2000	5	7	7,181
2001	6	6,9	7,018
2002	7	6,3	6,912
2003	8	6,5	6,361
2004	9	6,5	6,486
2005	10	6,3	6,499
2006	11	6,6	6,320
2007	12	7	6,572
2008	13		6,957

On peut mener les calculs de $\hat{Y}_{12}(1)$ pour différentes valeurs de α .

α	0,9	0,8	0,7	0,6	0,5	0,4	0,3	0,2	0,1
prévision pour 2008	6,957	6,910	6,858	6,805	6,754	6,713	6,697	6,738	6,898

Comment choisir entre ces valeurs ?

La manière la plus simple consiste à choisir un critère de qualité d'ajustement qu'on peut calculer pour les différentes valeurs de α , on choisit alors la valeur du paramètre qui donne la meilleure qualité d'ajustement.

On calcule l'erreur de prévision à l'horizon 1 : $e_t = Y_t - \hat{Y}_{t-1}(1)$, et le pourcentage d'erreur : e_t/Y_t . Par exemple pour $\alpha = 0,9$:

	Y_t	$\hat{Y}_{t-1}(1)$	e_t	en %
1996	7,3	7,300	0,000	0,0%
1997	7,1	7,300	-0,200	-2,8%
1998	7	7,162	-0,162	-2,3%
1999	7,2	7,050	0,150	2,1%
2000	7	7,154	-0,154	-2,2%
2001	6,9	7,048	-0,148	-2,1%
2002	6,3	6,946	-0,646	-10,2%
2003	6,5	6,500	0,000	0,0%
2004	6,5	6,500	0,000	0,0%
2005	6,3	6,500	-0,200	-3,2%
2006	6,6	6,362	0,238	3,6%
2007	7	6,526	0,474	6,8%

$$\bar{e} = -0,032, MAE = 0,207, MAPE = 3,1\%.$$

On peut reproduire ce travail pour différentes valeurs de α et obtenir le tableau suivant :

α	0,9	0,8	0,7	0,6	0,5	0,4	0,3	0,2	0,1
prévision pour 2008	6,957	6,910	6,858	6,805	6,754	6,713	6,697	6,738	6,898
$\bar{e}$	-0,032	-0,041	-0,053	-0,069	-0,091	-0,122	-0,167	-0,234	-0,335
MAE	0,207	0,203	0,198	0,207	0,220	0,235	0,253	0,289	0,354
MAPE	3,1%	3,0%	3,0%	3,1%	3,3%	3,5%	3,8%	4,4%	5,4%
MSE	0,069	0,070	0,072	0,076	0,081	0,089	0,103	0,130	0,193

Pour *MAE*, *MAPE* et *MSE*, le meilleur choix pour α se situe autour de 0,7.


Remarque

Un travail plus précis peut être mené avec le solveur d'Excel en minimisant la valeur du *MAPE* par rapport à α .

Celui-ci propose une solution $\alpha = 0,69$.

Ceci donne un *MAPE* de 2,94%.

Part des énergies renouvelables dans la consommation brute d'énergie intérieure en France



La méthode de Holt

La méthode de Holt permet de construire des prévisions linéaires :

$$\hat{Y}_T(h) = S_T + hT_T, h = 1, 2, \dots$$

- S_t est la composante de niveau
- T_t est la composante de tendance

Elle dépend de deux paramètres compris entre 0 et 1 : α et γ .

$$\begin{cases} S_t &= \alpha Y_t + (1 - \alpha)(S_{t-1} + T_{t-1}) \\ T_t &= \gamma(S_t - S_{t-1}) + (1 - \gamma)T_{t-1} \end{cases}$$

Au temps t , on estime deux composantes qui sont combinées pour fournir des prévisions


$$\begin{cases} S_t &= \alpha Y_t + (1 - \alpha)(S_{t-1} + T_{t-1}) \\ T_t &= \gamma(S_t - S_{t-1}) + (1 - \gamma)T_{t-1} \\ \hat{Y}_t(h) &= S_t + hT_t, h = 1, 2, \dots \end{cases}$$

L'initialisation des relations est faite en choisissant $S_0 = Y_1$ ou $S_0 = \bar{Y}$ ainsi que $T_0 = 0$.

Exemple : la proportion d'énergie renouvelable dans la consommation intérieure brute aux Pays-Bas (source : Eurostat).

1996	1997	1998	1999	2000	2001	2002	2003	2004	2005	2006	2007
1,8	2	2,2	2,3	2,4	2,4	2,6	2,6	2,8	3,4	3,6	3,6

**Part des énergies renouvelables dans la consommation brute d'énergie intérieure
aux Pays-Bas**




Calcul pour $\alpha = 0,85$ et $\gamma = 0,3$:

	t	Y_t	S_t	T_t	prévision	e_t	$ e_t/Y_t $
	0		1,8	0			
1996	1	1,8	1,8	0	1,8	0	0
1997	2	2	1,97	0,05	1,8	0,2	0,1
1998	3	2,2	2,17	0,10	2,02	0,18	0,08
1999	4	2,3	2,30	0,10	2,27	0,03	0,01
2000	5	2,4	2,40	0,10	2,40	0,00	0,00
2001	6	2,4	2,42	0,08	2,50	-0,10	0,04
2002	7	2,6	2,58	0,10	2,49	0,11	0,04
2003	8	2,6	2,61	0,08	2,69	-0,09	0,03
2004	9	2,8	2,78	0,11	2,70	0,10	0,04
2005	10	3,4	3,32	0,24	2,89	0,51	0,15
2006	11	3,6	3,59	0,25	3,56	0,04	0,01
2007	12	3,6	3,64	0,19	3,84	-0,24	0,07

Calcul des prévisions

	t	Y_t	S_t	T_t	prévision
2007	12	3,6	3,64	0,19	
2008	13				$3,82 = 3,64 + 0,19$
2009	14				$4,01 = 3,64 + 2 \times 0,19$
2010	14				$4,19 = 3,64 + 3 \times 0,19$

**Part des énergies renouvelables dans la consommation brute d'énergie intérieure
aux Pays-Bas**



La méthode de Winters

La méthode de **Winters** est également connue sous le nom de méthode de **Holt-Winters avec saisonnalité**, la méthode de Holt étant alors désignée sous le nom de méthode de **Holt-Winters sans saisonnalité**.

Deux versions de cette méthode existent : la méthode **additive** et la méthode **multiplicative**.

Cas additif

L'idée est d'introduire des coefficients **saisonniers** :

$$\hat{Y}_T(h) = S_T + hT_T + I_{T+h-s}, h = 1, 2, \dots$$

S_t est la composante de niveau, T_t est la composante de tendance et I_t est un coefficient saisonnier. s est la saison.

Trois paramètres entre 0 et 1 : α , γ et δ .

$$\begin{cases} S_t &= \alpha (Y_t - I_{t-s}) + (1 - \alpha)(S_{t-1} + T_{t-1}) \\ T_t &= \gamma(S_t - S_{t-1}) + (1 - \gamma)T_{t-1} \\ I_t &= \delta (Y_t - S_t) + (1 - \delta)I_{t-s} \end{cases}$$

Initialisation de la méthode

s valeurs initiales $t = 0, -1, -2, \dots, -(s - 1)$.

Pour S , on prend la moyenne des s premières observations. Pour T , on prend 0. Pour I , on prend $Y - S$.

Exemple des passagers des lignes aériennes : 12 valeurs initiales $t = -11, -10, \dots, 0$.

Valeurs initiales pour S ; 126,7 : moyenne des 12 premières observations (celles de l'année 1949).

Valeurs initiales pour les coefficients saisonniers I : écart entre les 12 premières données (celles de 1949) et la valeur initiale pour S : 126,7.

	t	Y_t	S_t	T_t	I_t
janvier	-11		126,7	0	$112 - 126,7 = -14,7$
février	-10		126,7	0	$118 - 126,7 = -8,7$
mars	-9		126,7	0	$132 - 126,7 = 5,3$
avril	-8		126,7	0	2,3
mai	-7		126,7	0	-5,7
juin	-6		126,7	0	8,3
juillet	-5		126,7	0	21,3
août	-4		126,7	0	21,3
septembre	-3		126,7	0	9,3
octobre	-2		126,7	0	-7,7
novembre	-1		126,7	0	-22,7
décembre	0		126,7	0	-8,7
1949					
janvier	1	112			
février	2	118			
mars	3	132			
avril	4	129			
mai	5	121			
juin	6	135			
juillet	7	148			
août	8	148			
septembre	9	136			
octobre	10	119			
novembre	11	104			
décembre	12	118			

◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ◀ ≡ ▶

La suite du tableau, à partir de $t = 1$, est complétée à l'aide des autres formules :


$$\begin{cases} S_t &= \alpha (Y_t - I_{t-s}) + (1 - \alpha)(S_{t-1} + T_{t-1}) \\ T_t &= \gamma(S_t - S_{t-1}) + (1 - \gamma)T_{t-1} \\ I_t &= \delta (Y_t - S_t) + (1 - \delta)I_{t-s} \end{cases}$$

Ainsi pour un choix de $\alpha = 0,3$, $\gamma = 0,1$ et $\delta = 0,9$, on obtient un *MAPE* de 3,38%.

	t	Y_t	S_t	T_t	I_t	prévision de Y_t $\hat{Y}_{t-1}(1)$	erreur e_t	$ e_t/Y_t $
janv.	-11		126,7	0	-14,7			
févr.	-10		126,7	0	-8,7			
mars	-9		126,7	0	5,3			
avril	-8		126,7	0	2,3			
mai	-7		126,7	0	-5,7			
juin	-6		126,7	0	8,3			
juil.	-5		126,7	0	21,3			
août	-4		126,7	0	21,3			
sept.	-3		126,7	0	9,3			
oct.	-2		126,7	0	-7,7			
nov.	-1		126,7	0	-22,7			
déc.	0		126,7	0	-8,7			
janv. 49	1	112	126,7	0	-14,7	112	0	0
févr.	2	118	126,7	0	-8,7	118	0	0
mars	3	132	126,7	0	5,3	132	0	0
avril	4	129	126,7	0	2,3	129	0	0
mai	5	121	126,7	0	-5,7	121	0	0
juin	6	135	126,7	0	8,3	135	0	0
juil.	7	148	126,7	0	21,3	148	0	0
août	8	148	126,7	0	21,3	148	0	0
sept.	9	136	126,7	0	9,3	136	0	0
oct.	10	119	126,7	0	-7,7	119	0	0
nov.	11	104	126,7	0	-22,7	104	0	0
déc.	12	118	126,7	0	-8,7	118	0	0
janv. 50	13	115	127,60	0	-12,81	112	3	0,03
févr.	14	126	129,79	0,30	-4,28	118,99	7,01	0,06
mars	15	141	131,78	0,47	8,83	135,39	5,61	0,04
avril	16	135	132,38	0,48	2,59	134,54	0,46	0,00
mai	17	125	132,21	0,42	-7,06	127,16	-2,16	0,02
juin	18	149	135,05	0,66	13,38	140,93	8,07	0,05
.	.	.	.	.	.	.	.	.
.	.	.	.	.	.	.	.	.
déc.	144	432	487,88	3,38	-55,02	444,29	-12,29	0,03

	t	Y_t	S_t	T_t	I_t	prévisions
janvier 60	133	417	454,86	4,33	-37,58	
février	134	391	455,16	3,93	-63,21	
mars	135	419	446,24	2,65	-24,24	
avril	136	461	455,63	3,32	3,79	
mai	137	472	460,45	3,47	11,19	
juin	138	535	466,50	3,73	67,90	
juillet	139	622	477,29	4,43	143,06	
août	140	606	480,23	4,28	126,12	
septembre	141	508	483,83	4,22	24,33	
octobre	142	461	489,96	4,41	-29,41	
novembre	143	390	487,81	3,75	-96,28	
décembre	144	432	487,88	3,38	-55,02	
janvier 61	145					$453,68 = 487,88 + 3,38 - 37,58$
février	146					$431,43 = 487,88 + 2 \times 3,38 - 63,21$
mars	147					$473,79 = 487,88 + 3 \times 3,38 - 24,24$
avril	148					$505,21 = 487,88 + 4 \times 3,38 + 3,79$
mai	149					$515,99 = 487,88 + 5 \times 3,38 + 11,19$
juin	150					$576,08 = 487,88 + 6 \times 3,38 + 67,9$
juillet	151					$654,63 = 487,88 + 7 \times 3,38 + 143,06$
août	152					$641,06 = 487,88 + 8 \times 3,38 + 126,12$
septembre	153					$542,66 = 487,88 + 9 \times 3,38 + 24,33$
octobre	154					$492,30 = 487,88 + 10 \times 3,38 - 29,41$
novembre	155					$428,81 = 487,88 + 11 \times 3,38 - 96,28$
décembre	156					$473,46 = 487,88 + 12 \times 3,38 - 55,02$

Le solveur détermine un choix des constantes : $\alpha = 0,303$, $\gamma = 0,033$ et $\delta = 1$, pour un *MAPE* de 3,21%.



Cas multiplicatif

Prévisions du type :

$$\hat{Y}_T(h) = (S_T + h.T_T).I_{T+h-s}$$

Trois paramètres compris en 0 et 1 : α , γ et δ .

$$\begin{cases} S_t &= \alpha (Y_t/I_{t-s}) + (1 - \alpha)(S_{t-1} + T_{t-1}) \\ T_t &= \gamma (S_t - S_{t-1}) + (1 - \gamma)T_{t-1} \\ I_t &= \delta (Y_t/S_t) + (1 - \delta)I_{t-s} \end{cases}$$

Initialisation de la méthode

s valeurs initiales $t = 0, -1, -2, \dots, -(s-1)$.

Pour S , on prend la moyenne des s premières observations, pour T on prend 0, pour I on prend Y/S .

Exemple des passagers des lignes aériennes : 12 valeurs initiales $t = 0, -1, -2, \dots, -11$.

Valeurs initiale pour S : 126,7 : moyenne des 12 premières observations (celles de l'année 1949).

Valeur initiale pour T : 0

Valeurs initiales pour les coefficients saisonniers I : rapport entre les 12 premières données (celles de 1949) et la valeur initiale pour S : 126,7.

	t	Y_t	S_t	T_t	I_t
	janvier	-11	126,7	0	0,88
	février	-10	126,7	0	0,93
	mars	-9	126,7	0	1,04
	avril	-8	126,7	0	1,02
	mai	-7	126,7	0	0,96
	juin	-6	126,7	0	1,07
	juillet	-5	126,7	0	1,17
	août	-4	126,7	0	1,17
	septembre	-3	126,7	0	1,07
	octobre	-2	126,7	0	0,94
	novembre	-1	126,7	0	0,82
	décembre	0	126,7	0	0,93
1949	janvier	1	112		
	février	2	118		
	mars	3	132		
	avril	4	129		
	mai	5	121		
	juin	6	135		
	juillet	7	148		
	août	8	148		
	septembre	9	136		
	octobre	10	119		
	novembre	11	104		
	décembre	12	118		

La suite du tableau, à partir de $t = 1$, est complétée à l'aide des autres formules :


$$\begin{cases} S_t &= \alpha (Y_t / I_{t-s}) + (1 - \alpha)(S_{t-1} + T_{t-1}) \\ T_t &= \gamma (S_t - S_{t-1}) + (1 - \gamma)T_{t-1} \\ I_t &= \delta (Y_t / S_t) + (1 - \delta)I_{t-s} \end{cases}$$

Ainsi pour un choix de $\alpha = 0,3$, $\gamma = 0,1$ et $\delta = 0,9$, on obtient un *MAPE* de 2,87% :

	t	Y_t	S_t	T_t	I_t	prévision de Y_t $\hat{Y}_{t-1}(1)$	erreur e_t	$ e_t/Y_t $
janv.	-11		126,7	0	0,88			
févr.	-10		126,7	0	0,93			
mars	-9		126,7	0	1,04			
avril	-8		126,7	0	1,02			
mai	-7		126,7	0	0,96			
juin	-6		126,7	0	1,07			
juil.	-5		126,7	0	1,17			
août	-4		126,7	0	1,17			
sept.	-3		126,7	0	1,07			
oct.	-2		126,7	0	0,94			
nov.	-1		126,7	0	0,82			
déc.	0		126,7	0	0,93			
janv. 49	1	112	126,7	0	0,88	112	0	0
févr.	2	118	126,7	0	0,93	118	0	0
mars	3	132	126,7	0	1,04	132	0	0
avril	4	129	126,7	0	1,02	129	0	0
mai	5	121	126,7	0	0,96	121	0	0
juin	6	135	126,7	0	1,07	135	0	0
juil.	7	148	126,7	0	1,17	148	0	0
août	8	148	126,7	0	1,17	148	0	0
sept.	9	136	126,7	0	1,07	136	0	0
oct.	10	119	126,7	0	0,94	119	0	0
nov.	11	104	126,7	0	0,82	104	0	0
déc.	12	118	126,7	0	0,93	118	0	0
janv. 50	13	115	127,72	0	0,90	112	3	0,03
févr.	14	126	130,06	0,33	0,97	119,04	6,96	0,06
mars	15	141	131,87	0,47	1,07	135,84	5,16	0,04
avril	16	135	132,42	0,48	1,02	134,75	0,25	0,00
mai	17	125	132,30	0,42	0,95	126,92	-1,92	0,02
juin	18	149	134,86	0,64	1,10	141,41	7,59	0,05
.	.	.	.	.	.	.	.	.
.	.	.	.	.	.	.	.	.
déc.	144	432	476,06	3,27	0,91	434,94	-2,94	0,01

	t	Y_t	S_t	T_t	I_t	prévision
janvier 60	133	417	447,45	4,50	0,93	416,91
février	134	391	450,53	4,36	0,87	395,11
mars	135	419	441,90	3,06	0,96	463,09
avril	136	461	452,51	3,81	1,01	436,32
mai	137	472	457,70	3,95	1,03	467,28
juin	138	535	461,04	3,89	1,16	537,38
juillet	139	622	465,03	3,90	1,34	621,54
août	140	606	463,03	3,31	1,31	632,52
septembre	141	508	465,07	3,18	1,09	512,67
octobre	142	461	472,46	3,60	0,97	447,57
novembre	143	390	473,66	3,36	0,82	396,68
décembre	144	432	476,06	3,27	0,91	434,94
janvier 61	145					$446,70 = (476,06 + 3,27) \times 0,93$
février	146					$419,13 = (476,06 + 2 \times 3,27) \times 0,87$
mars	147					464,08
avril	148					496,44
mai	149					507,42
juin	150					575,35
juillet	151					667,30
août	152					659,27
septembre	153					552,47
octobre	154					495,37
novembre	155					422,06
décembre	156					467,79

Le solveur détermine un choix optimal des constantes : $\alpha = 0,368$, $\gamma = 0,036$ et $\delta = 0,964$, pour un $MAPE$ de 2,79%



Séries temporelles et processus stationnaires

Une série temporelle est une réalisation (finie) d'un processus stochastique. C'est donc une suite de nombres.

Dans ce cours, nous considérerons qu'un **processus stochastique** est une suite de variables aléatoires indicées par le temps.

Parfois, on étudie la loi des échantillons

$$(X_{t_1}, X_{t_2}, \dots, X_{t_n}).$$

Lorsque cette loi n'est pas affectée par translation dans le temps, on dit que le processus est **strictement stationnaire** :

$$\mathcal{L}(X_{t_1}, X_{t_2}, \dots, X_{t_n}) = \mathcal{L}(X_{t_1+k}, X_{t_2+k}, \dots, X_{t_n+k}),$$

$$\forall n, k, t_1, t_2, \dots, t_n.$$

C'est le cas, par exemple, des processus gaussiens.

Souvent on s'intéresse aux **deux premiers moments** de la loi du processus

$$\mathbb{E}[X_1], \mathbb{E}[X_2], \dots, \mathbb{E}[X_t], \dots$$

$$\mathbb{V}[X_1], \mathbb{V}[X_2], \dots, \mathbb{V}[X_t], \dots$$

$$\text{Cov}(X_1, X_2), \text{Cov}(X_1, X_3), \dots, \text{Cov}(X_i, X_j), \dots \text{ avec } i \neq j.$$

Lorsqu'on concentre l'analyse sur les deux premiers moments, on utilise le concept de processus (faiblement) **stationnaire** ou **stationnaire au second ordre**.

On pensera à vérifier que les moments existent !

D'un point de vue théorique :

On se place dans l'espace $\mathcal{L}^2(\Omega, \mathcal{F}, \mathbb{P})$ des variables aléatoires X définies sur $(\Omega, \mathcal{F}, \mathbb{P})$ telles que : $\mathbb{E}[X^2] < \infty$.

On parle de variables aléatoires de carré intégrable ou du seconde ordre.

$\mathcal{L}^2(\Omega, \mathcal{F}, \mathbb{P})$ est une espace vectoriel normé de dimension infinie :

- **Produit scalaire** : $\langle X, Y \rangle$
 X, Y sont orthogonales au sens de $\mathcal{L}^2$ si $\mathbb{E}[XY] = 0$
- **Norme** : $\|X\| = \sqrt{\mathbb{E}[X^2]}$.

On a alors $\|X\|^2 = \mathbb{E}[X^2] = \mathbb{V}(X) + (\mathbb{E}[X])^2$

Si H est un sous-espace fermé de $\mathcal{L}^2(\Omega, \mathcal{F}, \mathbb{P})$, on peut définir X^* , la **projection orthogonale** de X sur H :

$$\|X - X^*\| = \min_{Z \in H} \|X - Z\|.$$

On a : $X^* \in H$ et $\langle X - X^*, Z \rangle = 0, \forall Z \in H$.

H peut être le sous-espace fermé engendré par des variables $(Z_i, i \in \mathcal{I})$, avec $\mathcal{I}$ fini ou infini. Dans ce cas, la projection orthogonale X^* est la **régression affine** de X sur $(Z_i, i \in \mathcal{I})$: $X^* \in H$: X^* est donc une combinaison linéaire des variables Z_i et $\langle X - X^*, Z_i \rangle = 0, \forall i \in \mathcal{I}$.

Par exemple, H peut être le sous-espace engendré par le passé d'une série. On recherchera alors la projection de X_{t+1} sur $I_t = \{X_t, X_{t-1}, \dots\}$, l'information disponible à la date t .

Intuitivement, le processus est **stationnaire** si

- 1 l'espérance est stable au cours du temps :

$$\mathbb{E}[X_1] = \mathbb{E}[X_2] = \dots = \mathbb{E}[X_t] = \dots = m.$$

- 2 la variance est stable au cours du temps :

$$\mathbb{V}[X_1] = \mathbb{V}[X_2] = \dots = \mathbb{V}[X_t] = \dots = \sigma^2.$$

- 3 les covariances sont stables au cours du temps :

$$\begin{aligned}\text{Cov}(X_1, X_{1+k}) &= \text{Cov}(X_2, X_{2+k}) = \dots \\ &= \text{Cov}(X_{t-k}, X_k) = \dots = \text{Cov}(X_t, X_{t+k}) = \gamma_k.\end{aligned}$$

Les covariances ne dépendent que du **délai** k entre les variables considérées, et pas de la date t à laquelle elles sont évaluées.

$\text{Cov}(X_t, X_{t+k})$ dépend de k mais pas de t .

définitions

Plus formellement, on considère un processus à temps discret du second ordre $(X_t, t \in \mathbb{Z})$.

Fonction moyenne :

$$m(t) = \mathbb{E}[X_t]$$

Fonction d'auto-covariance d'ordre h (ou de délai h) :

$$\begin{aligned}\gamma_h(t) &= \text{Cov}(X_t, X_{t-h}) = \mathbb{E}[(X_t - \mathbb{E}[X_t])(X_{t-h} - \mathbb{E}[X_{t-h}])] \\ &= \mathbb{E}[X_t X_{t-h}] - \mathbb{E}[X_t] \mathbb{E}[X_{t-h}]\end{aligned}$$

La fonction d'auto-covariance d'ordre 0 est la fonction de variance

$$\gamma_0(t) = \text{Cov}(X_t, X_t) = \mathbb{V}[X_t].$$

Définition 1

$(X_t, t \in \mathbb{Z})$ est un processus *stationnaire du seconde ordre* ou *(faiblement) stationnaire* si :

- $\forall t \in \mathbb{Z} : \mathbb{E}[X_t] = m$
- $\forall t, h \in \mathbb{Z} : \text{Cov}(X_t, X_{t-h}) = \gamma_h$

Les quantités m et γ_h ne dépendent pas de t : la loi du processus stationnaire, pour ses deux premiers moments, est stable par translation dans le temps.

Pour un processus du seconde ordre, la stationnarité stricte implique la stationnarité faible.

Auto-covariances, auto-corrélations

Proposition 1

Soit $(X_t, t \in \mathbb{Z})$ un processus stationnaire. La fonction d'auto-covariance :

$$\begin{aligned}\gamma_h &: \mathbb{Z} \rightarrow \mathbb{R} \\ h &\mapsto \text{Cov}(X_t, X_{t-h})\end{aligned}$$

est paire : $\gamma_h = \gamma_{-h}$

En effet,

$$\gamma_{-h} = \text{Cov}(X_t, X_{t+h}) = \text{Cov}(X_{t+h}, X_t) = \text{Cov}(X_t, X_{t-h}) = \gamma_h$$

On se limite donc à l'étude pour $h \in \mathbb{N}$.

Le graphe (en bâtons) de la fonction $h \mapsto \gamma_h$ est le **variogramme**.

Proposition 2

Soit $(X_t, t \in \mathbb{Z})$ un processus stationnaire. La fonction d'auto-covariance vérifie

$$\forall h \in \mathbb{Z}, \quad |\gamma_h| \leq \gamma_0$$

En effet,

$$\gamma_h^2 = \text{Cov}(X_t, X_{t-h})^2 \leq \mathbb{V}(X_t)\mathbb{V}(X_{t-h}) = \gamma_0^2$$

et $\gamma_0 = \mathbb{V}(X_t) \geq 0$.

Pour un processus stationnaire : $\forall n \in \mathbb{N}, \forall (t_1, t_2, \dots, t_n) \in \mathbb{Z}^n$

$$\mathbb{E} \begin{pmatrix} X_{t_1} \\ X_{t_2} \\ \vdots \\ X_{t_n} \end{pmatrix} = \begin{pmatrix} m \\ m \\ \vdots \\ m \end{pmatrix}$$

$$\mathbb{V} \begin{pmatrix} X_{t_1} \\ X_{t_2} \\ \vdots \\ X_{t_n} \end{pmatrix} = \begin{pmatrix} \gamma_0 & \gamma_{t_2-t_1} & \gamma_{t_3-t_1} & \cdots & \gamma_{t_n-t_1} \\ \gamma_{t_2-t_1} & \gamma_0 & \gamma_{t_3-t_2} & \cdots & \gamma_{t_n-t_2} \\ \gamma_{t_3-t_1} & \gamma_{t_3-t_2} & \gamma_0 & \ddots & \gamma_{t_n-t_3} \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ \gamma_{t_n-t_1} & \gamma_{t_n-t_2} & \gamma_{t_n-t_3} & \cdots & \gamma_0 \end{pmatrix}$$

En particulier, la **matrice d'auto-covariance** d'ordre K donnée par :

$$\mathbb{V} \begin{pmatrix} X_t \\ X_{t-1} \\ \vdots \\ X_{t-K} \end{pmatrix} = \begin{pmatrix} \gamma_0 & \gamma_1 & \gamma_2 & \cdots & \gamma_K \\ \gamma_1 & \gamma_0 & \gamma_1 & \cdots & \gamma_{K-1} \\ \gamma_2 & \gamma_1 & \gamma_0 & \ddots & \gamma_{K-2} \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ \gamma_K & \gamma_{K-1} & \gamma_{K-2} & \cdots & \gamma_0 \end{pmatrix}$$

est symétrique définie positive.

Définition 2

Soit $(X_t, t \in \mathbb{Z})$ un processus stationnaire. La *fonction d'auto-corrélation* est définie par :

$$\forall h \in \mathbb{Z} : \text{Corr}(X_t, X_{t-h}) = \frac{\text{Cov}(X_t, X_{t-h})}{\sqrt{\mathbb{V}(X_t)\mathbb{V}(X_{t-h})}} = \frac{\gamma_h}{\gamma_0} = \rho_h.$$

- $\rho_0 = 1$ et $\forall h \in \mathbb{Z} : -1 \leq \rho_h \leq 1$.
- La fonction d'auto-corrélation est paire : $\rho_h = \rho_{-h}$.

On considère souvent la **matrice d'auto-corrélation** d'ordre K donnée par

$$R_K = \text{Corr} \begin{pmatrix} X_t \\ X_{t-1} \\ \vdots \\ X_{t-K} \end{pmatrix} = \begin{pmatrix} \rho_0 & \rho_1 & \rho_2 & \cdots & \rho_K \\ \rho_1 & \rho_0 & \rho_1 & \cdots & \rho_{K-1} \\ \rho_2 & \rho_1 & \rho_0 & \ddots & \rho_{K-2} \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ \rho_K & \rho_{K-1} & \rho_{K-2} & \cdots & \rho_0 \end{pmatrix}$$

R_K est symétrique définie positive.

Le graphe (en bâtons) de la fonction $h \mapsto \rho_h$ est le **auto-corrélogramme**.


Bruits blancs

Définition 3

Le processus $\varepsilon = (\varepsilon_t, t \in \mathbb{Z})$ est un *bruit blanc* (faible) si :

- $\forall t \in \mathbb{Z} : \mathbb{E}[\varepsilon_t] = 0$
- $\forall t \in \mathbb{Z} : \mathbb{V}[\varepsilon_t] = \sigma^2 \in \mathbb{R}^{*+}$
- $\forall t \neq t' \in \mathbb{Z} : \text{Cov}(\varepsilon_t, \varepsilon_{t'}) = 0$

Trajectoire simulée d'un bruit blanc faible



Définition 4

Le processus $\varepsilon = (\varepsilon_t, t \in \mathbb{Z})$ est un **bruit blanc fort** si les variables sont i.i.d. (indépendantes et de même loi) et :

- $\forall t \in \mathbb{Z} : \mathbb{E}[\varepsilon_t] = 0$
- $\forall t \in \mathbb{Z} : \mathbb{V}[\varepsilon_t] = \sigma^2 \in \mathbb{R}^{*+}$

Un bruit fort est donc aussi un bruit blanc faible. Ces deux types de bruits blancs constituent des processus (faiblement) stationnaires. Si on impose en plus au processus ε d'être gaussien, on obtient un **bruit blanc gaussien**. Un processus gaussien est un processus strictement stationnaire.

Exercice 1

On considère une suite $(X_t, t \in \mathbb{Z})$ de variables aléatoires indépendantes et identiquement distribuées dont la loi est donnée par :

$$X_t(\Omega) = \{-1, 1\} \quad \text{et} \quad \mathbb{P}(X_t = 1) = \mathbb{P}(X_t = -1) = \frac{1}{2}.$$

- ❶ Calculer les moments d'ordre 1, 2, 3, ...
- ❷ Calculer la fonction d'auto-covariance, la fonction d'auto-corrélation.
- ❸ Ce processus est-il stationnaire ?
- ❹ S'agit-il d'un bruit blanc ? Faible, fort ?

Exercice 2

On considère une suite $(X_t, t \in \mathbb{Z})$ de variables aléatoires indépendantes dont la loi est uniforme sur le segment $[-1, 1]$.

- ① Calculer les moments d'ordre 1, 2, 3, $\dots$
- ② Calculer la fonction d'auto-covariance, la fonction d'auto-corrélation.
- ③ Ce processus est-il stationnaire ?
- ④ S'agit-il d'un bruit blanc ? Faible, fort ?

Exercice 3

On considère un bruit blanc $(\varepsilon_t, t \in \mathbb{Z})$ et on définit

$$X_t = \varepsilon_t - \varepsilon_{t-12}$$

- 1 Calculer l'espérance et la variance de X_t .
- 2 Calculer la fonction d'auto-covariance, la fonction d'auto-corrélation de X
- 3 Ce processus est-il stationnaire ?

Exercice 4 : la moyenne mobile d'ordre 1

On considère un bruit blanc $(\varepsilon_t, t \in \mathbb{Z})$ et on définit


$$X_t = \varepsilon_t - \theta \varepsilon_{t-1}$$

où $\theta \in (-1, 1)$ et $\theta \neq 0$.

- ❶ Calculer l'espérance et la variance de X_t .
- ❷ Calculer la fonction d'auto-covariance, la fonction d'auto-corrélation de X
- ❸ Ce processus est-il stationnaire ?

Trajectoire simulée d'une moyenne mobile d'ordre 1

Moyenne mobile d'ordre 1



Exercice 5 : la marche aléatoire

On considère un bruit blanc $(\varepsilon_t, t \in \mathbb{Z})$ et on définit

$$X_0 = 0$$

$$X_1 = X_0 + \varepsilon_1 = \varepsilon_1$$


$$\vdots$$

$$X_t = X_{t-1} + \varepsilon_t$$


$$= \varepsilon_1 + \varepsilon_2 + \cdots + \varepsilon_t$$

- 1 Calculer l'espérance et la variance de X_t .
- 2 Ce processus est-il stationnaire ?


Trajectoire simulée d'une marche aléatoire



Trajectoire simulée d'une marche aléatoire



Trajectoire simulée d'une marche aléatoire



Exercice 6

On considère un bruit blanc $(\varepsilon_t, t \in \mathbb{Z})$ et on définit

$$X_t = \sum_{i=0}^{\infty} \frac{1}{2^i} \varepsilon_{t-i}$$

- 1 Calculer l'espérance et la variance de X_t .
- 2 Calculer la fonction d'auto-covariance, la fonction d'auto-corrélation de X
- 3 Ce processus est-il stationnaire ?

Exercice 7

On considère un bruit blanc $(\varepsilon_t, t \in \mathbb{Z})$, deux réels non nuls a et b et on définit

$$X_t = a + bt + \varepsilon_t$$

- ① Calculer l'espérance et la variance de X_t .
- ② Calculer la fonction d'auto-covariance, la fonction d'auto-corrélation de X
- ③ Ce processus est-il stationnaire ?

Exercice 8

On considère un bruit blanc $(\varepsilon_t, t \in \mathbb{Z})$, et on définit

$$X_t = (-1)^t \varepsilon_t$$

- ❶ Calculer l'espérance et la variance de X_t .
- ❷ Calculer la fonction d'auto-covariance, la fonction d'auto-corrélation de X
- ❸ Ce processus est-il stationnaire ?

Proposition 3

Soit $(X_t, t \in \mathbb{Z})$ un processus stationnaire. Si $(a_i, i \in \mathbb{Z})$ est une suite de nombres réels absolument sommable : $\sum_{i=-\infty}^{\infty} |a_i| < \infty$, alors :

$$Y_t = \sum_{i=-\infty}^{\infty} a_i X_{t-i}$$

est un processus stationnaire.

Conséquence : les processus suivants sont stationnaires :

$$Y_t = \sum_{i=0}^{\infty} a_i X_{t-i}, \quad Y_t = \sum_{i=0}^{\infty} \alpha^i X_{t-i} \text{ avec } |\alpha| < 1.$$

Fonction d'auto-corrélations partielle

Soit $(X_t, t \in \mathbb{Z})$ un processus stationnaire.

On considère la régression affine de X_t sur $(1, X_{t-1}, X_{t-2}, \dots, X_{t-h})$, notée $X_{t,h}^*$:

$$X_t = \underbrace{a_{0,h} + a_{1,h}X_{t-1} + a_{2,h}X_{t-2} + \dots + a_{h,h}X_{t-h}}_{X_{t,h}^*} + u_t$$

avec $\mathbb{E}[u_t] = 0$ et $\text{Cov}(u_t, X_{t-i}) = 0, \forall i = 1, 2, \dots, h, \forall t \in \mathbb{Z}$.

On note $r_h = a_{h,h}$, pour $h = 1, 2, \dots$

r_h est l'auto-corrélation partielle d'ordre h .

Définition 5

Soit $(X_t, t \in \mathbb{Z})$ un processus stationnaire. L'*auto-corrélation partielle* d'ordre h est le coefficient de X_{t-h} dans la régression de X_t sur $X_{t-1}, X_{t-2}, \dots, X_{t-h}$.

On pose $r_0 = 1$

$h \mapsto r_h, \forall h \in \mathbb{N}$ est la fonction d'auto-corrélation partielle.

On représente les auto-corrélations partielles sur un diagramme en bâton appelé auto-corrélogramme partiel.

Le calcul de k autocorrélations partielles nécessite l'estimation de k régressions

Calcul de r_1

$$X_t = a_{0,1} + r_1 X_{t-1} + u_t$$

Calcul de r_2

$$X_t = a_{0,2} + a_{1,2} X_{t-1} + r_2 X_{t-2} + u_t$$

Calcul de r_3

$$X_t = a_{0,3} + a_{1,3} X_{t-1} + a_{2,3} X_{t-2} + r_3 X_{t-3} + u_t$$

Auto-corrélation partielle d'ordre 1

$$X_t = a_{0,1} + r_1 X_{t-1} + u_t$$

avec $\mathbb{E}[u_t X_{t-1}] = 0$ et $\mathbb{E}[u_t] = 0$.

$$\mathbb{E}[X_t] = a_{0,1} + r_1 \mathbb{E}[X_{t-1}] + \mathbb{E}[u_t] \Rightarrow a_{0,1} = m(1 - r_1)$$

$$X_t X_{t-1} = a_{0,1} X_{t-1} + r_1 X_{t-1}^2 + u_t X_{t-1}$$

$$\mathbb{E}[X_t X_{t-1}] = a_{0,1} \mathbb{E}[X_{t-1}] + r_1 \mathbb{E}[X_{t-1}^2] + \mathbb{E}[u_t X_{t-1}]$$

$$\mathbb{E}[X_t X_{t-1}] = m^2(1 - r_1) + r_1 \mathbb{E}[X_{t-1}^2]$$

$$\mathbb{E}[X_t X_{t-1}] - m^2 = r_1 (\mathbb{E}[X_{t-1}^2] - m^2)$$

$$r_1 = \frac{\mathbb{E}[X_t X_{t-1}] - m^2}{\mathbb{E}[X_{t-1}^2] - m^2} = \frac{\text{Cov}(X_t, X_{t-1})}{\mathbb{V}[X_{t-1}]} = \frac{\gamma_1}{\gamma_0} = \rho_1$$

Proposition 4

Soit $(X_t, t \in \mathbb{Z})$ un processus stationnaire. L'auto-corrélation partielle d'ordre 1 est égale à l'auto-corrélation d'ordre 1 :

$$r_1 = \rho_1$$

Auto-corrélation partielle d'ordre 2

$$X_t = a_{0,2} + a_{1,2}X_{t-1} + r_2X_{t-2} + u_t$$

avec $\mathbb{E}[u_t X_{t-1}] = \mathbb{E}[u_t X_{t-2}] = 0$ et $\mathbb{E}[u_t] = 0$.

$$\mathbb{E}[X_t] = a_{0,2} + a_{1,2}\mathbb{E}[X_{t-1}] + r_2\mathbb{E}[X_{t-2}] + \mathbb{E}[u_t] \Rightarrow a_{0,2} = m(1 - a_{1,2} - r_2)$$

$$X_t X_{t-1} = a_{0,2}X_{t-1} + a_{1,2}X_{t-1}^2 + r_2X_{t-1}X_{t-2} + u_t X_{t-1}$$

$$\mathbb{E}[X_t X_{t-1}] = a_{0,2}\mathbb{E}[X_{t-1}] + a_{1,2}\mathbb{E}[X_{t-1}^2] + r_2\mathbb{E}[X_{t-1}X_{t-2}]$$

$$\mathbb{E}[X_t X_{t-1}] = m^2(1 - r_1) + r_1\mathbb{E}[X_{t-1}^2]$$

$$\mathbb{E}[X_t X_{t-1}] - m^2 = a_{1,2}(\mathbb{E}[X_{t-1}^2] - m^2) + r_2(\mathbb{E}[X_{t-2}X_{t-1}] - m^2)$$

$$\gamma_1 = a_{1,2}\gamma_0 + r_2\gamma_1$$

$$X_t X_{t-2} = a_{0,2} X_{t-2} + a_{1,2} X_{t-1} X_{t-2} + r_2 X_{t-2}^2 + u_t X_{t-2}$$

$$\mathbb{E}[X_t X_{t-2}] = m(1 - a_{1,2} - r_2) \mathbb{E}[X_{t-2}] + a_{1,2} \mathbb{E}[X_{t-1} X_{t-2}] + r_2 \mathbb{E}[X_{t-2}^2]$$

$$\mathbb{E}[X_t X_{t-2}] - m^2 = a_{1,2} (\mathbb{E}[X_{t-1} X_{t-2}] - m^2) + r_2 (\mathbb{E}[X_{t-2}^2] - m^2)$$

$$\gamma_2 = a_{1,2} \gamma_1 + r_2 \gamma_0$$

$$\Rightarrow \begin{cases} \gamma_1 &= a_{1,2} \gamma_0 + r_2 \gamma_1 \\ \gamma_2 &= a_{1,2} \gamma_1 + r_2 \gamma_0 \end{cases}$$

$$\begin{cases} \rho_1 &= a_{1,2} + r_2 \gamma_1 \\ \rho_2 &= a_{1,2} \rho_1 + r_2 \end{cases}$$

$$\begin{pmatrix} \rho_1 \\ \rho_2 \end{pmatrix} = \begin{pmatrix} 1 & \rho_1 \\ \rho_1 & 1 \end{pmatrix} \begin{pmatrix} a_{1,2} \\ r_2 \end{pmatrix}$$

Proposition 5

Soit $(X_t, t \in \mathbb{Z})$ un processus stationnaire. L'auto-corrélation partielle d'ordre 2 est égale à :

$$r_2 = \frac{\rho_2 - \rho_1^2}{1 - \rho_1^2}$$

Exercice

$$\begin{pmatrix} \rho_1 \\ \rho_2 \\ \rho_3 \end{pmatrix} = \begin{pmatrix} 1 & \rho_1 & \rho_2 \\ \rho_1 & 1 & \rho_1 \\ \rho_2 & \rho_1 & 1 \end{pmatrix} \begin{pmatrix} a_{1,3} \\ a_{2,3} \\ r_3 \end{pmatrix} = R_2 \begin{pmatrix} a_{1,3} \\ a_{2,3} \\ r_3 \end{pmatrix}$$

En déduire que :

$$r_3 = \frac{\begin{vmatrix} 1 & \rho_1 & \rho_1 \\ \rho_1 & 1 & \rho_2 \\ \rho_2 & \rho_1 & \rho_3 \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 & \rho_2 \\ \rho_1 & 1 & \rho_1 \\ \rho_2 & \rho_1 & 1 \end{vmatrix}}$$

Proposition 6

Soit $(X_t, t \in \mathbb{Z})$ un processus stationnaire. L'auto-corrélation partielle d'ordre h , r_h , est obtenue en résolvant le système :

$$\begin{pmatrix} \rho_1 \\ \rho_2 \\ \vdots \\ \rho_h \end{pmatrix} = R_{h-1} \begin{pmatrix} a_{1,h} \\ a_{2,h} \\ \vdots \\ r_h \end{pmatrix}$$

On peut calculer les auto-corrélations partielles grâce à l'algorithme de Durbin-Levinson.

Innovation

Soit $(X_t, t \in \mathbb{Z})$ un processus.

On considère l'espace engendré par le passé de la variable :

$$I_{t-1} = H \{X_{t-1}, X_{t-2}, X_{t-3}, \dots\}$$

Cet espace représente l'information engendrée par le passé de la variable. Cette information est croissante : il n'y a ni perte, ni omission d'information.

La projection orthogonale notée $\mathbb{E}[X_t | I_{t-1}]$ est la meilleure approximation de X_t qui s'écrit sous la forme d'une combinaison linéaire des variables passées :

$$\|X_t - \mathbb{E}[X_t | I_{t-1}]\| = \min_{Z \in I_{t-1}} \|X_t - Z\|$$

et $\langle X_t - \mathbb{E}[X_t | I_{t-1}], X_{t-i} \rangle = 0, \forall i \geq 1.$

Cette projection peut s'écrire sous la forme :

$$\mathbb{E}\mathbb{L}[X_t|I_{t-1}] = a_0 + a_1X_{t-1} + a_2X_{t-2} + \dots$$

Définition 6

Soit $(X_t, t \in \mathbb{Z})$ un processus. L'innovation de X_t est

$$\varepsilon_t = X_t - \mathbb{E}\mathbb{L}[X_t|I_{t-1}]$$

où $\mathbb{E}\mathbb{L}[X_t|I_{t-1}]$ est la régression affine de X_t sur l'espace I_{t-1} engendré par le passé de la variable.

Proposition 7

Si $(X_t, t \in \mathbb{Z})$ est un processus stationnaire, alors son innovation est un bruit blanc.

Proposition 8 (Décomposition de Wold)

Si $(X_t, t \in \mathbb{Z})$ est un processus stationnaire tel que :

$$\lim_{k \rightarrow \infty} \mathbb{E}[X_t | X_{t-k}, X_{t-k-1}, \dots] = \mathbb{E}[X_t],$$

alors il existe un bruit blanc $(\varepsilon_t, t \in \mathbb{Z})$ tel que :

$$\begin{aligned} X_t &= m + \varepsilon_t + \alpha_1 \varepsilon_{t-1} + \alpha_2 \varepsilon_{t-2} + \dots \\ &= m + \sum_{i=0}^{\infty} \alpha_i \varepsilon_{t-i} \end{aligned}$$

avec $\alpha_0 = 1$ et $1 + \alpha_1^2 + \alpha_2^2 + \dots < \infty$.

Le bruit blanc ε est l'innovation de X . On parle d'écriture **moyenne mobile infinie** ($MA(\infty)$).

Meilleur prédicteur et meilleur prédicteur linéaire

Généralement le prédicteur optimal $\mathbb{E}[X_t | X_{t-1}, X_{t-2}, \dots]$ n'est pas connu. Il peut s'agir d'une fonction très compliquée de $X_{t-1}, X_{t-2}, \dots$ et on considère : $\mathbb{E}[X_t | X_{t-k}, X_{t-k-1}, \dots]$, le meilleur prédicteur linéaire de X_t .

Rappels et exemple

Le meilleur prédicteur de Y sachant X est l'espérance conditionnelle $\mathbb{E}[Y|X]$.

En général, ce prédicteur n'est pas linéaire en X , sauf lorsque la loi jointe de (X, Y) est normale bivariée. Si :

$$\begin{pmatrix} X \\ Y \end{pmatrix} \rightarrow \mathcal{N} \left(\begin{pmatrix} m_X \\ m_Y \end{pmatrix}; \begin{pmatrix} \sigma_X^2 & \sigma_{X,Y} \\ \sigma_{X,Y} & m_Y \end{pmatrix} \right)$$

alors

$$Y|X \rightarrow \mathcal{N} \left(m_Y + \frac{\sigma_{X,Y}}{\sigma_X^2}(X - m_X); (1 - \rho^2)\sigma_Y^2 \right)$$

Donc : $\mathbb{E}[Y|X] = m_Y + \frac{\sigma_{X,Y}}{\sigma_X^2}(X - m_X)$ est le meilleur prédicteur de Y sachant X et est linéaire en X .

De manière plus générale, si (X, Y) ne suit pas une loi normale bivariée, par exemple si la loi jointe est :

X/Y	0	1	2	3	
0	0.1	0	0	0.1	0.2
1	0	0.2	0.1	0	0.3
2	0.2	0.2	0	0.1	0.5
	0.3	0.4	0.1	0.2	1

On a :

$$\mathbb{E}[X] = 0 \times 0.2 + 1 \times 0.3 + 2 \times 0.5 = 1.3$$

$$\mathbb{E}[Y] = 1.2$$

$$\mathbb{E}[X^2] = 0 \times 0.2 + 1 \times 0.3 + 4 \times 0.5 = 2.3$$

$$\mathbb{E}[Y^2] = 2.6$$

$$\mathbb{V}[X] = 2.3 - 1.3^2 = 0.61$$

$$\mathbb{V}[Y] = 1.16$$

$$\mathbb{E}[XY] = 1 \times 0.2 + 2 \times 0.1 + 2 \times 0.2 + 6 \times 0.1 = 1.4$$

$$\sigma_{X,Y} = 1.4 - 1.3 \times 1.2 = -0.16$$

On a

$$\mathbb{E}\mathbb{L}[Y|X] = m_Y + \frac{\sigma_{X,Y}}{\sigma_X^2}(X - m_X) = 1.2 - \frac{0.16}{0.61}(X - 1.3)$$

$$\mathbb{E}\mathbb{L}[Y|X = 0] = 1.2 - \frac{0.16}{0.61}(0 - 1.3) = 1.54$$

$$\mathbb{E}\mathbb{L}[Y|X = 1] = 1.2 - \frac{0.16}{0.61}(1 - 1.3) = 1.28$$

$$\mathbb{E}\mathbb{L}[Y|X = 2] = 1.2 - \frac{0.16}{0.61}(2 - 1.3) = 1.02$$

Calcul du meilleur prédicteur de Y sachant X , $\mathbb{E}[Y|X]$

On doit d'abord calculer les probabilités conditionnelles :

$$\mathbb{P}_{Y|X=0}(0) = 0.1/0.2, \quad \mathbb{P}_{Y|X=0}(1) = 0/0.2, \dots$$

puis les espérances suivantes :

$$\mathbb{E}[Y|X=0] = 0 \times 0.5 + 1 \times 0 + 2 \times 0 + 3 \times 0.5 = 1.5$$

$$\mathbb{E}[Y|X=1] = 0 \times 0 + 1 \times \frac{2}{3} + 2 \times \frac{1}{3} + 3 \times 0 = \frac{4}{3}$$

$$\mathbb{E}[Y|X=2] = 0 \times \frac{2}{5} + 1 \times \frac{2}{5} + 2 \times 0 + 3 \times \frac{1}{5} = 1$$

Les deux variables $\mathbb{E}L[Y|X]$ et $\mathbb{E}[Y|X]$ sont distinctes. Elles prennent des valeurs différentes avec des probabilités différentes.

On peut voir qu'elles ont la même espérance : 1.2.

On peut aussi montrer que $\mathbb{E}L[Y|X]$ et $\mathbb{E}[Y|X]$ sont des prédicteurs sans biais de Y .

$\mathbb{E}[Y|X]$ est le prédicteur optimal au sens des moindres carrés.

$$\begin{aligned}\mathbb{E}[(Y - \mathbb{E}[Y|X])^2] &= \mathbb{E}[Y] - \mathbb{E}[\mathbb{E}[Y|X]^2] \\ &= 2.6 - (1.5^2 \times 0.2 + 1.33^2 \times 0.3 + 1^2 \times 0.5) = 1,11667\end{aligned}$$

Tandis que

$$\begin{aligned}\mathbb{E}[(Y - \mathbb{E}[Y|X])^2] &= \mathbb{E}\left[\left(Y - m_Y - \frac{\sigma_{X,Y}}{\sigma_X^2}(X - m_X)\right)^2\right] \\ &= \mathbb{E}[(Y - m_Y)^2] + \frac{\sigma_{X,Y}^2}{\sigma_X^4} \mathbb{E}[(X - m_X)^2] \\ &\quad - \frac{\sigma_{X,Y}}{\sigma_X^2} \mathbb{E}[(X - m_X)(Y - m_Y)] \\ &= \mathbb{V}[Y] - \frac{\sigma_{X,Y}^2}{\sigma_X^2} = 1,11803\end{aligned}$$

On a bien $\mathbb{E}[(Y - \mathbb{E}[Y|X])^2] \leq \mathbb{E}[(Y - \mathbb{E}[Y])^2]$

L'opérateur retard noté B (ou L)

$$BX_t = X_{t-1}$$

$$B^2X_t = B(BX_t) = BX_{t-1} = X_{t-2}$$

$$B^kX_t = X_{t-k}$$

On peut considérer des polynômes en B , à coefficients réels :

$$A(B) = a_0 + a_1B + a_2B^2 + \cdots + a_pB^p$$

$$\begin{aligned}\rightarrow A(B)X_t &= (a_0 + a_1B + a_2B^2 + \cdots + a_pB^p) X_t \\ &= a_0X_t + a_1BX_t + a_2B^2X_t + \cdots + a_pB^pX_t \\ &= a_0X_t + a_1BX_{t-1} + a_2B^2X_{t-2} + \cdots + a_pB^pX_{t-p}\end{aligned}$$

ou, même, des séries en B à coefficients réels :

$$\begin{aligned} A(B) &= \sum_{i=0}^{\infty} a_i B^i \\ \rightarrow A(B)X_t &= \left(\sum_{i=0}^{\infty} a_i B^i \right) X_t \\ &= a_0 X_t + a_1 B X_t + \dots \\ &= a_0 X_t + a_1 B X_{t-1} + \dots \end{aligned}$$

On a aussi $B^{-1}X_t = X_{t+1}$

- L'opérateur de différence (première) : $1 - B$
- L'opérateur de différence saisonnière : $1 - B^s$

Les processus autorégressifs

Un processus autorégressif d'ordre p est un processus stationnaire s'écrivant sous la forme :

$$X_t = \varphi_1 X_{t-1} + \varphi_2 X_{t-2} + \cdots + \varphi_p X_{t-p} + \varepsilon_t$$

où : $\varphi_1, \dots, \varphi_p \in \mathbb{R}$, $\varphi_p \neq 0$ et ε est un bruit blanc.

On parle alors de processus $AR(p)$.

On introduit le polynôme

$$\Phi(B) = 1 - \varphi_1 B - \dots - \varphi_p B^p$$

qui permet d'écrire le modèle autorégressif sous une forme très compacte :

$$X_t = \varphi_1 X_{t-1} + \varphi_2 X_{t-2} + \dots + \varphi_p X_{t-p} + \varepsilon_t$$

$$X_t - \varphi_1 X_{t-1} - \varphi_2 X_{t-2} - \dots - \varphi_p X_{t-p} = \varepsilon_t$$

$$(1 - \varphi_1 B - \dots - \varphi_p B^p) X_t = \varepsilon_t$$

$$\Phi(B) X_t = \varepsilon_t$$

Exemple : le processus autorégressif d'ordre 1

Un processus autorégressif d'ordre 1 est un processus stationnaire X défini par :

$$X_t = \varphi X_{t-1} + \varepsilon_t$$

où $\varphi \in \mathbb{R}$ et ε est un bruit blanc.

On peut écrire :

$$X_t - \varphi X_{t-1} = \underbrace{(1 - \varphi B)}_{\Phi(B)} X_t = \varepsilon_t$$

Par remplacements successifs, on obtient :

$$\begin{aligned} X_t &= \varphi \underbrace{X_{t-1}}_{\varphi X_{t-2} + \varepsilon_{t-1}} + \varepsilon_t = \varphi(\varphi X_{t-2} + \varepsilon_{t-1}) + \varepsilon_t \\ &= \varepsilon_t + \varphi \varepsilon_{t-1} + \varphi^2 X_{t-2} \\ &= \varepsilon_t + \varphi \varepsilon_{t-1} + \varphi^2 (\varphi X_{t-3} + \varepsilon_{t-2}) \\ &\vdots \\ &= \varepsilon_t + \varphi \varepsilon_{t-1} + \cdots + \varphi^{k-1} \varepsilon_{t-k+1} + \varphi^k X_{t-k} \end{aligned}$$

Intuitivement, si $-1 < \varphi < 1$, alors $\lim_{k \rightarrow \infty} \varphi^k = 0$ et on obtient l'écriture moyenne-mobile infinie du processus :

$$\begin{aligned} X_t &= \varepsilon_t + \varphi \varepsilon_{t-1} + \cdots + \varphi^{k-1} \varepsilon_{t-k+1} + \cdots = \sum_{i=0}^{\infty} \varphi^i \varepsilon_{t-i} \\ &= \left(\sum_{i=0}^{\infty} \varphi^i B^i \right) \varepsilon_t \end{aligned}$$

Pour $-1 < \varphi < 1$: $X_t = \varphi X_{t-1} + \varepsilon_t$

- $X_t = (\sum_{i=0}^{\infty} \varphi^i B^i) \varepsilon_t$ est stationnaire car $\sum_{i=0}^{\infty} |\varphi^i| < \infty$
- $X_t = (\sum_{i=0}^{\infty} \varphi^i B^i) \varepsilon_t$ est solution du modèle
- $X_t = (\sum_{i=0}^{\infty} \varphi^i B^i) \varepsilon_t + A\varphi^t$ est aussi solution du modèle mais n'est pas stationnaire si $A \neq 0$.

Liens entre les deux écritures

On a deux écritures "équivalentes" pour $|\varphi| < 1$:

$$(1 - \varphi B)X_t = \varepsilon_t \Leftrightarrow X_t = \left(\sum_{i=0}^{\infty} \varphi^i B^i \right) \varepsilon_t$$

On peut donc en conclure que

$$(1 - \varphi B)^{-1} = \sum_{i=0}^{\infty} \varphi^i B^i$$

Généralisation : inversion d'un polynôme en B

Soit $A(B) = a_0 + a_1B + a_2B^2 + \cdots + a_pB^p$.

Le polynôme $P(B)$ est l'inverse du polynôme $A(B)$ si

$$P(B)A(B)X_t = X_t,$$

quel que soit t et quel que soit le processus du second ordre $(X_t, t \in \mathbb{Z})$.

On note souvent ce polynôme inverse $A^{-1}(B)$. On a alors :

$$A^{-1}(B)A(B)X_t = X_t.$$

Comment déterminer $A^{-1}(B)$?

Généralisation : rappel

Soit $A(x) = ax^2 + bx + c$.

L'équation $ax^2 + bx + c = 0$ a deux solutions notées x_1^* et x_2^* qui sont réelles si $b^2 - 4ac \geq 0$, complexes si $b^2 - 4ac < 0$.

$$\begin{aligned} A(x) &= a(x - x_1^*)(x - x_2^*) = a(x^2 - xx_2^* - x_1^*x + x_1^*x_2^*) \\ &= ax^2 - a(x_1^* + x_2^*)x + ax_1^*x_2^* \end{aligned}$$

On a alors $x_1^* + x_2^* = \frac{-b}{a}$ et $x_1^*x_2^* = \frac{c}{a}$. et

$$\begin{aligned} A(x) &= x(x - x_1^*)(x - x_2^*) = a(-x_1^*) \left(1 - \frac{x}{x_1^*}\right) (-x_2^*) \left(1 - \frac{x}{x_2^*}\right) \\ &= c \left(1 - \frac{x}{x_1^*}\right) \left(1 - \frac{x}{x_2^*}\right) \end{aligned}$$

De même $A(x) = a_0 + a_1x + a_2x^2 + \cdots + a_px^p$ peut toujours être factorisé sous la forme :

$$A(x) = a_p(x - x_1^*)(x - x_2^*) \cdots (x - x_p^*)$$

où $x_1^*, x_2^*, \dots, x_p^*$ sont les racines du polynôme, c'est-à-dire les solutions de l'équation

$$a_0 + a_1x + a_2x^2 + \cdots + a_px^p = 0.$$

Par conséquent

$$\begin{aligned} A(x) &= a_p(x - x_1^*)(x - x_2^*) \cdots (x - x_p^*) \\ &= a_p(-x_1^*) \left(1 - \frac{x}{x_1^*}\right) (-x_2^*) \left(1 - \frac{x}{x_2^*}\right) \cdots (-x_p^*) \left(1 - \frac{x}{x_p^*}\right). \end{aligned}$$

On a donc

$$A(x) = a_0 \left(1 - \frac{x}{x_1^*}\right) \left(1 - \frac{x}{x_2^*}\right) \cdots \left(1 - \frac{x}{x_p^*}\right).$$

Un polynôme en B , $\Phi(B)$, peut toujours être factorisé :

$$1 - \varphi_1 B - \dots - \varphi_p B^p = \left(1 - \frac{B}{x_1^*}\right) \left(1 - \frac{B}{x_2^*}\right) \dots \left(1 - \frac{B}{x_p^*}\right)$$

où $x_1^*, x_2^*, \dots, x_p^*$ sont les p solutions de l'équation caractéristique :

$$1 - \varphi_1 x - \varphi_2 x^2 - \dots - \varphi_p x^p = 0.$$

En comparant avec les résultats précédents, si on suppose que $|1/x_k^*| < 1$ ou $|x_k^*| > 1$:

$$\left(1 - \frac{B}{x_k^*}\right)^{-1} = \sum_{i=0}^{\infty} \left(\frac{1}{x_k^*}\right)^i B^i$$

On peut donc calculer l'inverse de $\Phi(B)$, si on suppose que $|x_k^*| > 1$, $k = 1, \dots, p$:

$$\begin{aligned}\Phi^{-1}(B) &= \left(1 - \frac{B}{x_1^*}\right) \left(1 - \frac{B}{x_2^*}\right) \cdots \left(1 - \frac{B}{x_p^*}\right) \\ &= \left[\sum_{i=0}^{\infty} \left(\frac{1}{x_1^*}\right)^i B^i \right] \cdots \left[\sum_{i=0}^{\infty} \left(\frac{1}{x_p^*}\right)^i B^i \right] \\ &= \sum_{k=0}^{\infty} \alpha_k B^k\end{aligned}$$

où les coefficients α_k sont des fonctions compliquées des coefficients $\varphi_1, \dots, \varphi_p$.

Exemple

$$X_t = \frac{3}{4}X_{t-1} - \frac{1}{8}X_{t-2} + \varepsilon_t$$

$$\Rightarrow X_t - \frac{3}{4}X_{t-1} + \frac{1}{8}X_{t-2} = \varepsilon_t$$

$$\Rightarrow \left(1 - \frac{3}{4}B + \frac{1}{8}B^2\right) X_t = \varepsilon_t$$

L'équation caractéristique est :

$$1 - \frac{3}{4}x + \frac{1}{8}x^2 = 0$$

Les solutions $x_1^* = 2$ et $x_2^* = 4$ sont strictement supérieures à 1.

Le polynôme $1 - \frac{3}{4}B + \frac{1}{8}B^2$ est inversible.

Son inverse est

$$\begin{aligned}
 \Phi^{-1}(B) &= \left(1 - \frac{3}{4}B + \frac{1}{8}B^2\right)^{-1} = \left(1 - \frac{1}{2}B\right)^{-1} \left(1 - \frac{1}{4}B\right)^{-1} \\
 &= \left[\sum_{i=0}^{\infty} \left(\frac{1}{2}\right)^i B^i\right] \left[\sum_{i=0}^{\infty} \left(\frac{1}{4}\right)^i B^i\right] \\
 &= \sum_{i=0}^{\infty} \sum_{j=0}^{\infty} \left(\frac{1}{2}\right)^i \left(\frac{1}{2}\right)^{2j} B^{i+j} = \sum_{i=0}^{\infty} \sum_{j=0}^{\infty} \frac{1}{2^{i+2j}} B^{i+j} = \sum_{j=0}^{\infty} \sum_{k=j}^{\infty} \frac{1}{2^{k+j}} B^k \\
 &= \sum_{k=0}^{\infty} \frac{1}{2^j} \underbrace{\sum_{j=0}^k \frac{1}{2^j}}_{2 - \frac{1}{2^k}} B^k = \sum_{k=0}^{\infty} \underbrace{\frac{1}{2^k} \left(2 - \frac{1}{2^k}\right)}_{\alpha_k} B^k = \sum_{k=0}^{\infty} \alpha_k B^k
 \end{aligned}$$

Il existe une solution stationnaire dont l'écriture moyenne-mobile infinie est :

$$X_t = \left(\sum_{k=0}^{\infty} \alpha_k B^k \right) \varepsilon_t = \varepsilon_t + \frac{3}{4} \varepsilon_{t-1} + \frac{7}{16} \varepsilon_{t-2} + \dots$$

Conclusion

Pour que le processus soit stationnaire, il faut que les coefficients remplissent des contraintes assez compliquées : il faut que les p solutions $x_1^*, x_2^*, \dots, x_p^*$ de l'équation caractéristique

$$1 - \varphi_1 x - \varphi_2 x^2 - \dots - \varphi_p x^p = 0$$

soient telles que $|x_i^*| > 1, i = 1, \dots, p$.

- Si ces contraintes sont satisfaites, le processus X_t peut s'écrire sous forme moyenne-mobile infinie $MA(\infty)$:

$$X_t = \varepsilon_t + \alpha_1 \varepsilon_{t-1} + \alpha_2 \varepsilon_{t-2} + \cdots$$

- Innovation de X_t :

$$\mathbb{E}[X_t | X_{t-1}, X_{t-2}, \cdots] = \varphi_1 X_{t-1} + \cdots + \varphi_p X_{t-p}$$

Donc $X_t - \mathbb{E}[X_t | X_{t-1}, X_{t-2}, \cdots] = \varepsilon_t$.

ε_t est l'innovation de X_t .

Les processus moyennes-mobiles

Un processus moyenne-mobile d'ordre q est un processus s'écrivant sous la forme :

$$X_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} - \cdots - \theta_q \varepsilon_{t-q}$$

où $\theta_1, \dots, \theta_q \in \mathbb{R}, \theta_q \neq 0$ et ε est un bruit blanc.

On parle de processus $MA(q)$

Le processus est toujours stationnaire, quelles que soient les valeurs des coefficients $\theta_1, \dots, \theta_q$.

On peut introduire le polynôme

$$\Theta(B) = 1 - \theta_1 B - \theta_2 B^2 - \dots - \theta_q B^q$$

et écrire :

$$\begin{aligned} X_t &= \varepsilon_t - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q} \\ &= (1 - \theta_1 B - \dots - \theta_q B^q) \varepsilon_t \\ &= \Theta(B) \varepsilon_t. \end{aligned}$$

- Pour que ε soit l'innovation du processus X , il faut que les q solutions $x_1^*, x_2^*, \dots, x_q^*$ de l'équation caractéristique

$$1 - \theta_1 x - \theta_2 x^2 - \dots - \theta_q x^q = 0$$

soient telles que $|x_i^*| > 1, i = 1, \dots, q$.

- Si ces contraintes sont satisfaites, le processus X_t peut s'écrire sous forme autorégressive infinie $AR(\infty)$

$$X_t = \alpha_1 X_{t-1} + \alpha_2 X_{t-2} + \dots + \varepsilon_t$$

et on dit que le processus est inversible.

Les processus autorégressifs moyennes-mobiles

Un processus autorégressif moyenne mobile d'ordre p et q est un processus stationnaire s'écrivant sous la forme :

$$X_t = \varphi_1 X_{t-1} + \cdots + \varphi_p X_{t-p} + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \cdots - \theta_q \varepsilon_{t-q}$$

où $\varphi_1, \dots, \varphi_p, \theta_1, \dots, \theta_q \in \mathbb{R}, \theta_q \neq 0$ et ε un bruit blanc.

On parle de processus $ARMA(p, q)$.

On peut introduire les deux polynômes $\Phi(B)$ et $\Theta(B)$:

$$\Phi(B) = 1 - \varphi_1 B - \dots - \varphi_p B^p$$

$$\Theta(B) = 1 - \theta_1 B - \dots - \theta_q B^q$$

pour écrire :

$$X_t = \varphi_1 X_{t-1} + \dots + \varphi_p X_{t-p} + \varepsilon_t - \theta_1 \varepsilon_{t-1} - \dots - \theta_q \varepsilon_{t-q}$$

On a donc

$$\Phi(B)X_t = \Theta(B)\varepsilon_t.$$

- Pour que le processus soit stationnaire, il faut que les p solutions $x_1^*, x_2^*, \dots, x_p^*$ de l'équation caractéristique

$$1 - \varphi_1 x + \varphi_2 x^2 + \dots + \varphi_p x^p = 0$$

soient telles que $|x_i^*| > 1, i = 1, \dots, p$.

- Pour que ε soit l'innovation du processus X , il faut que les q solutions $x_1^*, x_2^*, \dots, x_q^*$ de l'équation caractéristique

$$1 - \theta_1 x + \theta_2 x^2 + \dots + \theta_q x^q = 0$$

soient telles que $|x_i^*| > 1, i = 1, \dots, q$.

Exercice

On considère le modèle :

$$X_t = \frac{4}{3}X_{t-1} - \frac{1}{3}X_{t-2} + \varepsilon_t - \frac{1}{4}\varepsilon_{t-1}$$

où ε est un bruit blanc.

- Ce modèle admet-il une solution stationnaire ? Justifiez votre réponse.
- Est-il possible d'écrire X_t sous forme autorégressive infinie ? Si oui, expliquez comment on obtient cette écriture. Si non, expliquez pourquoi.

Le modèle s'écrit :

$$\left(1 - \frac{4}{3}B + \frac{1}{3}B^2\right) X_t = \left(1 - \frac{1}{4}B\right) \varepsilon_t$$

Le polynôme autorégressif est $\Phi(B) = 1 - \frac{4}{3}B + \frac{1}{3}B^2$. L'équation caractéristique associée est

$$1 - \frac{4}{3}x + \frac{1}{3}x^2 = 0$$

Elle admet deux solutions : $x_1^* = 1$ et $x_2^* = 3$. Le modèle n'admet pas de solution stationnaire X_t .

On peut écrire

$$\Phi(B) = 1 - \frac{4}{3}B + \frac{1}{3}B^2 = \left(1 - \frac{1}{3}B\right) (1 - B)$$

Le modèle devient

$$\left(1 - \frac{1}{3}B\right) (1 - B)X_t = \left(1 - \frac{1}{4}B\right) \varepsilon_t$$

Si on définit $Z_t = (1 - B)X_t$, on a :

$$\left(1 - \frac{1}{3}B\right) Z_t = \left(1 - \frac{1}{4}B\right) \varepsilon_t$$

Ce modèle admet une solution stationnaire Z_t :

$$Z_t = \left(1 - \frac{1}{3}B\right)^{-1} \left(1 - \frac{1}{4}B\right) \varepsilon_t$$

On peut en établir le développement moyenne-mobile infinie :

$$\begin{aligned}
Z_t &= \left(1 - \frac{1}{3}B\right)^{-1} \left(1 - \frac{1}{4}B\right) \varepsilon_t = \left(\sum_{i=0}^{\infty} \frac{1}{3^i} B^i\right) \left(1 - \frac{1}{4}B\right) \varepsilon_t \\
&= \left(\sum_{i=0}^{\infty} \frac{1}{3^i} B^i - \frac{1}{4} \sum_{i=0}^{\infty} \frac{1}{3^i} B^{i+1}\right) \varepsilon_t \\
&= \left(\sum_{i=0}^{\infty} \frac{1}{3^i} B^i - \frac{1}{4} \sum_{k=1}^{\infty} \frac{1}{3^{k-1}} B^k\right) \varepsilon_t \\
&= \left(1 + \sum_{k=1}^{\infty} \left(\frac{1}{3^k} - \frac{1}{4} \frac{1}{3^{k-1}} B^k\right) B^k\right) \varepsilon_t \\
&= \left(1 + \sum_{k=1}^{\infty} \left(\frac{1}{3^{k-1}} \left(\frac{1}{3} - \frac{1}{4}\right)\right) B^k\right) \varepsilon_t \\
&= \left(1 + \frac{1}{12} \sum_{k=1}^{\infty} \left(\frac{1}{3^{k-1}}\right) B^k\right) \varepsilon_t
\end{aligned}$$

$$\left(1 - \frac{4}{3}B + \frac{1}{3}B^2\right) X_t = \left(1 - \frac{1}{4}B\right) \varepsilon_t$$

Le polynôme moyenne-mobile est :

$$\Theta(B) = 1 - \frac{1}{4}B$$

L'équation caractéristique associée est

$$1 - \frac{1}{4}x = 0$$

Elle admet une solution unique : $x_1^* = 4$ qui est, en module, strictement supérieure à 1. Le processus X_t est donc inversible et on a :

$$\left(1 - \frac{1}{4}B\right)^{-1} \left(1 - \frac{4}{3}B + \frac{1}{3}B^2\right) X_t = \varepsilon_t.$$

$$\left(1 - \frac{1}{4}B\right)^{-1} \left(1 - \frac{4}{3}B + \frac{1}{3}B^2\right) X_t = \varepsilon_t$$

$$\left(\sum_{i=0}^{\infty} \frac{1}{4^i} B^i\right) \left(1 - \frac{4}{3}B + \frac{1}{3}B^2\right) X_t = \varepsilon_t$$

$$\left[\left(\sum_{i=0}^{\infty} \frac{1}{4^i} B^i\right) - \frac{4}{3} \left(\sum_{i=0}^{\infty} \frac{1}{4^i} B^{i+1}\right) + \frac{1}{3} \left(\sum_{i=0}^{\infty} \frac{1}{4^i} B^{i+2}\right)\right] X_t = \varepsilon_t$$

$$\left[\left(\sum_{i=0}^{\infty} \frac{1}{4^i} B^i\right) - \frac{4}{3} \left(\sum_{j=1}^{\infty} \frac{1}{4^{j-1}} B^j\right) + \frac{1}{3} \left(\sum_{k=2}^{\infty} \frac{1}{4^{k-2}} B^k\right)\right] X_t = \varepsilon_t$$

$$\left[1 + \frac{1}{4}B - \frac{4}{3}B + \sum_{i=2}^{\infty} \frac{1}{4^i} B^i - \frac{4}{3} \sum_{j=2}^{\infty} \frac{1}{4^{j-1}} B^j + \frac{1}{3} \sum_{k=2}^{\infty} \frac{1}{4^{k-2}} B^k \right] X_t = \varepsilon_t$$

$$\left[1 - \frac{13}{12}B \sum_{i=2}^{\infty} \frac{1}{4^i} B^i \right] X_t = \varepsilon_t$$

Caractérisation des autocorrélogrammes

Processus $AR(p)$:

Les autocorrélations vérifient les équations de Yule-Walker :

$$\rho_h + \sum_{i=1}^p \varphi_i \rho_{h-i} = 0, \forall h > 0.$$

Elles sont toujours non nulles et globalement décroissantes.

Les autocorrélations partielles sont nulles à partir de l'ordre $p + 1$:

$$r_h = 0, \forall h \geq p + 1 \quad \text{et} \quad r_p = \varphi_p \neq 0.$$

Processus $MA(q)$: Les autocorrélations sont nulles à partir de l'ordre $q + 1$:

$$\rho_q = \frac{\theta_q}{1 + \theta_1^2 + \dots + \theta_q^2} \neq 0$$
$$\rho_h = 0, \forall h \geq q + 1$$

Les autocorrélations partielles sont toujours non nulles et globalement décroissantes.

Processus $ARMA(p, q)$: Les autocorrélations partielles sont non nulles et globalement décroissantes.

Méthode du coin :

$$\Delta(i, j) = \det \begin{pmatrix} \rho_i & \rho_{i-1} & \cdots & \rho_{i-(j-1)} \\ \rho_{i+1} & \rho_i & \cdots & \rho_{i-(j-2)} \\ \vdots & \vdots & & \vdots \\ \rho_{i+j-1} & \rho_{i+j-2} & \cdots & \rho_i \end{pmatrix}$$

On montre que

$$\Delta(i, j) = 0, \forall i \geq p, \forall j \geq q$$


$$\Delta(i, q-1) \neq 0, \forall i \geq p_1$$


$$\Delta(p-1, j) \neq 0, \forall j \geq q-1$$

i	j	0	1	...	$q-1$	q	$q+1$	...
0								
1								
$\vdots$								
$p-1$					$\neq 0$	$\neq 0$	$\neq 0$	...
p					$\neq 0$	0	0	...
$p+1$					$\neq 0$	0	0	...
$\vdots$					$\vdots$	$\vdots$	$\vdots$	

Exemple d'un $AR(2)$


Série artificielle 1








Exemple d'un $AR(4)$


Série artificielle 2





Exemple d'une série saisonnière





Processus intégrés

Il s'agit de processus non stationnaires, qui se ramènent par différenciation à un processus stationnaire.

Exemple : la marche aléatoire

$$X_t = X_{t-1} + \varepsilon_t$$

X n'est pas stationnaire

$$Y_t = X_t - X_{t-1} = (1 - B)X_t$$

Y est un bruit blanc et est donc stationnaire.

$(1 - B)$ est l'opérateur de différence première. $(1 - B)^d$ est l'opérateur de différence d'ordre d . Le processus X est *intégré d'ordre* d ($I(d)$) si X n'est pas stationnaire mais que Y défini par $Y_t = (1 - B)^d X_t$ est stationnaire.

On peut montrer que la marche aléatoire est un processus $I(1)$.

Le processus est *ARIMA*(p, d, q) s'il s'écrit :

$$\Phi(B)(1 - B)^d X_t = \Theta(B)\varepsilon_t$$

X n'est pas stationnaire.

$$Y_t = (1 - B)^d X_t$$

est stationnaire et *ARMA*(p, q). X est intégré d'ordre d .

Méthode de Box et Jenkins

D'après le nom de deux statisticiens George Box et Gwilym Jenkins auteurs de l'ouvrage *Time Series Analysis : Forecasting and Control*. (1970, San Fransisco : Holden-Day)

Méthode permettant de trouver en plusieurs étapes un modèle *ARMA* représentant le série statistique étudiée

- complexe
- extrapolative
- itérative

Première étape : analyse des données

Etape fondée principalement sur les représentations graphiques des données et des autocorrélogrammes ayant pour objet la **stationnarisation** de la série ainsi que la correction des **valeurs aberrantes**. On peut :


- faire une différence ordinaire :


$$(1 - B), (1 - B)^2, \dots, (1 - B)^d$$


- faire une différence saisonnière : $(1 - B^s)$
- faire une transformation affine, $\log$, $\sqrt{}$, $\dots$
- diviser par le nombre de jours (ouvrables) du mois, la taille de la population, $\dots$
- Autres méthodes

Les arrivées à l'aéroport de Saint-Denis


Arrivées par jour à l'aéroport de saint-Denis à La réunion




Arrivées par jour à l'aéroport de Saint-Denis de La Réunion - diff. première

Arrivées par jour à l'aéroport de Saint-Denis de La Réunion - diff. saisonnière

Le cours du dollar US en francs suisses



Les returns



Deuxième étape : identification du modèle



Cette étape est basée sur l'analyse des autocorrélogrammes de la série **stationnarisée** ainsi que sur la méthode du coin.

Elle aboutit au choix de la forme d'un (ou plusieurs) modèle(s) :

$$Ar(p), MA(q), ARMA(p, q), ARIMA(p, d, q), \dots$$

avec ou sans transformation des données.

Les returns



Plusieurs choix possibles sur cet exemple.

On peut par exemple remarquer que les autocorrélations partielles sont faibles au delà de l'ordre 9 et penser à un modèle $AR(9)$.

On peut aussi remarquer que les autocorrélations sont faibles au delà de l'ordre 9 et penser à un modèle $MA(9)$.

Avant de passer à la phase d'estimation, il vaut mieux séparer l'échantillon en un échantillon pour l'estimation et un échantillon-test (pour un exercice de prévision).

Troisième étape : estimation du modèle

$$(1 - \varphi_1 B - \varphi_2 B^2 - \dots - \varphi_p B^p) X_t = (1 - \theta_1 B - \dots - \theta_q B^q) \varepsilon_t,$$

avec $\mathbb{E}[\varepsilon_t] = 0$, $\mathbb{V}[\varepsilon_t] = \sigma^2$ et $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$ pour $i \neq j$.

p et q ont été déterminés lors de la phase précédente.

Il faut estimer $\varphi_1, \varphi_2, \dots, \varphi_p, \theta_1, \theta_2, \dots, \theta_q$ et σ^2 .

On utilise la méthode du maximum de vraisemblance et des logiciels spécialisés.

Modèle 1: ARMA, utilisant les observations 1985:09-2011:08 (T = 312)

Variable dépendante: ld_SWISSDOL

	coefficient	erreur std.	t	p. critique	
const	-0.00342682	0.00210883	-1.625	0.1042	
phi_1	0.0536563	0.0560715	0.9569	0.3386	
phi_2	-0.0302342	0.0563425	-0.5366	0.5915	
phi_3	0.0504921	0.0562589	0.8975	0.3695	
phi_4	-0.0808116	0.0559673	-1.444	0.1488	
phi_5	0.0342234	0.0564798	0.6059	0.5446	
phi_6	-0.0801962	0.0565488	-1.418	0.1561	
phi_7	0.0451529	0.0568329	0.7945	0.4269	
phi_8	-0.0238960	0.0572638	-0.4173	0.6765	
phi_9	0.144369	0.0572690	2.521	0.0117	**
Moy. var. dép.		-0.003322			
Éc. type var. dép.		0.033738			
Moyenne des innovations		0.000024			
Ec. type des innovations		0.033071			
Log de vraisemblance		620.8030			
Critère d'Akaike		-1219.606			
Critère de Schwarz		-1178.433			
Hannan-Quinn		-1203.150			

Quatrième étape : validation du modèle

1) Vérification : ε est un bruit blanc

ε est non observable, on l'approche à l'aide des résidus e de l'estimation $\hat{\varepsilon}_t = e_t$.

$$(1 - \varphi_1 B - \dots - \varphi_p B^p)X_t = (1 - \theta_1 B - \dots - \theta_q B^q)\varepsilon_t$$

$$(1 - \hat{\varphi}_1 B - \dots - \hat{\varphi}_p B^p)X_t = (1 - \hat{\theta}_1 B - \dots - \hat{\theta}_q B^q)e_t$$

ε doit être de moyenne nulle

$$H_0 : \mathbb{E}[\varepsilon] = 0$$

sous H_0 on a $\sqrt{T}\bar{e}/\hat{\sigma} \sim \mathcal{N}(0, 1)$.

On rejette H_0 avec un risque $\alpha = 5\%$ lorsque la statistique $t = \sqrt{T}\bar{e}/\hat{\sigma}$ est supérieure à 1.96 en valeur absolue.


Sur l'exemple, on obtient avec R les résultats suivants :

- moyenne des innovations : 0.000024
- Ec. type des innovations : 0.033071

$$t. = \sqrt{312} \frac{0.000024}{0.033071} = 0.013 < 1.96$$

On ne rejette pas $H_0 : \mathbb{E}[\varepsilon] = 0$ à un niveau 5%.

ε doit être de variance constante





ε doit être non-corrélé

Test individuel

$$H_0 : \rho_k(\varepsilon) = 0$$

sous $H_0 : \sqrt{T}\hat{\rho}_k(e) \sim \mathcal{N}(0, 1)$. On rejette H_0 avec un risque $\alpha = 5\%$

lorsque l'autocorrélation estimée $\hat{\rho}_k(e)$ est supérieure à $1.96/\sqrt{T}$ en valeur absolue.



Test global [Portemaneau]

$$H_0 : \rho_1(\varepsilon) = \rho_2(\varepsilon) = \cdots = \rho_K(\varepsilon) = 0$$

Statistique de Box-Pierce :

$$\text{Sous } H_0 : Q = T \sum_{k=1}^K \hat{\rho}_k^2(e) \sim \chi_{K-p-q}^2.$$

$$RH_0 \text{ si } Q > \chi_{K-p-q; 1-\alpha}^2$$

Statistique de Ljung-Box : Sous

$$H_0 : Q' = T(T+2) \sum_{k=1}^K \frac{\hat{\rho}_k^2(e)}{T-k} \sim \chi_{K-p-q}^2.$$

$$RH_0 \text{ si } Q > \chi_{K-p-q; 1-\alpha}^2$$

Fonction d'auto-corrélation résiduelle

RETARD	ACF	PACF	Q	[p. crit.]
1	0.0044	0.0044	0.0062	[0.937]
2	-0.0144	-0.0144	0.0715	[0.965]
3	0.0098	0.0099	0.1020	[0.992]
4	-0.0044	-0.0047	0.1082	[0.999]
5	0.0206	0.0210	0.2440	[0.999]
6	-0.0078	-0.0083	0.2636	[1.000]
7	0.0043	0.0051	0.2696	[1.000]
8	-0.0019	-0.0026	0.2708	[1.000]
9	0.0038	0.0043	0.2756	[1.000]
10	-0.0294	-0.0302	0.5561	[1.000]
11	0.1056 *	0.1066 *	4.1839	[0.964]
12	-0.0426	-0.0459	4.7763	[0.965]
13	-0.0263	-0.0216	5.0026	[0.975]
14	-0.0702	-0.0750	6.6213	[0.948]

2) Tests sur les coefficients

Ces tests sont utiles pour éliminer des coefficients non significatifs des modèles ou pour juger de la pertinence d'une augmentation ou d'une diminution des ordres du modèle.

Modèle 2: ARMA, utilisant les observations 1985:09-2011:08
(T = 312)

Variable dépendante: ld_SWISSDOL

	coefficient	erreur std.	z	p. critique	
const	-0.003480	0.0021727	-1.602	0.1092	
phi_9	0.133302	0.0572753	2.327	0.0199	**

Moy. var. dép.	-0.003322
Éc. type var. dép.	0.033738
Moyenne des innovations	0.000072
Ec. type des innovations	0.033387
Log de vraisemblance	617.8843
Critère d'Akaike	-1229.769
Critère de Schwarz	-1218.540
Hannan-Quinn	-1225.281

Cinquième étape : calcul des prévisions

Premier exemple : $AR(2)$.

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \varepsilon_t$$

On a les données $X_1, X_2, \dots, X_T$.

Prévisions faites en T pour $X_{T+1}, X_{T+2}, \dots$

On a les prévisions

$$\widehat{X}_T(1), \widehat{X}_T(2), \dots$$

$$X_{T+1} = \varphi_1 X_T + \varphi_2 X_{T-1} + \varepsilon_{T+1}$$

$$\mathbb{E}\mathbb{L}[X_{T+1}|X_T, \dots, X_{T-1}] = \varphi_1 X_T + \varphi_2 X_{T-1}$$

$$\widehat{X}_T(1) = \widehat{\varphi}_1 X_T + \widehat{\varphi}_2 X_{T-1}$$

$$X_{T+2} = \varphi_1 X_{T+1} + \varphi_2 X_T + \varepsilon_{T+2}$$

$$\mathbb{E}\mathbb{L}[X_{T+2}|X_T, \dots, X_{T-1}] = \varphi_1 \mathbb{E}\mathbb{L}[X_{T+1}|X_T, \dots, X_{T-1}] + \varphi_2 X_T$$

$$\widehat{X}_T(2) = \widehat{\varphi}_1 \widehat{X}_T(1) + \widehat{\varphi}_2 X_T + \varepsilon_{T+1}$$

$$\widehat{X}_T(h) = \widehat{\varphi}_1 \widehat{X}_T(h-1) + \widehat{\varphi}_2 \widehat{X}_T(h-2), \quad h \geq 3$$

Deuxième exemple : $MA(2)$

$$X_t = \varepsilon_t - \theta_1 \varepsilon_{t-1} - \theta_2 \varepsilon_{t-2}$$

$$X_{T+1} = \varepsilon_{T+1} - \theta_1 \varepsilon_T - \theta_2 \varepsilon_{T-1}$$

$$\mathbb{E}[X_{T+1} | X_T, X_{T-1}, \dots] = -\theta_1 \varepsilon_T - \theta_2 \varepsilon_{T-1}$$

$$\widehat{X}_T(1) = -\widehat{\theta}_1 \varepsilon_{t-1} - \widehat{\theta}_2 \varepsilon_{t-2}$$

$$X_{T+2} = \varepsilon_{T+2} - \theta_1 \varepsilon_{T+1} - \theta_2 \varepsilon_T$$

$$\mathbb{E}[X_{T+2} | X_T, X_{T-1}, \dots] = -\theta_2 \varepsilon_T$$

$$\widehat{X}_T(2) = -\widehat{\theta}_2 \varepsilon_T$$

et

$$\widehat{X}_T(h) = 0, \quad h \geq 3.$$

Pour un *ARMA*, on combine ces deux exemples.
Les prévisions sont des combinaisons linéaires des observations X_t et des résidus $e_t, t = 1, \dots, T$.

Erreurs de prévisions

A l'horizon 1 :

$$\Phi(B)X_t = \Theta(B)\varepsilon_t \Rightarrow X_t = \Phi(B)^{-1}\Theta(B)\varepsilon_t$$

$$\Rightarrow X_t = \varepsilon_t + \alpha_1\varepsilon_{t-1} + \alpha_2\varepsilon_{t-2} + \dots$$

$$\mathbb{E}\mathbb{L}[X_t|X_{t-1}, X_{t-2}, \dots] = \alpha_1\varepsilon_{t-1} + \alpha_2\varepsilon_{t-2} + \dots$$

$$X_t - \mathbb{E}\mathbb{L}[X_t|X_{t-1}, X_{t-2}, \dots] = \varepsilon_t$$

$$X_t - \widehat{X}_{t-1}(1) = e_t$$

A l'horizon 2 :

$$\Phi(B)X_t = \Theta(B)\varepsilon_t \Rightarrow X_t = \Phi(B)^{-1}\Theta(B)\varepsilon_t$$

$$\Rightarrow X_t = \varepsilon_t + \alpha_1\varepsilon_{t-1} + \alpha_2\varepsilon_{t-2} + \cdots$$

$$\mathbb{E}\mathbb{L}[X_t|X_{t-2}, X_{t-3}, \cdots] = \alpha_2\varepsilon_{t-2} + \alpha_3\varepsilon_{t-3} + \cdots$$

$$X_t - \mathbb{E}\mathbb{L}[X_t|X_{t-2}, X_{t-3}, \cdots] = \varepsilon_t + \alpha_1\varepsilon_{t-1}$$

$$X_t - \widehat{X}_{t-2}(2) = e_t + \hat{\alpha}_1 e_{t-1}.$$

A l'horizon h :

$$\Phi(B)X_t = \Theta(B)\varepsilon_t \Rightarrow X_t = \Phi(B)^{-1}\Theta(B)\varepsilon_t$$

$$\Rightarrow X_t = \varepsilon_t + \alpha_1\varepsilon_{t-1} + \alpha_2\varepsilon_{t-2} + \cdots$$

$$\mathbb{E}[X_{t-h}|X_{t-h-1}, \cdots] = \alpha_h\varepsilon_{t-h} + \alpha_{h+1}\varepsilon_{t-h-1} + \cdots$$

$$X_t - \mathbb{E}[X_t|X_{t-h}|X_{t-h-1}, \cdots] = \varepsilon_t + \cdots + \alpha_{h-1}\varepsilon_{t-h+1}$$

$$X_t - \widehat{X}_{t-h}(h) = e_t + \hat{\alpha}_1 e_{t-1} + \cdots + \hat{\alpha}_{h-1} e_{t-h+1}.$$

Intervalles de prévisions

Pour la prévision à l'ordre 1, on a :

$$X_{T+1} - \widehat{X}_T(1) = \mathcal{N}(0, \widehat{\sigma}^2)$$

Donc $\mathbb{P}(-1.96\widehat{\sigma} < e_{T+1} < 1.96\widehat{\sigma}) \simeq 0.95$ et l'intervalle de prévision pour la valeur future X_{T+1} (au niveau 95%) est :

$$[\widehat{X}_T(1) - 1.96\widehat{\sigma}; \widehat{X}_T(1) + 1.96\widehat{\sigma}]$$

Cet intervalle a la même largeur, quelle que soit la date T .

Pour la prévision à l'horizon h , on a :

$$\begin{aligned} X_{T+h} - \widehat{X}_T(h) &= e_{T+h} + \alpha_1 e_{T+h-1} + \cdots + \alpha_{h-1} e_{T+1} \\ &\simeq \mathcal{N}(0; [1 + \hat{\alpha}_1^2 + \cdots + \hat{\alpha}_{h-1}^2] \hat{\sigma}^2) \end{aligned}$$

L'intervalle de prévision pour la valeur future X_{T+h} est :


$$[\widehat{X}_T(h) \pm 1.96[1 + \hat{\alpha}_1^2 + \cdots + \hat{\alpha}_{h-1}^2] \hat{\sigma}]$$

Cet intervalle a une largeur croissante avec h . Pour h fixé, la largeur ne dépend pas de t .

Pour l'intervalle de confiance à 95%, $z(.0.025) = 1.96$

ld_SWISSDOL

Obs	prédiction	intervalle de 95%
2011:09	-0.011028	-0.076465 - 0.054409
2011:10	-0.002521	-0.067958 - 0.062916
2011:11	-0.005125	-0.070562 - 0.060312
2011:12	-0.004969	-0.070406 - 0.060468
2012:01	-0.010263	-0.075699 - 0.055174



Sixième étape : comparaison de modèles

Il arrive que plusieurs modèles soient satisfaisants du point de vue statistique. Il faut alors choisir le meilleur d'entre eux, en comparant leur qualité d'ajustement et de prévision.

On utilise les critères d'information et les critères de qualité prédictive.

Critères d'information :

Critère *AIC* (Akaike Information Criterion) :

$$AIC = -2\log(\mathcal{L}) + 2(p + q)$$

Un modèle est préférable à un autre lorsque son critère *AIC* est inférieur à celui de l'autre modèle.

Critère *SBIC* (Schwarz Bayesian Information Criterion) :

$$SBIC = -2\log(\mathcal{L}) + (p + q) \log(T)$$



Un modèle est préférable à un autre lorsque son critère *SBIC* est inférieur à celui de l'autre modèle.

Modèle 2: ARMA, utilisant les observations 1985:09-2011:08

(T = 312)

Variable dépendante: ld_SWISSDOL

	coefficient	erreur std.	t	p. critique	
const	-0.00344406	0.00212964	-1.617	0.1058	
theta_9	0.129969	0.0555260	2.341	0.0192	**
Moy. var. dép.		-0.003322			
Éc. type var. dép.		0.033738			
Moyenne des innovations		0.000055			
Ec. type des innovations		0.033392			
Log de vraisemblance		617.8362			
Critère d'Akaike		-1229.672			
Critère de Schwarz		-1218.443			
Hannan-Quinn		-1225.185			



Fonction d'auto-corrélation résiduelle

RETARD	ACF	PACF	Q	[p. crit.]
1	0.0438	0.0438	0.6033	[0.437]
2	-0.0272	-0.0292	0.8369	[0.658]
3	0.0425	0.0451	1.4098	[0.703]
4	-0.0685	-0.0736	2.9022	[0.574]
5	0.0271	0.0369	3.1374	[0.679]
6	-0.0680	-0.0785	4.6169	[0.594]
7	0.0250	0.0422	4.8179	[0.682]
8	0.0017	-0.0159	4.8188	[0.777]
9	0.0013	0.0171	4.8194	[0.850]
10	-0.0020	-0.0194	4.8206	[0.903]
11	0.0892	0.1041 *	7.4097	[0.765]
12	-0.0262	-0.0500	7.6330	[0.813]
13	-0.0455	-0.0251	8.3126	[0.823]
14	-0.0615	-0.0783	9.5558	[0.794]

Critères de qualité prédictive

- l'erreur moyenne $\bar{e} = \frac{1}{T} \sum_{i=1}^T e_i$
- l'erreur moyenne absolue $MAE = \frac{1}{T} \sum_{i=1}^T |e_i|$
- le carré moyen des erreurs

$$MSE = \frac{1}{T} \sum_{i=1}^T e_i^2 = \frac{SCR}{n}$$

- la variance empirique de l'erreur

$$\mathbb{V}_e(e) = \frac{1}{T} \sum_{i=1}^T (e_i - \bar{e})^2$$

- l'erreur moyenne absolue en pourcentage

$$MAPE = \frac{1}{T} \sum_{i=1}^T \left| \frac{e_i}{X_i} \right|$$